Departamento de Informática
Universidad Técnica Federico Santa María
INF-396 Introducción a la Ciencia de Datos · Segundo semestre 2026

La función de pérdida de mínimos cuadrados

1. El modelo y su pérdida

Se tienen n observaciones (x_i, y_i), $i = 1, \dots, n$. El modelo de regresión lineal simple predice

$$\hat{y}_i = b_0 + b_1 x_i,$$

donde b_0 (intercepto) y b_1 (pendiente) son los coeficientes que hay que elegir. El residuo de la observación i es $e_i = y_i - \hat{y}_i$, y la pérdida cuadrática de esa observación es $L(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2$. Hay que distinguir dos cosas:

- L es la *función de pérdida*: mide el costo del error en una sola observación.
- S es lo que se minimiza: la suma de las pérdidas en los n datos de entrenamiento, que en mínimos cuadrados es la suma de cuadrados de los residuos (James et al., 2013, p. 62).

$$S(b_0, b_1) = \sum_{i=1}^{n} L(y_i, \hat{y}_i) = \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2. \tag{1}$$

Mínimos cuadrados elige los coeficientes que minimizan S: $(\hat{b}_0, \hat{b}_1) = \arg\min_{b_0, b_1} S(b_0, b_1)$. Minimizar S o la pérdida promedio S/n da los mismos coeficientes, porque dividir por n no cambia dónde está el mínimo. Lo mismo vale para el RMSE, $\sqrt{S/n}$: la raíz es creciente.

2. Derivar e igualar a cero

S es una función de dos variables, b_0 y b_1; los datos x_i e y_i son números fijos. En un mínimo, las dos derivadas parciales valen cero. Por la regla de la cadena,

$$\frac{\partial S}{\partial b_0} = -2 \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i) = 0, \tag{2}$$

$$\frac{\partial S}{\partial b_1} = -2 \sum_{i=1}^{n} x_i \, (y_i - b_0 - b_1 x_i) = 0. \tag{3}$$

Estas dos igualdades son las *ecuaciones normales*. Como $y_i - b_0 - b_1 x_i$ es el residuo e_i, también dicen dos cosas sobre los residuos de la recta ajustada:

- $\sum e_i = 0$: los residuos promedian cero. La recta no se equivoca sistemáticamente hacia arriba ni hacia abajo.
- $\sum x_i e_i = 0$: junto con lo anterior, los residuos tienen correlación cero con x. La recta ya usó toda la relación lineal entre x e y; lo que queda en los residuos no se puede predecir con una recta en x.

El intercepto. De (2), $\sum y_i - n b_0 - b_1 \sum x_i = 0$. Dividiendo por n, con $\bar{x} = \frac{1}{n}\sum x_i$ e $\bar{y} = \frac{1}{n}\sum y_i$,

$$\hat{b}_0 = \bar{y} - \hat{b}_1 \bar{x}. \tag{4}$$

Es decir, la recta pasa por el punto de los promedios $(\bar{x}, \bar{y})$.

La pendiente. Se reemplaza (4) en (3). Como $y_i - b_0 - b_1 x_i = (y_i - \bar{y}) - b_1 (x_i - \bar{x})$,

$$\sum_{i=1}^{n} x_i (y_i - \bar{y}) = b_1 \sum_{i=1}^{n} x_i (x_i - \bar{x}).$$

Además $\sum \bar{x}\,(y_i - \bar{y}) = 0$ y $\sum \bar{x}\,(x_i - \bar{x}) = 0$, porque las desviaciones respecto del promedio suman cero. Restando esos ceros a cada lado, la x_i que multiplica se puede reemplazar por $x_i - \bar{x}$:

$$\hat{b}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}. \tag{5}$$

Estas son las fórmulas (3.4) de James et al. (2013, p. 62), que el libro presenta sin la derivación. Si se divide el numerador y el denominador por $n - 1$, el numerador es la covarianza de x e y y el denominador, la varianza de x. Con la correlación de Pearson r y las desviaciones estándar s_x y s_y, la misma pendiente se escribe

$$\hat{b}_1 = r\,\frac{s_y}{s_x}.$$

3. ¿Es un mínimo?

Que las derivadas valgan cero también ocurre en un máximo o en un punto silla. Para descartarlo se miran las segundas derivadas, que forman la matriz hessiana:

$$H = \begin{pmatrix} \dfrac{\partial^2 S}{\partial b_0^2} & \dfrac{\partial^2 S}{\partial b_0\,\partial b_1} \\[2ex] \dfrac{\partial^2 S}{\partial b_1\,\partial b_0} & \dfrac{\partial^2 S}{\partial b_1^2} \end{pmatrix} = 2\begin{pmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix}.$$

Su primer elemento, $2n$, es positivo, y su determinante es

$$\det H = 4\Big(n\sum x_i^2 - \big(\sum x_i\big)^2\Big) = 4n\sum_{i=1}^{n}(x_i - \bar{x})^2 > 0,$$

siempre que no todos los x_i sean iguales. Entonces H es definida positiva en todo punto: S es una función convexa, con forma de cuenco, y el punto donde se anulan las derivadas es su único mínimo. Si todos los x_i fueran iguales, el determinante sería cero y la pendiente no quedaría determinada: con una sola x no hay recta que ajustar.

4. Con varias variables: la forma matricial

Con p variables, se arma la matriz X de $n \times (p + 1)$, con una columna de unos para el intercepto y una columna por variable, y el vector de coeficientes $b = (b_0, b_1, \ldots, b_p)^\top$. Las predicciones son $\hat{y} = Xb$ y la suma de cuadrados es

$$S(b) = \|y - Xb\|^2 = (y - Xb)^\top (y - Xb).$$

El gradiente es $\nabla S(b) = -2\,X^\top(y - Xb)$. Igualarlo a cero da las ecuaciones normales en forma matricial,

$$X^\top X\,\hat{b} = X^\top y \qquad \Longrightarrow \qquad \hat{b} = (X^\top X)^{-1} X^\top y, \tag{6}$$

siempre que $X^\top X$ sea invertible (Hastie, Tibshirani y Friedman, 2009, sección 3.2). Con $p = 1$, (6) entrega las mismas fórmulas (4) y (5). La hessiana es $2X^\top X$, que es semidefinida positiva porque $v^\top X^\top X v = \|Xv\|^2 \geq 0$ para cualquier vector v: otra vez, S es convexa.

La condición $X^\top(y - X\hat{b}) = 0$ tiene una lectura geométrica: el vector de residuos es perpendicular a cada columna de X. Con la columna de unos, eso es $\sum e_i = 0$; con la columna de x, es $\sum x_i e_i = 0$, las mismas condiciones de la sección 2.

$X^\top X$ deja de ser invertible cuando una columna es combinación lineal de otras (colinealidad perfecta) o cuando hay más coeficientes que observaciones, $p + 1 > n$. En esos casos hay infinitas soluciones con la misma pérdida mínima, y mínimos cuadrados por sí solo no elige entre ellas. Es uno de los motivos para agregar a la pérdida un castigo por los coeficientes, como en Ridge y Lasso.

5. Un ejemplo: el salario y las carreras anotadas

Con los 263 jugadores de béisbol con salario de los datos Hitters (James et al., 2013), y es el salario de 1987, en miles de dólares, y x, las carreras anotadas en toda la carrera:

Cantidad	Valor
n	263
$\bar{x}$ (carreras)	361,2
$\bar{y}$ (miles de dólares)	535,9
$\sum(x_i - \bar{x})(y_i - \bar{y})$	22.026.235
$\sum(x_i - \bar{x})^2$	28.739.433

Con (5), $\hat{b}_1 = 22.026.235/28.739.433 = 0{,}766$: cada carrera anotada en la carrera se asocia, en promedio, con 766 dólares más de salario. Con (4), $\hat{b}_0 = 535{,}9 - 0{,}766 \times 361{,}2 = 259{,}1$. La recta ajustada es

$$\widehat{\text{salario}} = 259{,}1 + 0{,}766 \times \text{carreras}.$$

La suma de cuadrados en el mínimo es $S = 36.437.951$, que corresponde a un RMSE de $\sqrt{S/263} = 372$ miles de dólares. Es el punto más bajo de la curva de la pérdida contra la pendiente que se vio en clase: cualquier otra pendiente, con su intercepto, da un RMSE mayor. También se puede verificar la otra forma de la pendiente: con $r = 0{,}563$, $s_y = 451{,}1$ y $s_x = 331{,}2$, $r\, s_y / s_x = 0{,}767$, igual salvo por el redondeo. En el código, `np.polyfit(x, y, 1)` y `LinearRegression` de scikit-learn entregan estos mismos dos números.

Referencias

Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The Elements of Statistical Learning* (2.ª ed.). Springer. Sección 3.2.

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer. Sección 3.1.1, pp. 61 y 62. PDF gratuito en statlearning.com.