Pauta de corrección: Certamen 1

INF-396 Introducción a la Ciencia de Datos

Universidad Técnica Federico Santa María · Departamento de Informática
Certamen 1, viernes 9 de octubre de 2026 · Duración: 2 horas · Puntaje total: 100 puntos

Resumen de puntajes

Parte	Preguntas	Puntos
1. Alternativas	A a J, 2 puntos cada una	20
2. Desarrollo	Una pregunta a elección: 1 (regresión múltiple) o 2 (dos correlaciones)	40
3. Cálculo	3 (Spearman, 15 puntos) y 4 (regresión por comuna, inferencia y bootstrap, 25 puntos)	40
Total		**100**

Criterios generales

Se corrige el argumento y el procedimiento, no solo el número final. La calculadora es opcional: una aproximación hecha a mano con el método correcto ($r \approx 0{,}65$ o $0{,}66$ para $\sqrt{0{,}433}$; $t \approx 5{,}7$) vale el puntaje completo. Un error aritmético con el método correcto deja el ítem en Parcialmente logrado, en la parte alta del rango; un número correcto sin procedimiento ni interpretación, en Parcialmente logrado. Los rangos de puntaje de cada nivel son orientativos: dentro de cada nivel se elige el puntaje según cuánto falta.

Parte 1. Alternativas (20 puntos)

Dos puntos por pregunta. Cero si hay más de una opción marcada.

Clave

Pregunta	Respuesta
A	b
B	c
C	a
D	b
E	b
F	d
G	c
H	d
I	b
J	d

Justificación de cada pregunta

- **A: b)** Pearson se calcula con los valores y es sensible a los puntos extremos: las cuatro comunas de ingreso más alto (Lo Barnechea, La Reina, Vitacura y Las Condes) están muy por sobre el resto y en la línea de la tendencia, y elevan el coeficiente, de ahí el 0,90. Spearman reemplaza los valores por rangos, y esas comunas pasan a ser solo las posiciones 42 a 45: mide la monotonía sin que los

extremos dominen, 0,73. La a) es falsa: Spearman no descarta observaciones, usa las 45 comunas y solo reemplaza cada valor por su rango; Pearson no es siempre mayor (c) y los dos coeficientes no tienen por qué coincidir (d).

- **B: c)** El código de comuna es una etiqueta: categórica nominal. Que esté guardada como número (tipo computacional) no la vuelve numérica (tipo estadístico); el promedio no tiene sentido.

- **C: a)** La caja de Bip! va de 38 a 80 minutos y la mediana del auto es 26: toda la mitad central de Bip! queda por sobre ella. La b) es falsa porque los atípicos están ocultos y el bigote termina en el último dato bajo la cerca de 1,5 IQR, no en el máximo (el viaje más largo en Bip! supera las 2 horas); en c) el IQR del auto es 25 y el de Bip! 42; la d) es falsa: 15 minutos es el primer cuartil del auto, así que solo el 25 % de sus viajes dura menos.

- **D: b)** Con dos ejes verticales cada línea se dibuja en su propia escala, y las líneas se cruzan donde el autor decidió alinear las escalas: cambiando el rango de un eje, el cruce se mueve a otra hora o desaparece. Lo único legible es la forma de cada serie por separado. La a) compara unidades distintas (miles de viajes contra porcentaje); la c) es falsa, Cairo no prohíbe las dobles escalas, advierte cómo leerlas; la d) infiere causalidad de una coincidencia visual.

- **E: b)** Las seis dummies sumarían 1 en toda fila, igual que la constante: colinealidad perfecta. Se elimina una, que queda de referencia, y cada coeficiente se lee contra ella. La d) es falsa: una columna redundante no lleva el R^2 a 1; el problema es la colinealidad.

- **F: d)** Media muy por sobre la mediana: cola hacia la derecha, unos pocos valores altos arrastran la media; la mediana deja la mitad de las personas a cada lado, así que más de la mitad gana menos que el promedio. La b) confunde la media con la mediana; la c) no se deduce de los datos: la mitad de los sueldos está bajo $800.000.

- **G: c)** Entre Q_1 y Q_3 está el 50 % central. IQR $= 40$; cerca superior $60 + 1{,}5 \cdot 40 = 120$, y 125 la supera. La mediana no se deduce de los cuartiles (a), el 25 % es menor que 20 (b), y el IQR es 40, no 80 (d).

- **H: d)** Con factores de expansión cada fila pesa lo que representa: 100, 100 y 600 personas. La media ponderada $(0 \cdot 100 + 0 \cdot 100 + 4 \cdot 600)/800 = 3{,}0$ describe a la población; la simple describe a los tres encuestados. Los factores no tienen que sumar ninguna cantidad fija (c), y sirven igual para totales y promedios (b).

- **I: b)** Es un proxy: cuando el modelo no observa lo que le interesa (el ingreso), lo reemplaza por una variable correlacionada (la comuna), y cada persona queda juzgada por el grupo al que pertenece y no por lo que hizo; O'Neil muestra que así el modelo reproduce la desigualdad de partida. La a) confunde dato público con dato inocuo; la c) es falsa, O'Neil no exige variables medidas en cada persona, critica los proxies que juzgan por el grupo; la d) es falsa, la transparencia no elimina el daño que causa un proxy.

- **J: d)** Variable ordinal: los códigos 1, 2 y 3 tienen orden pero no distancias iguales, así que la media y la desviación estándar no tienen sentido; la mediana y la moda sí. No es nominal (c), porque el orden sí importa; la a) es falsa, nada garantiza que los códigos estén igualmente espaciados.

Parte 2. Desarrollo (40 puntos, una pregunta a elección)

Si el estudiante respondió las dos preguntas, se corrige únicamente la 1.

Pregunta 1: interpretación de una regresión lineal (40 puntos)

Respuesta esperada

a) La ecuación ajustada es

$$\log_{10}(\text{duración}) = 1{,}164 + 0{,}368 \cdot \log_{10}(\text{km}) + 0{,}055 \cdot \text{Bicicleta} + 0{,}263 \cdot \text{Bip!} \\ + 0{,}015 \cdot \text{Caminata} + 0{,}008 \cdot \text{Taxi} + 0{,}119 \cdot \text{TaxiColectivo}.$$

El 0,368 se lee con el modo fijo: por cada unidad que sube el logaritmo de la distancia, el logaritmo de la duración sube 0,368. En términos multiplicativos, multiplicar la distancia por 10 multiplica la duración por $10^{0{,}368} = 2{,}3$. La referencia es el auto, el único de los seis modos que no está en la tabla: sus dummies valen 0, y el intercepto 1,164 es el logaritmo de la duración predicha para un viaje en auto con $\log_{10}(\text{km}) = 0$, es decir, de 1 km ($10^{1{,}164} = 14{,}6$ minutos).

b) Bip!: a igual distancia, un viaje en Bip! tarda 1,83 veces lo que uno en auto (un 83 % más). Taxi colectivo: 1,32 veces, un 32 % más. Taxi: el coeficiente 0,008 tiene $p = 0{,}317$ e intervalo $[-0{,}008;\ 0{,}024]$, que incluye el 0. Si en la población el taxi no tuviera efecto, un coeficiente tan lejos de cero como este aparecería por azar de la muestra en un 32 % de los casos: no es un resultado raro. A igual distancia, no se puede distinguir la duración de un viaje en taxi de la de uno en auto; el multiplicador 1,02 es compatible con 1.

c) El modelo no respalda la conclusión tal como está formulada. Sostiene una asociación: en estos datos, a igual distancia, los viajes en Bip! duran más que los viajes en auto. No sostiene que un mismo pasajero, al cambiar de modo, acorte su viaje: las personas que viajan en Bip! y en auto difieren en variables que el modelo no incluye (hora del viaje y congestión, origen y destino, acceso a la red de metro, ingreso, propósito del viaje), y parte de la diferencia puede deberse a eso. Para que la frase fuera válida habría que suponer que los pasajeros de Bip! y de auto son comparables en todo lo demás, o comparar a las mismas personas con un diseño distinto. Las medias sin controlar (62 minutos en Bip! contra 32 en auto) son el origen del "casi la mitad": la razón es 0,52 sin controlar y $1/1{,}83 = 0{,}55$ a igual distancia, parecidas, pero en los dos casos se comparan personas distintas. Mérito adicional, sin exigirlo: el taxi colectivo dura lo mismo que el auto sin controlar (32) pero un 32 % más a igual distancia, señal de que sus viajes son más cortos en distancia.

Rúbrica

a) Ecuación y lectura (12 puntos)		**Puntos**
Logrado	Ecuación completa, lectura del coeficiente con las demás variables fijas (se acepta la lectura en escala logarítmica o la multiplicativa), referencia identificada y el intercepto leído para ella.	12
Parcialmente logrado	Ecuación correcta pero lectura incompleta, o referencia identificada sin leer el intercepto.	6 a 11
No logrado	Ecuación incorrecta, sin lectura, o con los coeficientes leídos como minutos.	0 a 5

b) Bip!, taxi colectivo y taxi (14 puntos)		Puntos
Logrado	Las dos lecturas con "a igual distancia", ya sea multiplicativas ($10^{0{,}263} = 1{,}83$ y $10^{0{,}119} = 1{,}32$, con calculadora) o en la escala del logaritmo (Bip! suma 0,263 al logaritmo de la duración; se acepta como completa), y el taxi leído como indistinguible del auto por el valor p y el intervalo. Si además escribe que el valor p es "la probabilidad de que el resultado sea coincidencia", 12 o 13.	14
Parcialmente logrado	Lecturas correctas pero sin "a igual distancia", o el taxi leído solo con el valor p sin el intervalo, o solo con la frase "probabilidad de que sea coincidencia" sin conclusión, o una de las dos lecturas mal.	7 a 13
No logrado	Lee los coeficientes como minutos, o no interpreta el taxi.	0 a 6

c) Asociación contra causalidad (14 puntos)		Puntos
Logrado	Dice que el modelo no respalda la frase, distingue la asociación a igual distancia de la afirmación causal, y nombra una variable omitida plausible.	14
Parcialmente logrado	Dice "correlación no es causalidad" sin aplicarlo al caso, o sin variable omitida.	7 a 13
No logrado	Acepta la conclusión causal sin distinguirla de la asociación, o la rechaza sin argumento.	0 a 6

Pregunta 2: dos correlaciones para las mismas variables (40 puntos)

Respuesta esperada

Es la falacia ecológica: una asociación entre promedios de grupos no implica la misma asociación entre los individuos.

a) Promedios por comuna: A $(0{,}5;\ 60)$, B $(1{,}0;\ 45)$, C $(1{,}5;\ 30)$.

Pearson con los tres promedios: $\bar{x} = 1{,}0$ e $\bar{y} = 45$.

$$\sum(x-\bar{x})(y-\bar{y}) = (-0{,}5)(15) + 0 + (0{,}5)(-15) = -15, \qquad \sum(x-\bar{x})^2 = 0{,}5, \qquad \sum(y-\bar{y})^2 = 450,$$

$$r = \frac{-15}{\sqrt{0{,}5 \cdot 450}} = \frac{-15}{15} = -1.$$

Pearson con los seis viajes: también $\bar{x} = 1{,}0$ e $\bar{y} = 45$; los productos $(x-\bar{x})(y-\bar{y})$ son 7, -12, 5, 5, -12 y 7, que suman 0, así que $r = 0{,}00$ sin necesidad de calcular el denominador.

Comparación: asociación negativa y perfecta entre comunas, ninguna entre los viajes. Lo que hay que notar: dentro de cada comuna, el viaje del hogar de mayor ingreso dura 50 minutos más (asociación positiva), y esa asociación dentro de las comunas cancela la negativa entre los promedios.

b) El estudiante no tiene razón. La correlación por comuna compara 45 promedios: cada uno resume más de mil viajes en promedio y borra la variación interna. La correlación por viaje compara los 69 mil viajes uno a uno, con toda esa variación. Ninguna está mal: miden asociaciones entre unidades distintas, y el promedio pierde la relación que existe dentro de cada comuna, tal como en el ejemplo.

c) La correlación por viaje responde a la pregunta sobre las personas; la correlación por comuna, a la pregunta sobre las comunas. Usar la segunda para afirmar algo sobre las personas no es válido: es exactamente el salto que el ejemplo muestra que falla.

Rúbrica

a) Promedios y los dos coeficientes (16 puntos)		**Puntos**
Logrado	Los seis promedios, $r = -1$ entre promedios y $r = 0$ entre viajes (se acepta "cercano a cero" por redondeo), con la comparación: negativa perfecta contra nula. Se valora, sin exigirlo, que note la asociación positiva dentro de cada comuna.	16
Parcialmente logrado	Promedios correctos con un solo coeficiente bien calculado, o los dos coeficientes con errores aritméticos pero el método correcto, o sin la comparación.	8 a 15
No logrado	Solo los promedios, o coeficientes con el signo al revés.	0 a 7

b) Qué compara cada correlación (12 puntos)		**Puntos**
Logrado	Dice que el estudiante no tiene razón, explica qué compara cada correlación (promedios de comunas contra viajes individuales) y que el promedio borra la variación dentro de la comuna, apoyándose en el ejemplo.	12
Parcialmente logrado	Explica que son unidades distintas sin conectar con el ejemplo, o no se pronuncia sobre si el estudiante tiene razón.	6 a 11
No logrado	Da la razón al estudiante, insistiendo en que una de las dos está mal.	0 a 5

c) Qué pregunta responde cada una (12 puntos)		Puntos
Logrado	Asigna la correlación por viaje a las personas y la correlación por comuna a las comunas, y argumenta que no es válido pasar de la segunda a la primera.	12
Parcialmente logrado	Asigna bien las dos correlaciones pero no se pronuncia sobre la validez del salto, o lo hace sin argumento.	6 a 11
No logrado	Asigna las correlaciones al revés.	0 a 5

Parte 3. Cálculo (40 puntos)

Pregunta 3: coeficiente de Spearman (15 puntos)

Respuesta esperada

a) Cálculo, paso a paso.

Paso 1. Rangos del ingreso. Se ordena de menor a mayor y se asigna 1 al menor:

$$0{,}50\ (\text{La Pintana}) < 0{,}65\ (\text{Conchalí}) < 0{,}71\ (\text{Santiago}) < 1{,}47\ (\text{Providencia}) < 1{,}50\ (\text{Ñuñoa}).$$

Rangos: La Pintana 1, Conchalí 2, Santiago 3, Providencia 4, Ñuñoa 5.

Paso 2. Rangos del transporte público, en la misma dirección (1 al menor):

$$18{,}5\ (\text{Providencia}) < 26{,}1\ (\text{Ñuñoa}) < 29{,}3\ (\text{Santiago}) < 49{,}3\ (\text{La Pintana}) < 51{,}8\ (\text{Conchalí}).$$

Rangos: Providencia 1, Ñuñoa 2, Santiago 3, La Pintana 4, Conchalí 5.

Paso 3. Diferencias de rangos $d_i = R(\text{ingreso}) - R(\text{TP})$ y sus cuadrados:

Comuna	Ingreso	Rango	TP (%)	Rango	d_i	d_i^2
La Pintana	0,50	1	49,3	4	-3	9
Conchalí	0,65	2	51,8	5	-3	9
Santiago	0,71	3	29,3	3	0	0
Providencia	1,47	4	18,5	1	3	9
Ñuñoa	1,50	5	26,1	2	3	9
$\sum d_i^2$						**36**

Paso 4. Fórmula, con $n = 5$:

$$\rho = 1 - \frac{6\sum d_i^2}{n\,(n^2-1)} = 1 - \frac{6 \cdot 36}{5\,(25-1)} = 1 - \frac{216}{5 \cdot 24}$$
$$= 1 - \frac{216}{120} = 1 - 1{,}80 = -0{,}80.$$

Si una variable se ordena al revés, los d_i pasan a ser $-1, 1, 0, -1, 1$, $\sum d_i^2 = 4$ y $\rho = +0{,}80$: misma magnitud con el signo invertido por la dirección de los rangos. Se acepta sin descuento.

b) Interpretación. El signo negativo dice que a mayor ingreso, menor proporción de viajes en transporte público. La magnitud 0,80 indica una asociación monótona fuerte, cercana al orden inverso perfecto; no llega a -1 porque dos pares de comunas intercambian el orden (La Pintana y Conchalí; Providencia y Ñuñoa). Frase esperada: "existe una asociación negativa fuerte entre el ingreso y el uso del transporte público: las comunas de mayor ingreso usan menos el transporte público".

Lo que no corresponde decir: "inversamente proporcional" o "relación lineal", porque Spearman solo mide monotonía y no la forma de la relación; ni "el 80 % de la disminución se explica por el ingreso", porque el coeficiente no es un porcentaje ni un R^2.

Rúbrica

Una columna por criterio; el puntaje se elige dentro del nivel que mejor describe la respuesta. Si una respuesta calza con dos descripciones de la misma columna, se usa la de menor puntaje.

	a) Rangos 3 puntos	**a) Diferencias** 2 puntos	**a) Fórmula y ρ** 5 puntos	**b) Magnitud y significado** 5 puntos
Logrado	Rangos de las dos variables correctos, en cualquier dirección. **3**	Tabla con d_i y d_i^2 por comuna y $\sum d_i^2 = 36$. **2**	Fórmula correcta con $n = 5$, desarrollo visible y $\rho = -0{,}80$. **5**	Asociación fuerte y qué significa para las comunas (a mayor ingreso, menor uso del transporte público), dicha como asociación u orden, sin hablar de proporción ni de porcentaje. **5**
Parcialmente logrado	Un rango equivocado. **1 a 2**	Tabla bien calculada a partir de rangos con error, o un error aritmético. **1**	Fórmula correcta con error aritmético. **3 a 4**	Solo la magnitud o solo el significado. **3 a 4** Habla de proporción o de relación lineal (“inversamente proporcional”, “relación lineal”), aunque el resto esté bien. **2 a 3**
No logrado	Sin rangos. **0**	Sin tabla de diferencias. **0**	Fórmula mal aplicada, o solo el número sin procedimiento. **0 a 2**	Lee el coeficiente como porcentaje, confundiéndolo con R^2 (“el 80 % de la disminución…”). **1** Sin interpretación. **0**

El signo de ρ depende de la dirección en que se asignaron los rangos ($-0{,}80$ o $+0{,}80$) y no se descuenta por él en ningún criterio. Lo que se evalúa en b) es que la interpretación diga que a mayor ingreso hay menor uso del transporte público.

Pregunta 4: regresión lineal por comuna, inferencia y bootstrap (25 puntos)

Respuesta esperada

a) duración $= 24{,}1 + 1{,}93 \cdot$ distancia. Pendiente: por cada kilómetro adicional de distancia media, la duración media de los viajes de una comuna sube 1,93 minutos. Intercepto: la duración predicha para distancia 0, un valor de referencia sin sentido físico aquí.

b) Predicción para 5,2 km: $24{,}1 + 1{,}93 \cdot 5{,}2 = 34{,}1$; residuo $= 44{,}0 - 34{,}1 = 9{,}9$ minutos. Positivo: en Quilicura los viajes duran casi 10 minutos más de lo que su distancia media predice.

c) $r = +\sqrt{0{,}433} = 0{,}66$, positivo porque la pendiente lo es. La distancia media explica el 43 % de la variación de la duración media entre comunas; el resto depende de otras variables (modo, congestión, origen de los viajes).

d) $t = 1{,}93/0{,}337 = 5{,}7$: la pendiente está a 5,7 errores estándar del cero. Bajo H_0 (pendiente real 0), el 95 % de las pendientes caería a menos de 2 errores estándar; 5,7 está mucho más lejos, y la probabilidad de un t así es menor que 0,0005, por eso el summary la redondea a 0,000. No es $p = 0$ exacto: es $p < 0{,}001$.

e)

(i) Medias de los remuestreos: 30, 50 y 28 minutos.

(ii) Un intervalo del 95 % deja fuera el 5 % de las medias bootstrap, repartido en dos colas de 2,5 % cada una. En 2.000 medias, cada cola tiene

$$0{,}025 \cdot 2.000 = 50 \text{ medias.}$$

Se ordenan las 2.000 medias de menor a mayor. El percentil 2,5 es la media que deja 50 por debajo: la número 50 desde abajo. El percentil 97,5 es la que deja 50 por encima: la número $2.000 - 50 = 1.950$. Entre las posiciones 50 y 1.950 quedan $1.950 - 50 = 1.900$ medias, que son el 95 % de 2.000. Los valores que ocupan esas posiciones fueron 18 y 70 minutos, así que el intervalo bootstrap es $[18;\ 70]$. También se acepta la posición 51 para el límite inferior o 1.951 para el superior, porque las convenciones para ubicar un percentil difieren en una unidad; lo que importa es el 50 como tamaño de cada cola.

(iii) Fórmula: $EE = 35{,}4/\sqrt{5} = 15{,}8$; intervalo $40 \pm 31{,}6 = [8{,}4;\ 71{,}6]$ (si se mantiene $EE = 15{,}83$ sin redondear, $2 \cdot EE = 31{,}66$ y sale $[8{,}3;\ 71{,}7]$; ambos valen). El error estándar bootstrap, 14,3, se parece al de la fórmula, pero el intervalo no: la fórmula supone que la media de la muestra se distribuye como una campana simétrica alrededor de 40, y con solo cinco datos y un valor de 100 eso no se cumple (el teorema central del límite necesita más datos). La campana baja hasta 8,4, un valor que ningún remuestreo puede producir: la media más baja posible es 10, si salen cinco veces el 10, y la distribución real de las medias es asimétrica, con cola hacia arriba. El bootstrap lee esa forma directamente, por eso su límite inferior es 18.

(iv) El bootstrap, porque con cinco datos y cola larga los supuestos de la fórmula no se cumplen. Con 500 viajes la media sí se distribuiría como campana, los dos intervalos coincidirían y serían mucho más angostos: el error estándar bajaría a unos $35/\sqrt{500} \approx 1{,}6$ minutos.

Rúbrica

a) Ecuación y lectura (4 puntos)		**Puntos**
Logrado	Ecuación y las dos lecturas con unidades.	4
Parcialmente logrado	Ecuación sin unidades en la lectura, o sin leer el intercepto.	2 a 3
No logrado	Ecuación incorrecta.	0 a 1

b) Residuo (4 puntos)		**Puntos**
Logrado	9,9 con el signo interpretado.	4
Parcialmente logrado	Residuo con signo invertido o sin interpretar.	2 a 3
No logrado	Sin predicción.	0 a 1

c) r y R^2 (4 puntos)		**Puntos**
Logrado	0,66 y la lectura como fracción de variación explicada.	4
Parcialmente logrado	r sin lectura, o lectura sin r.	2 a 3
No logrado	Confunde R^2 con la pendiente.	0 a 1

d) t y p (5 puntos)		**Puntos**
Logrado	$t = 5{,}7$ explicado como errores estándar del cero y $p < 0{,}001$.	5
Parcialmente logrado	t correcto sin explicar, o p leído como "cero".	2 a 4
No logrado	Sin t.	0 a 1

e) Bootstrap de la media (8 puntos, por subítem)

Subítem	**Qué se pide y cómo se reparte**	**Puntos**
(i)	Las tres medias: 30, 50 y 28.	1
(ii)	Las posiciones 50 y 1.950, o 51 y 1.951, con el 50 como tamaño de cada cola (1 punto) y el intervalo $[18;\ 70]$ (1 punto).	2
(iii)	El intervalo $[8{,}4;\ 71{,}6]$ o $[8{,}3;\ 71{,}7]$ (1 punto) y la explicación de la diferencia: pocos datos y cola larga, la fórmula supone una campana simétrica y el bootstrap lee la forma real, 8,4 es un valor imposible (2 puntos). Con solo "son distintos porque uno es simulado" se da 1 de esos 2.	3
(iv)	Elige el bootstrap con la razón (1 punto) y el efecto de $n = 500$: los dos intervalos coincidirían y serían mucho más angostos (1 punto). Confundir el bootstrap con repetir la encuesta deja el subítem en 0.	2