Tarea 2

Departamento de Informática
Universidad Técnica Federico Santa María
INF-396 Introducción a la Ciencia de Datos · Segundo semestre 2026
Modalidad: en parejas · **Publicación**: lunes 26 de octubre
Entrega: martes 10 de noviembre por Aula
Puntaje: 100 puntos · Atrasos: 10 puntos menos por día, hasta 3 días; después, nota mínima

Qué se entrega

1. **Parte 1**: un PDF escrito en LaTeX, `tarea2_apellido1_apellido2_parte1.pdf`.
2. **Partes 2 a 4**: un notebook ejecutado, `tarea2_apellido1_apellido2.ipynb`, a partir de la plantilla `tarea2_plantilla.ipynb`, que corra de principio a fin en el entorno del curso (`uv sync`) leyendo los datos desde `datos/tarea2/`. Al final, la declaración de uso de IA generativa, en una línea.

Los contenidos de esta tarea entran en el Certamen 2. Por eso, a diferencia de la Tarea 1, el uso de IA generativa se limita a consultas breves: las demostraciones, el código y las interpretaciones deben ser trabajo propio de la pareja.

La plantilla separa entrenamiento y prueba, con el 30% en prueba y la semilla 396. En los tumores la separación es estratificada: se sortea el 30% de cada clase, de modo que ambas mitades conservan la proporción de malignos. No cambien esa separación.

Parte 1. Teoría (20 puntos)

1. Soluciones de Ridge y Lasso en una variable (15 pts). Sea $x \in \mathbb{R}^n$ una variable estandarizada, con $\Sigma x_i = 0$ y $\Sigma x_i^2 = n$, sea $y \in \mathbb{R}^n$ una respuesta centrada, y considere el modelo sin intercepto $y = b \cdot x$. Sea $b_{mco} = (1/n) \cdot \Sigma x_i y_i$ el estimador de mínimos cuadrados.

- Demuestren que, para $\lambda > 0$, el minimizador de $\Sigma(y_i - b \cdot x_i)^2 + \lambda b^2$ es $b_{ridge} = b_{mco} \cdot n / (n + \lambda)$.
- Demuestren que el minimizador de $(1/2n) \cdot \Sigma(y_i - b \cdot x_i)^2 + \lambda |b|$ es $b_{lasso} = b_{mco} - \lambda$ si $b_{mco} > \lambda$, $b_{lasso} = b_{mco} + \lambda$ si $b_{mco} < -\lambda$, y $b_{lasso} = 0$ si $|b_{mco}| \le \lambda$. Indicación: la función objetivo es convexa y no es diferenciable en $b = 0$; analicen los casos $b > 0$, $b < 0$ y $b = 0$.
- A partir de ambas expresiones, expliquen por qué Lasso anula coeficientes y Ridge solo los contrae.

Estas son las funciones objetivo que utiliza scikit-learn.

2. Monotonía de la norma de la solución de Ridge (5 pts). Sean b_1 y b_2 las soluciones de Ridge para λ_1 y λ_2, con $0 < \lambda_1 < \lambda_2$. Demuestren que $\|b_2\|^2 \le \|b_1\|^2$. Indicación: cada solución minimiza su propia función objetivo; escriban las dos desigualdades correspondientes y súmenlas.

Parte 2. Implementación (25 puntos)

En esta parte se trabaja con las viviendas de California: se predice el precio mediano de la zona a partir de las otras 8 variables. Estandaricen las 8 variables con el entrenamiento, centren el precio restándole su media de entrenamiento y no usen intercepto, de modo que la fórmula de Ridge aplique directamente.

3. Ridge con la fórmula (12 pts). La solución de Ridge es $b = (X^T X + \lambda I)^{-1} X^T y$. Programen esa fórmula con numpy. Para λ igual a 0, 10, 1.000 y 100.000, comparen sus coeficientes con los de scikit-learn y reporten la mayor diferencia en valor absoluto. Grafiquen los 8 coeficientes contra λ, con λ en escala logarítmica, y comenten qué pasa con ellos al crecer λ.

4. Validación cruzada a mano (13 pts). Programen la validación cruzada de 5 grupos sin las funciones de scikit-

learn que la hacen: barajen los índices del entrenamiento con la semilla 396, repártanlos en 5 grupos y, para cada λ de una grilla logarítmica entre 0,01 y 100.000, ajusten con cuatro grupos usando su función y midan el RMSE en el quinto, rotando. Grafiquen el error promedio contra λ, reporten el λ elegido y compárenlo con el de RidgeCV. Expliquen por qué pueden no coincidir y qué indica la forma de la curva sobre la necesidad de regularizar en este caso.

Parte 3. Clasificación con costos (30 puntos)

En esta parte se trabaja con los tumores de Wisconsin. La respuesta vale 1 si el tumor es maligno y 0 si es benigno; estandaricen las 30 variables con el entrenamiento.

5. Dos regresiones logísticas (8 pts). Sea $y_i \in \{0, 1\}$ el diagnóstico del tumor i y $p_i = 1 / (1 + e^{-(a + x_i^\top b)})$ la probabilidad de maligno que le asigna el modelo, con $x_i \in \mathbb{R}^{30}$. La regresión logística sin regularización elige a y b minimizando la pérdida logística

$$L(a, b) = -\Sigma \left[y_i \cdot \log p_i + (1 - y_i) \cdot \log(1 - p_i) \right],$$

que equivale a maximizar la verosimilitud. La regresión logística con la penalización de Ridge minimiza $L(a, b) + \lambda \|b\|^2$, sin penalizar el intercepto: el castigo impide que los coeficientes crezcan sin límite cuando las 30 variables separan perfectamente el entrenamiento. En scikit-learn la fuerza de la penalización se indica con $C = 1/\lambda$, y la logística viene penalizada por defecto.

Ajusten ambos modelos en scikit-learn, no en statsmodels, con las 30 variables estandarizadas; para el segundo, elijan C por validación cruzada de 5 grupos. Reporten el mayor $|b_j|$ y el AUC en entrenamiento y en prueba de cada modelo, e interpreten la diferencia entre ambos AUC en cada caso.

6. Clasificar con umbral 0,5 (6 pts). Cada modelo asigna a cada tumor una probabilidad de ser maligno; clasifiquen como maligno los tumores con probabilidad mayor o igual a 0,5. Para los dos modelos, reporten en prueba la matriz de confusión, la sensibilidad, la especificidad y la exactitud. Indiquen cuál de los dos errores es más grave en este problema.

7. El costo de cada error (10 pts). Dejar pasar un tumor maligno cuesta 20 veces lo que cuesta una falsa alarma. Obtengan el umbral que minimiza el costo esperado y aplíquenlo a los dos modelos: matriz de confusión y costo total, $20 \cdot FN + FP$, contra el del umbral 0,5. Expliquen por qué un modelo responde al cambio de umbral y el otro casi no. Después fijen una meta, detectar al 99% de los malignos, elijan el umbral con el entrenamiento y reporten en prueba la sensibilidad y la especificidad que logra.

8. Curva ROC y AUC (6 pts). Las dos curvas ROC en prueba en una sola figura, con los tres umbrales marcados. ¿Cuál modelo es mejor, y depende del umbral?

Parte 4. Regresión con muchas variables (25 puntos)

En esta parte se vuelve a las viviendas de California, ahora con intercepto y con la respuesta sin centrar: el precio mediano de la zona, en cientos de miles de dólares. Aquí pueden elegir λ con las funciones de scikit-learn.

9. Fabricar variables (5 pts). A partir de las 8 variables estandarizadas, construyan los 8 cuadrados y los 28 productos de pares: 44 variables en total. Vuelvan a estandarizarlas con el entrenamiento y reporten las dimensiones de las tablas.

10. Mínimos cuadrados, Ridge y Lasso (12 pts). Ajusten mínimos cuadrados con 8 y con 44 variables, y Ridge y Lasso con 44, con λ por validación cruzada de 5 grupos. Tabla con el RMSE en entrenamiento y en prueba de los cuatro modelos y del que predice siempre el promedio. Grafiquen, para Ridge y para Lasso, el RMSE de validación cruzada contra λ, marcando el λ elegido. Interpreten qué le pasa a mínimos cuadrados al pasar de 8 a 44 variables y qué hacen Ridge y Lasso con eso.

11. Qué conserva Lasso (8 pts). Grafiquen los coeficientes de Lasso contra λ (los 44, o los más relevantes), con λ en escala logarítmica, marcando el λ elegido. Cuántas de las 44 variables conserva Lasso con ese λ y cuáles son las cinco de mayor coeficiente. Cierre de media página: qué modelo usarían para tasar viviendas y por qué, y si sus coeficientes se pueden leer como efectos o solo sirven para predecir.

Los datos

En `datos/tarea2/` del repositorio, con un `README.md` que describe cada columna.

- `viviendas_california.csv`: 20.640 zonas censales de California, censo de 1990. Pace, R. K. y Barry, R. (1997), *Sparse Spatial Autoregressions*, Statistics and Probability Letters, 33, 291 a 297. Vía scikit-learn.
- `tumores_wisconsin.csv`: 569 tumores de mama con 30 medidas del núcleo celular. Street, W. N., Wolberg, W. H. y Mangasarian, O. L. (1993), *Nuclear feature extraction for breast tumor diagnosis*, IS&T/SPIE. Repositorio UCI, vía scikit-learn.