

¿Cómo se mueve Santiago?

**Clase 2 · Pandas (repaso) y análisis
exploratorio**

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · viernes 21 de agosto, 2026

Qué veremos hoy

- ▶ Le haremos preguntas a la Encuesta Origen Destino de Santiago 2012.
- ▶ Repasaremos Pandas aplicándolo a esas preguntas.
 - Merge y sus variantes, groupby, medidas de resumen.
 - Lo probablemente nuevo: tablas de códigos y factores de expansión.
- ▶ **En el segundo bloque parte la Tarea 1: el retrato de tu comuna.**

¿De quién habla este número?

El concepto de esta clase

Qué preguntarle a una cifra

- ▶ Pandas ya lo conocen; en esta clase es la herramienta de trabajo.
- ▶ El objetivo es examinar qué representa una cifra antes de usarla.
 - Un promedio puede describir una situación en la que pocos están.
 - Contar filas de una encuesta habla de la muestra, no de la ciudad.
 - Hay personas de las que la tabla no dice nada; esa ausencia informa.
- ▶ **Al cierre se retoma esta pregunta con los resultados de la clase.**


Los datos de hoy

Encuesta Origen Destino de Santiago 2012

La EOD 2012

- ▶ Encuesta de movilidad del Gran Santiago (SECTRA y U. Alberto Hurtado).
- ▶ Registra todos los viajes de un día de los hogares encuestados.
 - 18.264 hogares, 60.054 personas, 113.591 viajes.
 - Se usa en la planificación de transporte de la ciudad.
- ▶ **El mismo diseño relacional de la Casen, el Censo o la ENUSC.**

Una encuesta, varias tablas



Los códigos no significan nada sin sus tablas de parámetros: unirlos es parte del análisis.

Repaso de Pandas

Dos casos concretos

Caso 1: códigos que no significan nada solos


```
personas['Sexo'].value_counts()          # 1 y 2: ¿qué son?  
  
sexo = pd.read_csv('tablas_parametros/Sexo.csv', sep=';')  
personas = personas.merge(sexo, left_on='Sexo',  
                           right_on='Id', how='left')  
  
personas['Sexo'].isna().sum()             # después de todo merge:  
contar los NaN
```

Las variantes del merge: qué filas sobreviven

Qué filas sobreviven a cada tipo de merge

how="inner"


izquierda derecha



solo las llaves
que están en ambas

how="left"


izquierda derecha



todas las de la izquierda;
sin pareja quedan NaN

how="right"


izquierda derecha



todas las de la derecha;
sin pareja quedan NaN

how="outer"

izquierda derecha



todas las llaves
de ambas tablas

El valor por defecto es inner: descarta sin aviso las filas sin pareja.

El efecto del parámetro how sobre la población analizada

- ▶ Personas con viajes, merge inner: 113.591 filas (una por viaje).
- ▶ El mismo merge en left: 127.379 filas.
 - La diferencia son 13.788 personas que no viajaron ese día.
 - Con inner desaparecen; con left quedan, con NaN en el viaje.
- ▶ **Un promedio calculado sobre el resultado del inner excluye a quienes no viajaron.**

Caso 2: contar sin perder a los que no aparecen

```
viajes_por_persona = viajes.groupby(['Hogar', 'Persona']).size()

conteo = personas.set_index(['Hogar', 'Persona']).assign(
    n_viajes=viajes_por_persona)['n_viajes'].fillna(0)
```

- El groupby cuenta sobre la tabla de viajes; el fillna(0) trae de vuelta a los ausentes.

Quien no viaja también es dato

- ▶ El 23% de las personas no viajó ese día.
- ▶ Media: 1,9 viajes. Mediana: 2 viajes.
- ▶ Aquí la media quedó bajo la mediana: el bloque de ceros la baja.
- ▶ **La dirección del sesgo depende de la forma de la distribución.**



¿A quién representa la encuesta?

Los factores de expansión

De la muestra a la ciudad

El factor de expansión: de la muestra a la ciudad

37.326 encuestados con factor laboral · la suma de factores estima 6.651.735 personas



Contar filas responde por la muestra; sumar factores responde por la ciudad.

Análisis exploratorio


Examinar los datos antes de modelarlos

Qué es el análisis exploratorio de datos

- ▶ La etapa en que se examinan los datos antes de modelarlos (Tukey, 1977).
- ▶ Responde cuatro tipos de pregunta:
 - La forma: cómo se distribuye cada variable.
 - Lo típico y lo extremo: qué es frecuente y qué es anómalo.
 - Lo que falta: qué datos están ausentes y con qué patrón.
 - Las relaciones: qué variables se asocian con qué otras.
- ▶ **Genera hipótesis; el análisis confirmatorio (unidad 5) las pone a prueba.**


¿Cuánto gana un hogar típico?

- ▶ Media: \$688.274. Mediana: \$507.826.
- ▶ La media es un 36% más alta que la mediana.
- ▶ Los ingresos altos desplazan el promedio; la mayoría gana menos.
- ▶ **El promedio describe una situación en la que la mayoría no está.**



¿Cuánto dura un viaje?

- ▶ Mediana: 30 minutos. Percentil 95: 98 minutos.
- ▶ Máximo registrado: 1.335 minutos, un viaje de 22 horas.
- ▶ ¿Error de digitación? ¿Turno nocturno mal anotado?
- ▶ **Los valores extremos se investigan y la decisión se declara.**




¿En qué se mueve Santiago?


► Dos merges y un groupby ponderado por factor.

- Caminata: 34% de los viajes.
- Transporte público (Bip!): 24%.
- Auto: 23%.

► **La partición modal de un día laboral, calculada desde los microdatos.**



¿Se mueve igual toda la ciudad?




Normalizar por comuna permite comparar proporciones entre comunas de tamaños muy distintos.

¿El ingreso explica el uso de transporte público?

► Cada punto es una comuna: ingreso medio contra proporción de viajes en transporte público.

- Periferia (Buin, Melipilla): poco transporte público; la red no llega.
- Ingresos altos (Vitacura, Lo Barnechea): conectadas, con poco uso.
- Correlación de Pearson: -0,17. La asociación lineal es débil.

► **El coeficiente no reemplaza al gráfico: la estructura está en los grupos.**



Correlación y causalidad

- ▶ Correlación: dos variables varían juntas.
- ▶ Causalidad: intervenir una cambiaría la otra. Es una afirmación más fuerte.
 - Los datos observacionales muestran lo primero, no bastan para lo segundo.
 - Variable de confusión: la cobertura de la red afecta el uso y no es independiente del ingreso.
 - La inferencia causal tiene métodos propios; este curso no los cubre.
- ▶ **Una asociación se reporta como asociación, sin verbos causales que los datos no respaldan.**

¿Cambian las rutinas durante la semana?



El heatmap muestra 14 propósitos por 7 días en una sola figura: útil para tablas completas.

Síntesis: ¿de quién habla este número?

- ▶ 'El hogar promedio gana \$688 mil': la mayoría gana menos; la mediana describe al hogar típico.
- ▶ 'El 53% de los encuestados...': habla de la muestra; los factores de expansión hablan de la ciudad.
- ▶ '1,9 viajes en promedio': solo si contamos a quienes no viajaron; un inner los borra sin aviso.
- ▶ 'En Vitacura casi no se usa transporte público': un promedio comunal esconde la variación interna.
- ▶ **Las operaciones eran repaso; lo nuevo es examinar qué representa cada cifra.**

Segundo bloque: parte la Tarea 1

- ▶ El retrato de tu comuna: cada pareja adopta una comuna del Gran Santiago.
 - Hoy: elegir la comuna y construir su retrato numérico.
 - Próxima clase: el retrato gráfico, con métodos de visualización.
 - Entrega del retrato completo: jueves 10 de septiembre, por Aula.
- ▶ El enunciado está en evaluaciones/tareas/ y la guía de hoy en actividades/.
- ▶ **Lo que hagan en este bloque ya es parte de la tarea.**