

Análisis exploratorio de datos

Clase 2 · Modelos, tipos de datos y Pandas

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · viernes 21 de agosto, 2026

Contenidos de la clase

- ▶ 1. Qué es un modelo.
- ▶ 2. Inferencia y predicción: dos objetivos distintos.
- ▶ 3. Correlación (Pearson y Spearman) y causalidad.
- ▶ 4. Tipos de datos.
- ▶ 5. El análisis exploratorio de datos.
- ▶ 6. Aplicación: la Encuesta Origen Destino de Santiago, con Pandas.
- ▶ **En el segundo bloque comienza la Tarea 1.**

Marco conceptual

Modelos, inferencia y tipos de datos

¿Qué es un modelo?

- ▶ Una representación simplificada del proceso que genera los datos.
- ▶ Formalmente, se postula $Y = f(X) + \varepsilon$:
 - Y es la variable de interés; X , las variables observadas.
 - f es la relación sistemática que se quiere estimar.
 - ε es el error irreducible: lo que X no explica de Y .
- ▶ Ejemplo: el tiempo de un viaje en función de la distancia, el modo y la hora.
- ▶ **Construir un modelo implica decidir qué variables entran, qué se omite y qué se considera éxito (clase 1: esas decisiones incorporan las opiniones de quien modela).**

Inferencia y predicción

- ▶ Al estimar f puede buscarse una de dos cosas (James et al., cap. 2):
- ▶ Inferencia: comprender la relación entre X e Y .
 - Qué variables se asocian con Y , con qué magnitud y signo.
 - La forma de f importa: se prefieren modelos interpretables.
 - Ejemplo: ¿cómo se asocia el nivel socioeconómico con el uso de transporte público?
- ▶ Predicción: estimar Y para casos nuevos.
 - f puede tratarse como caja negra si predice con precisión.
 - Ejemplo: ¿cuántos viajes tendrá esta zona un día laboral?
- ▶ **En el curso: unidades 2 a 5 son descriptivas e inferenciales; unidades 6 a 9, predictivas.**

Correlación: los coeficientes de Pearson y de Spearman

- ▶ La correlación cuantifica cuánto varían conjuntamente dos variables numéricas. Veremos dos coeficientes, ambos entre -1 y 1:
 - Pearson: mide asociación lineal, sobre los valores originales.
 - Spearman: mide asociación monotónica, sobre los rangos; es robusto a valores extremos.
- ▶ En la EOD, distancia y duración del viaje tienen Pearson 0,43 y Spearman 0,72.
 - La relación es claramente creciente (Spearman alto), pero no lineal y con valores extremos (Pearson moderado).
- ▶ **Un coeficiente no reemplaza al gráfico: la estructura de la relación se mira.**

Correlación y causalidad

- ▶ Causalidad: intervenir X cambiaría Y. Es una afirmación más fuerte que la asociación.
 - Una asociación observada admite varias explicaciones: X causa Y, Y causa X, o una variable de confusión Z afecta a ambas.
 - Los datos observacionales, como los de una encuesta, muestran asociación; no bastan para establecer causalidad.
 - La inferencia causal tiene métodos propios; este curso no los cubre.
- ▶ **Regla de trabajo: una asociación se reporta como asociación, sin verbos causales que los datos no respaldan.**

Tipos de datos

- ▶ El tipo de una variable determina qué operaciones tienen sentido:
 - Categórico nominal: categorías sin orden (sexo, comuna, propósito del viaje).
 - Categórico ordinal: categorías con orden (nivel educativo).
 - Numérico discreto: conteos enteros (viajes por persona).
 - Numérico continuo: mediciones (ingreso del hogar, duración del viaje).
- ▶ El dtype computacional no es el tipo estadístico: un sexo codificado 1 o 2 es un int64 para Pandas, pero sigue siendo nominal.
- ▶ **Promediar una variable nominal produce un número sin significado: el promedio de Sexo en la EOD es 1,53.**

El análisis exploratorio de datos

- ▶ La etapa en que se examinan los datos antes de modelarlos (Tukey, 1977).
- ▶ Responde cuatro tipos de pregunta:
 - La forma: cómo se distribuye cada variable.
 - Lo típico y lo extremo: qué es frecuente y qué es anómalo.
 - Lo que falta: qué datos están ausentes y con qué patrón.
 - Las relaciones: qué variables se asocian con qué otras.
- ▶ Genera hipótesis; el análisis confirmatorio (unidad 5) las pone a prueba.
- ▶ **Una pregunta transversal para toda cifra resumen: ¿de quién habla este número? ¿De la muestra, de un subgrupo, de la ciudad?**


Los datos

Encuesta Origen Destino de Santiago 2012

La EOD 2012

- ▶ Encuesta de movilidad del Gran Santiago (SECTRA y U. Alberto Hurtado).
- ▶ Registra todos los viajes de un día de los hogares encuestados.
 - 18.264 hogares, 60.054 personas, 113.591 viajes.
 - Se usa en la planificación de transporte de la ciudad.
- ▶ **El mismo diseño relacional de la Casen, el Censo o la ENUSC.**

Una encuesta, varias tablas



Los códigos no significan nada sin sus tablas de parámetros: unirlos es parte del análisis.

Repaso de Pandas

Dos casos concretos con la EOD

Caso 1: códigos que requieren su tabla de parámetros

```
personas['Sexo'].value_counts()          # 1 y 2: ¿qué son?

sexo = pd.read_csv('tablas_parametros/Sexo.csv', sep=';')
personas = personas.merge(sexo, left_on='Sexo',
                           right_on='Id', how='left')


personas['Sexo'].isna().sum()             # después de todo merge:
contar los NaN
```

Las variantes del merge: qué filas se conservan

Qué filas sobreviven a cada tipo de merge

how="inner"


izquierda derecha



solo las llaves
que están en ambas

how="left"


izquierda derecha



todas las de la izquierda;
sin pareja quedan NaN

how="right"


izquierda derecha



todas las de la derecha;
sin pareja quedan NaN

how="outer"

izquierda derecha



todas las llaves
de ambas tablas

El valor por defecto es inner: descarta sin aviso las filas sin pareja.

El efecto del parámetro how sobre la población analizada

- ▶ Personas con viajes, merge inner: 113.591 filas (una por viaje).
- ▶ El mismo merge en left: 127.379 filas.
 - La diferencia son 13.788 personas que no viajaron ese día.
 - Con inner desaparecen; con left quedan, con NaN en el viaje.
- ▶ **Un promedio calculado sobre el resultado del inner excluye a quienes no viajaron.**

Caso 2: contar sin perder a los que no aparecen

```
viajes_por_persona = viajes.groupby(['Hogar', 'Persona']).size()

conteo = personas.set_index(['Hogar', 'Persona']).assign(
    n_viajes=viajes_por_persona)['n_viajes'].fillna(0)
```

- El groupby cuenta sobre la tabla de viajes; el fillna(0) reincorpora a los ausentes.

Exploración de la EOD

Estadística descriptiva sobre datos reales

Viajes por persona: los ausentes también cuentan

- ▶ El 23% de las personas no viajó ese día.
- ▶ Media: 1,9 viajes. Mediana: 2 viajes.
- ▶ La media quedó bajo la mediana: la masa de ceros la desplaza.
- ▶ **La dirección del sesgo depende de la forma de la distribución.**



Los factores de expansión: de la muestra a la ciudad

El factor de expansión: de la muestra a la ciudad


37.326 encuestados con factor laboral · la suma de factores estima 6.651.735 personas



Contar filas responde por la muestra; sumar factores responde por la ciudad.


El ingreso de los hogares: media y mediana

- ▶ Media: \$688.274. Mediana: \$507.826.
- ▶ La media es un 36% más alta que la mediana.
- ▶ Los ingresos altos desplazan el promedio; la mayoría gana menos.
- ▶ **El promedio describe una situación en la que la mayoría no está.**



La duración de los viajes: valores extremos

- ▶ Mediana: 30 minutos. Percentil 95: 98 minutos.
- ▶ Máximo registrado: 1.335 minutos, un viaje de 22 horas.
- ▶ ¿Error de digitación? ¿Turno nocturno mal anotado?
- ▶ **Los valores extremos se investigan y la decisión se declara.**




La partición modal del Gran Santiago


► Dos merges y un groupby ponderado por factor.

- Caminata: 34% de los viajes.
- Transporte público (Bip!): 24%.
- Auto: 23%.

► **Calculada desde los microdatos, con los factores de un día laboral.**



El reparto modal difiere entre comunas




Normalizar por comuna permite comparar proporciones entre comunas de tamaños muy distintos.

Ingreso y uso de transporte público


► Cada punto es una comuna: ingreso medio contra proporción de viajes en transporte público.

- Periferia (Buin, Melipilla): poco transporte público; la red no llega.
- Ingresos altos (Vitacura, Lo Barnechea): conectadas, con poco uso.
- Correlación de Pearson: -0,17. La asociación lineal es débil.

► **Como vimos en el marco conceptual: el coeficiente no reemplaza al gráfico, y la asociación no autoriza verbos causales.**



Los propósitos de viaje según el día de la semana



El heatmap muestra 14 propósitos por 7 días en una sola figura: útil para tablas completas.

Síntesis

- ▶ Un modelo es una simplificación con decisiones incorporadas; estimarlo puede buscar inferencia o predicción.
- ▶ Las asociaciones se reportan como asociaciones: la causalidad exige más que datos observacionales.
- ▶ El tipo de la variable, no su dtype, determina qué resúmenes tienen sentido.
- ▶ Con distribuciones asimétricas, la mediana y los percentiles describen mejor lo típico que la media.
- ▶ **Ante toda cifra resumen: ¿de quién habla este número? ¿Muestra, subgrupo o ciudad?**

Segundo bloque: comienza la Tarea 1

- ▶ El retrato de tu comuna: cada pareja adopta una comuna del Gran Santiago.
 - Hoy: elegir la comuna y construir su retrato numérico.
 - Próxima clase: el retrato gráfico, con métodos de visualización.
 - Entrega del retrato completo: jueves 10 de septiembre, por Aula.
- ▶ El enunciado está en evaluaciones/tareas/ y la guía de hoy en actividades/.
- ▶ **Lo que avancen en este bloque ya es parte de la tarea.**