

# Análisis exploratorio de datos

## Clase 2 · Modelos, tipos de datos y Pandas

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · viernes 21 de agosto, 2026

# Contenidos de la clase

- ▶ 1. Qué es un modelo.
- ▶ 2. Inferencia y predicción: dos objetivos distintos.
- ▶ 3. Correlación (Pearson y Spearman) y causalidad.
- ▶ 4. Tipos de datos.
- ▶ 5. El análisis exploratorio de datos.
- ▶ 6. Aplicación: la Encuesta Origen Destino de Santiago, con Pandas.
- ▶ **El concepto de la clase es el EDA: examinar los datos antes de modelarlos. Los puntos 1 a 4 son sus definiciones de base; el punto 6 lo aplica a la EOD.**

# Marco conceptual

Modelos, inferencia y tipos de datos

# ¿Qué es un modelo?

- ▶ Una representación simplificada del proceso que genera los datos (James et al., 2023, cap. 2).
- ▶ Formalmente, se postula  $Y = f(X) + \varepsilon$ :
  - $Y$  es la variable de interés;  $X$ , las variables observadas.
  - $f$  es la relación sistemática que se quiere estimar.
  - $\varepsilon$  es el error irreducible: lo que  $X$  no explica de  $Y$ .
- ▶ Ejemplo: el tiempo de un viaje en función de la distancia, el modo y la hora.
- ▶ **Construir un modelo implica decidir qué variables entran, qué se omite y qué se considera éxito (clase 1: esas decisiones incorporan las opiniones de quien modela).**

# Inferencia y predicción

- ▶ Al estimar  $f$  puede buscarse una de dos cosas (James et al., cap. 2):
- ▶ Inferencia: comprender la relación entre  $X$  e  $Y$ .
  - Qué variables se asocian con  $Y$ , con qué magnitud y signo.
  - La forma de  $f$  importa: se prefieren modelos interpretables.
  - Ejemplo: ¿cómo se asocia el nivel socioeconómico con el uso de transporte público?
- ▶ Predicción: estimar  $Y$  para casos nuevos.
  - $f$  puede tratarse como caja negra si predice con precisión.
  - Ejemplo: ¿cuántos viajes tendrá esta zona un día laboral?
- ▶ **En el curso: unidades 2 a 5 son descriptivas e inferenciales; unidades 6 a 9, predictivas.**

# El coeficiente de correlación de Pearson

► Mide la asociación lineal entre dos variables numéricas: qué tan bien se ajustan los puntos a una recta. Se denota  $r$  (Bruce, Bruce y Gedeck, 2020).


► En la fórmula:  $x_i$  e  $y_i$  son los valores del par  $i$ ;  $\bar{x}$  e  $\bar{y}$ , sus medias;  $n$ , el número de pares.

- $r = 1$ : recta creciente exacta;  $r = -1$ : decreciente exacta.

- $r = 0$ : sin asociación lineal (puede existir asociación de otra forma).

► **Su cuadrado anticipa el  $R^2$  de la regresión (unidad 7).**

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$



# Antes de Spearman: cómo se calculan los rangos

Cinco viajes de la EOD: rango = posición al ordenar cada variable

| Distancia (km) | Duración (min) | Rango dist. | Rango dur. | d  | d <sup>2</sup> |
|----------------|----------------|-------------|------------|----|----------------|
| 0.2            | 20             | 1           | 2          | -1 | 1              |
| 0.5            | 5              | 2           | 1          | 1  | 1              |
| 5.0            | 60             | 3           | 3          | 0  | 0              |
| 8.7            | 75             | 4           | 4          | 0  | 0              |
| 17.8           | 90             | 5           | 5          | 0  | 0              |

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} = 1 - \frac{6 \cdot 2}{5(25 - 1)} = 0.90$$

Cada variable se ordena por separado y cada valor recibe su posición; d compara las posiciones de un mismo viaje.

# El coeficiente de Spearman


► El mismo Pearson, calculado sobre los rangos: la posición de cada valor al ordenar (1 = el menor). Se denota  $\rho$  (rho).

► En la fórmula:  $d_i$  es la diferencia entre los rangos del caso  $i$  en ambas variables;  $n$ , el número de pares. Vale sin empates.

○ Los valores 5, 12, 8 y 200 tienen rangos 1, 3, 2 y 4: la magnitud desaparece, queda el orden.


► **Mide asociación monotónica: robusto a extremos, invariante ante transformaciones monótonas, válido para ordinales.**

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$





# La correlación, vista en los datos completos



La mediana por tramo sube de forma sostenida (Spearman 0,76) pero no recta y con extremos (Pearson 0,43).

# Cuando la relación no es lineal, el coeficiente puede ocultarla


► Los viajes por persona según la edad: suben hasta los 30 a 40 años y luego bajan.

► La asociación es clara, pero  $r = 0,04$  y  $p = 0,05$ .

- La relación no es monótona: el tramo que sube y el que baja se cancelan.


- Ni Pearson ni Spearman están diseñados para esta forma.

► **Un coeficiente cercano a cero no demuestra ausencia de asociación: el gráfico sí la muestra.**



# ¿Cuándo usar cada coeficiente?


- ▶ Pearson: relación aproximadamente recta, sin extremos dominantes; antesala del modelo lineal.
- ▶ Spearman: asimetrías, extremos, curvas crecientes, o variables ordinales.
  - La brecha entre ambos es un diagnóstico: 0,43 contra 0,76 indica curva o extremos.
  - Tras el logaritmo, Pearson llega a 0,73, casi igual a Spearman.
- ▶ **Calcule ambos; si difieren mucho, mire el gráfico antes de reportar.**



# Correlación y causalidad

- ▶ Causalidad: intervenir X cambiaría Y. Es una afirmación más fuerte que la asociación.
  - Una asociación observada admite varias explicaciones: X causa Y, Y causa X, o una variable de confusión Z afecta a ambas.
  - Los datos observacionales, como los de una encuesta, muestran asociación; no bastan para establecer causalidad.
  - La inferencia causal tiene métodos propios; este curso no los cubre.
- ▶ **Regla de trabajo: una asociación se reporta como asociación, sin verbos causales que los datos no respaldan.**

# Tipos de datos



El tipo de la variable determina qué operaciones tienen sentido (Bruce, Bruce y Gedeck, 2020, cap. 1).

# El tipo estadístico no es el tipo computacional

- ▶ En la EOD el sexo viene codificado 1 o 2: para Pandas es un entero (int64).
- ▶ El tipo computacional permite operar; el tipo estadístico decide si la operación significa algo.
  - El promedio de Sexo en la EOD es 1,53: aritméticamente correcto, sin significado.
  - El promedio de Edad sí es interpretable: la variable es numérica.
- ▶ **Identificar el tipo de cada variable es un paso del análisis, no una formalidad.**

# El análisis exploratorio de datos (EDA)

- ▶ La etapa en que se examinan los datos antes de modelarlos (EDA, por exploratory data analysis; Tukey, 1977).
- ▶ Responde cuatro tipos de pregunta:
  - La forma: cómo se distribuye cada variable.
  - Lo típico y lo extremo: qué es frecuente y qué es anómalo.
  - Lo que falta: qué datos están ausentes y con qué patrón.
  - Las relaciones: qué variables se asocian con qué otras.
- ▶ Genera hipótesis; el análisis confirmatorio (unidad 5) las pone a prueba.
- ▶ **Una pregunta transversal para toda cifra resumen: ¿de quién habla este número? ¿De la muestra, de un subgrupo, de la ciudad?**

# Los datos


Encuesta Origen Destino de Santiago 2012



# La EOD 2012

- ▶ Encuesta de movilidad del Gran Santiago (SECTRA y U. Alberto Hurtado).
- ▶ Registra todos los viajes de un día de los hogares encuestados.
  - 18.264 hogares, 60.054 personas, 113.591 viajes.
  - Se usa en la planificación de transporte de la ciudad.
- ▶ **El mismo diseño relacional de la Casen, el Censo o la ENUSC.**

# Una encuesta, varias tablas



Llaves: Hogar · Hogar + Persona · Hogar + Persona + Viaje. Los códigos se resuelven contra tablas\_parametros/.

# Repaso de Pandas

Dos casos concretos con la EOD

# El DataFrame: la estructura central de Pandas

**viajes.csv cargado como DataFrame: filas indexadas, columnas con nombre y tipo**

|   | Hogar  | Persona  | Viaje      | ComunaOrigen | Proposito | TiempoViaje |
|---|--------|----------|------------|--------------|-----------|-------------|
| 0 | 173431 | 17343102 | 1734310202 | 94           | 7         | 70          |
| 1 | 173441 | 17344101 | 1734410101 | 94           | 1         | 105         |
| 2 | 173441 | 17344101 | 1734410102 | 71           | 7         | 90          |
| 3 | 173441 | 17344103 | 1734410301 | 94           | 1         | 55          |
| 4 | 173441 | 17344103 | 1734410302 | 91           | 7         | 150         |
| 5 | 173451 | 17345101 | 1734510101 | 94           | 6         | 60          |
| 6 | 173451 | 17345101 | 1734510102 | 70           | 7         | 45          |
| 7 | 173451 | 17345101 | 1734510103 | 94           | 7         | 20          |

Los códigos (ComunaOrigen, Proposito) se resuelven contra tablas\_parametros/ con merge.

# El DataFrame: origen y propiedades

- ▶ Estructura tabular bidimensional: columnas con nombre y tipo propio, filas indexadas.
- ▶ El concepto viene del lenguaje S: los objetos `data.frame` (Chambers y Hastie, 1992). Wes McKinney lo llevó a Python con `pandas` (McKinney, 2010).
  - Cada columna es un arreglo tipado y contiguo en memoria.
  - Por eso las operaciones se ejecutan en código compilado sobre la columna completa, en vez de interpretar un ciclo elemento por elemento: sumar `TiempoViaje` toma 0,08 ms contra 7 ms del ciclo equivalente.
  - El índice alinea los datos automáticamente en operaciones entre tablas y series.
  - Implementa el álgebra relacional en memoria: selección, proyección, join (merge) y agregación (`groupby`).

# Abrir el dataset

```
import pandas as pd

viajes = pd.read_csv('datos/eod_stgo/viajes.csv',
                     sep=';', decimal=',')
```


- Todo el código de la clase está en el notebook 02\_pandas\_eda.ipynb del repositorio.

# Las variantes del merge: qué filas se conservan

## Qué filas sobreviven a cada tipo de merge

**how="inner"**


izquierda derecha



solo las llaves  
que están en ambas

**how="left"**


izquierda derecha



todas las de la izquierda;  
sin pareja quedan NaN

**how="right"**


izquierda derecha



todas las de la derecha;  
sin pareja quedan NaN

**how="outer"**

izquierda derecha



todas las llaves  
de ambas tablas

El valor por defecto es inner: descarta sin aviso las filas sin pareja.

# El efecto del parámetro how sobre la población analizada

- ▶ Personas con viajes, merge inner: 113.591 filas (una por viaje).
- ▶ El mismo merge en left: 127.379 filas.
  - La diferencia son 13.788 personas que no viajaron ese día.
  - Con inner desaparecen; con left quedan, con NaN en el viaje.
- ▶ **Un promedio calculado sobre el resultado del inner excluye a quienes no viajaron.**




# Exploración de la EOD

EDA sobre la EOD: estadística descriptiva ponderada

# Los factores de expansión: de la muestra a la ciudad

## El factor de expansión: de la muestra a la ciudad


37.326 encuestados con factor laboral · la suma de factores estima 6.651.735 personas



Contar filas responde por la muestra; sumar factores responde por la ciudad.


# El factor de expansión, formalmente

- ▶ Cada persona  $i$  tiene una probabilidad  $\pi_i$  de ser incluida en la muestra (según su zona, su hogar y el día asignado).
- ▶ Su factor es el inverso:  $w_i = 1/\pi_i$ , las personas de la población que representa (Horvitz y Thompson, 1952).
  - El total poblacional se estima sumando factores; las medias, ponderando por ellos.
  - Se usa el factor de la unidad analizada: hogar (Factor), persona (Factor\_LaboralNormal), viaje (FactorLaboralNormal); dos nombres difieren solo en un guion bajo.
- ▶ **Dos pasos, en orden: definir la población (¿día laboral?) y ponderar dentro de ella. La**




# Viajes por persona: los ausentes también cuentan

- ▶ Quien no viajó no está en la tabla de viajes: hay que reincorporarlo antes de calcular.
- ▶ Ponderado: el 15% de las personas no viajó; media de 2,2 viajes, mediana de 2.
- ▶ El 59% de la población hace exactamente 2 viajes: la ida y la vuelta.
- ▶ **La cifra ingenua decía 23%: mezclaba días de fin de semana y omitía los factores.**




# El ingreso de los hogares: media y mediana

- ▶ Ponderado por el factor del hogar: media \$729.898, mediana \$520.000.
- ▶ La media es un 40% más alta que la mediana.
- ▶ Los ingresos altos desplazan el promedio; la mayoría gana menos.
- ▶ **El promedio describe una situación en la que la mayoría no está.**



# La duración de los viajes: valores extremos

- ▶ Ponderado por el factor del viaje:  
mediana de 25 minutos, percentil 95 de 90.
- ▶ Máximo registrado: 1.335 minutos, un viaje de 22 horas.
- ▶ ¿Error de digitación? ¿Turno nocturno mal anotado?
- ▶ **Los valores extremos se investigan y la decisión se declara.**




# La partición modal del Gran Santiago


► Dos merges y un groupby ponderado por factor.

- Caminata: 34% de los viajes.
- Transporte público (Bip!): 24%.
- Auto: 23%.

► **Calculada desde los microdatos, con los factores de un día laboral.**



# El reparto modal difiere entre comunas



Normalizar por comuna permite comparar proporciones entre comunas de tamaños muy distintos.




# Ingreso y uso de transporte público

► Cada punto es una comuna: ingreso medio contra proporción de viajes en transporte público.

- Periferia (Buin, Melipilla): poco transporte público; la red no llega.
- Ingresos altos (Vitacura, Lo Barnechea): conectadas, con poco uso.
- Correlación de Pearson: -0,17. La asociación lineal es débil.

► **Como vimos en el marco conceptual: el coeficiente no reemplaza al gráfico, y la asociación no autoriza verbos causales.**



# Los propósitos de viaje según el día de la semana



El heatmap muestra 14 propósitos por 7 días en una sola figura: útil para tablas completas.

# Cuando los datos crecen

El concepto de DataFrame se conserva; la herramienta cambia con el tamaño



PySpark se usa con SQL o con sus propios DataFrames; Dask reparte operaciones estilo Pandas; Polars y DuckDB rinden en una sola máquina.

# Síntesis

- ▶ Un modelo es una simplificación con decisiones incorporadas; estimarlo puede buscar inferencia o predicción.
- ▶ Las asociaciones se reportan como asociaciones: la causalidad exige más que datos observacionales.
- ▶ El tipo de la variable, no su dtype, determina qué resúmenes tienen sentido.
- ▶ Con distribuciones asimétricas, la mediana y los percentiles describen mejor lo típico que la media.
- ▶ En una encuesta, primero se define la población y luego se pondera por los factores: la cifra ingenua del 23% sin viajes era en realidad un 15%

# Segundo bloque: comienza la Tarea 1

- ▶ El retrato de tu comuna: cada pareja adopta una comuna del Gran Santiago.
  - Hoy: elegir la comuna y construir su retrato numérico.
  - Próxima clase: el retrato gráfico, con métodos de visualización.
  - Entrega del retrato completo: jueves 10 de septiembre, por Aula.
- ▶ El enunciado está en evaluaciones/tareas/ y la guía de hoy en actividades/.
- ▶ **Lo que avancen en este bloque ya es parte de la tarea.**

# Referencias

- ▶ James, G., Witten, D., Hastie, T. y Tibshirani, R. (2023). An Introduction to Statistical Learning with Applications in Python. Springer. Capítulo 2. Descarga gratuita en [statlearning.com](https://statlearning.com).
- ▶ Bruce, P., Bruce, A. y Gedeck, P. (2020). Practical Statistics for Data Scientists, 2ª ed. O'Reilly. Capítulo 1.
- ▶ Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.
- ▶ Horvitz, D. G. y Thompson, D. J. (1952). A Generalization of Sampling Without Replacement from a Finite Universe. JASA 47(260).
- ▶ Chambers, J. M. y Hastie, T. J. (1992). Statistical Models in S. Wadsworth & Brooks/Cole.