

Análisis exploratorio de datos

Clase 2 · Modelos, tipos de datos y Pandas

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · viernes 21 de agosto, 2026

Contenidos de la clase

- ▶ 1. Qué es un modelo.
- ▶ 2. Inferencia y predicción: dos objetivos distintos.
- ▶ 3. Correlación (Pearson y Spearman) y causalidad.
- ▶ 4. Tipos de datos.
- ▶ 5. El análisis exploratorio de datos.
- ▶ 6. Aplicación: la Encuesta Origen Destino de Santiago, con Pandas.
- ▶ **El concepto de la clase es el EDA: examinar los datos antes de modelarlos. Los puntos 1 a 4 son sus definiciones de base; el punto 6 lo aplica a la EOD.**

Marco conceptual

Modelos, inferencia y tipos de datos

¿Qué es un modelo?

- ▶ Una representación simplificada del proceso que genera los datos (James et al., 2023, cap. 2).
- ▶ Formalmente, se postula $Y = f(X) + \varepsilon$:
 - Y es la variable de interés; X , las variables observadas.
 - f es la relación sistemática que se quiere estimar.
 - ε es el error irreducible: lo que X no explica de Y .
- ▶ Ejemplo: el tiempo de un viaje en función de la distancia, el modo y la hora.
- ▶ **Construir un modelo implica decidir qué variables entran, qué se omite y qué se considera éxito (clase 1: esas decisiones incorporan las opiniones de quien modela).**

Inferencia y predicción

- ▶ Al estimar f puede buscarse una de dos cosas (James et al., cap. 2):
- ▶ Inferencia: comprender la relación entre X e Y .
 - Qué variables se asocian con Y , con qué magnitud y signo.
 - La forma de f importa: se prefieren modelos interpretables.
 - Ejemplo: ¿cómo se asocia el nivel socioeconómico con el uso de transporte público?
- ▶ Predicción: estimar Y para casos nuevos.
 - f puede tratarse como caja negra si predice con precisión.
 - Ejemplo: ¿cuántos viajes tendrá esta zona un día laboral?
- ▶ **En el curso: unidades 2 a 5 son descriptivas e inferenciales; unidades 6 a 9, predictivas.**

El coeficiente de correlación de Pearson

► Mide la asociación lineal entre dos variables numéricas: qué tan bien se ajustan los puntos a una recta. Se denota r (Bruce, Bruce y Gedeck, 2020).


► En la fórmula: x_i e y_i son los valores del par i ; $\bar{x}$ e $\bar{y}$, sus medias; n , el número de pares.

- $r = 1$: recta creciente exacta; $r = -1$: decreciente exacta.

- $r = 0$: sin asociación lineal (puede existir asociación de otra forma).

► **Su cuadrado anticipa el R^2 de la regresión (unidad 7).**

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$



Antes de Spearman: cómo se calculan los rangos

Cinco viajes de la EOD: rango = posición al ordenar cada variable

Distancia (km)	Duración (min)	Rango dist.	Rango dur.	d	d ²
0.2	20	1	2	-1	1
0.5	5	2	1	1	1
5.0	60	3	3	0	0
8.7	75	4	4	0	0
17.8	90	5	5	0	0

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} = 1 - \frac{6 \cdot 2}{5(25 - 1)} = 0.90$$

Cada variable se ordena por separado y cada valor recibe su posición; d compara las posiciones de un mismo viaje.

El coeficiente de Spearman


► El mismo Pearson, calculado sobre los rangos: la posición de cada valor al ordenar (1 = el menor). Se denota ρ (rho).

► En la fórmula: d_i es la diferencia entre los rangos del caso i en ambas variables; n , el número de pares. Vale sin empates.


○ Los valores 5, 12, 8 y 200 tienen rangos 1, 3, 2 y 4: la magnitud desaparece, queda el orden.

► **Mide asociación monotónica: robusto a extremos, invariante ante transformaciones monótonas, válido para ordinales.**

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$



La correlación, vista en los datos completos



La mediana por tramo sube de forma sostenida (Spearman 0,76) pero no recta y con extremos (Pearson 0,43).

Cuando la relación no es lineal, el coeficiente puede ocultarla


► Los viajes por persona según la edad: suben hasta los 30 a 40 años y luego bajan.

► La asociación es clara, pero $r = 0,04$ y $p = 0,05$.

- La relación no es monótona: el tramo que sube y el que baja se cancelan.


- Ni Pearson ni Spearman están diseñados para esta forma.

► **Un coeficiente cercano a cero no demuestra ausencia de asociación: el gráfico sí la muestra.**



¿Cuándo usar cada coeficiente?


- ▶ Pearson: relación aproximadamente recta, sin extremos dominantes; antesala del modelo lineal.
- ▶ Spearman: asimetrías, extremos, curvas crecientes, o variables ordinales.
 - La brecha entre ambos es un diagnóstico: 0,43 contra 0,76 indica curva o extremos.
 - Tras el logaritmo, Pearson llega a 0,73, casi igual a Spearman.
- ▶ **Calcule ambos; si difieren mucho, mire el gráfico antes de reportar.**



Correlación y causalidad

- ▶ Causalidad: intervenir X cambiaría Y. Es una afirmación más fuerte que la asociación.
 - Una asociación observada admite varias explicaciones: X causa Y, Y causa X, o una variable de confusión Z afecta a ambas.
 - Los datos observacionales, como los de una encuesta, muestran asociación; no bastan para establecer causalidad.
 - La inferencia causal tiene métodos propios; este curso no los cubre.
- ▶ **Regla de trabajo: una asociación se reporta como asociación, sin verbos causales que los datos no respaldan.**

Tipos de datos



El tipo de la variable determina qué operaciones tienen sentido (Bruce, Bruce y Gedeck, 2020, cap. 1).

El tipo estadístico no es el tipo computacional

- ▶ En la EOD el sexo viene codificado 1 o 2: para Pandas es un entero (int64).
- ▶ El tipo computacional permite operar; el tipo estadístico decide si la operación significa algo.
 - El promedio de Sexo en la EOD es 1,53: aritméticamente correcto, sin significado.
 - El promedio de Edad sí es interpretable: la variable es numérica.
- ▶ **Identificar el tipo de cada variable es un paso del análisis, no una formalidad.**

El análisis exploratorio de datos (EDA)

- ▶ La etapa en que se examinan los datos antes de modelarlos (EDA, por exploratory data analysis; Tukey, 1977).
- ▶ Responde cuatro tipos de pregunta:
 - La forma: cómo se distribuye cada variable.
 - Lo típico y lo extremo: qué es frecuente y qué es anómalo.
 - Lo que falta: qué datos están ausentes y con qué patrón.
 - Las relaciones: qué variables se asocian con qué otras.
- ▶ Genera hipótesis; el análisis confirmatorio (unidad 5) las pone a prueba.
- ▶ **Una pregunta transversal para toda cifra resumen: ¿de quién habla este número? ¿De la muestra, de un subgrupo, de la ciudad?**


Los datos

Encuesta Origen Destino de Santiago 2012

La EOD 2012

- ▶ Encuesta de movilidad del Gran Santiago (SECTRA y U. Alberto Hurtado).
- ▶ Registra todos los viajes de un día de los hogares encuestados.
 - 18.264 hogares, 60.054 personas, 113.591 viajes.
 - Se usa en la planificación de transporte de la ciudad.
- ▶ **El mismo diseño relacional de la Casen, el Censo o la ENUSC.**

Una encuesta, varias tablas



Llaves: Hogar · Hogar + Persona · Hogar + Persona + Viaje. Los códigos se resuelven contra tablas_parametros/.

Repaso de Pandas

Dos casos concretos con la EOD

El DataFrame: la estructura central de Pandas

viajes.csv cargado como DataFrame: filas indexadas, columnas con nombre y tipo

	Hogar	Persona	Viaje	ComunaOrigen	Proposito	TiempoViaje
0	173431	17343102	1734310202	94	7	70
1	173441	17344101	1734410101	94	1	105
2	173441	17344101	1734410102	71	7	90
3	173441	17344103	1734410301	94	1	55
4	173441	17344103	1734410302	91	7	150
5	173451	17345101	1734510101	94	6	60
6	173451	17345101	1734510102	70	7	45
7	173451	17345101	1734510103	94	7	20

Los códigos (ComunaOrigen, Proposito) se resuelven contra tablas_parametros/ con merge.

El DataFrame: origen y propiedades

- ▶ Estructura tabular bidimensional: columnas con nombre y tipo propio, filas indexadas.
- ▶ El concepto viene del lenguaje S: los objetos `data.frame` (Chambers y Hastie, 1992). Wes McKinney lo llevó a Python con `pandas` (McKinney, 2010).
 - Cada columna es un arreglo tipado y contiguo en memoria.
 - Por eso las operaciones se ejecutan en código compilado sobre la columna completa, en vez de interpretar un ciclo elemento por elemento: sumar `TiempoViaje` toma 0,08 ms contra 7 ms del ciclo equivalente.
 - El índice alinea los datos automáticamente en operaciones entre tablas y series.
 - Implementa el álgebra relacional en memoria: selección, proyección, join (merge) y agregación (`groupby`).


Abrir el dataset

```
import pandas as pd

viajes = pd.read_csv('datos/eod_stgo/viajes.csv',
                     sep=';', decimal=',')
```

- Todo el código de la clase está en el notebook 02_pandas_eda.ipynb del repositorio.

Las variantes del merge: qué filas se conservan



El valor por defecto es inner: descarta sin aviso las filas sin pareja.

El efecto del parámetro how sobre la población analizada

- ▶ Personas con viajes, merge inner: 113.591 filas (una por viaje).
- ▶ El mismo merge en left: 127.379 filas.
 - La diferencia son 13.788 personas que no viajaron ese día.
 - Con inner desaparecen; con left quedan, con NaN en el viaje.
- ▶ **Un promedio calculado sobre el resultado del inner excluye a quienes no viajaron.**

Exploración de la EOD

EDA sobre la EOD: estadística descriptiva ponderada

Los factores de expansión: de la muestra a la ciudad

El factor de expansión: de la muestra a la ciudad


37.326 encuestados con factor laboral · la suma de factores estima 6.651.735 personas



Contar filas responde por la muestra; sumar factores responde por la ciudad.


El factor de expansión, formalmente

- ▶ Cada persona i tiene una probabilidad π_i de ser incluida en la muestra (según su zona, su hogar y el día asignado).
- ▶ Su factor es el inverso: $w_i = 1/\pi_i$, las personas de la población que representa (Horvitz y Thompson, 1952).
 - El total poblacional se estima sumando factores; las medias, ponderando por ellos.
 - Se usa el factor de la unidad analizada: hogar (Factor), persona (Factor_LaboralNormal), viaje (FactorLaboralNormal); dos nombres difieren solo en un guion bajo.
- ▶ **Dos pasos, en orden: definir la población (¿día laboral?) y ponderar dentro de ella. La**




Viajes por persona: los ausentes también cuentan

- ▶ Quien no viajó no está en la tabla de viajes: hay que reincorporarlo antes de calcular.
- ▶ Ponderado: el 15% de las personas no viajó; media de 2,2 viajes, mediana de 2.
- ▶ El 59% de la población hace exactamente 2 viajes: la ida y la vuelta.
- ▶ **La cifra ingenua decía 23%: mezclaba días de fin de semana y omitía los factores.**




El ingreso de los hogares: media y mediana

- ▶ Ponderado por el factor del hogar: media \$729.898, mediana \$520.000.
- ▶ La media es un 40% más alta que la mediana.
- ▶ Los ingresos altos desplazan el promedio; la mayoría gana menos.
- ▶ **El promedio describe una situación en la que la mayoría no está.**



La duración de los viajes: valores extremos

- ▶ Ponderado por el factor del viaje:
mediana de 25 minutos, percentil 95 de 90.
- ▶ Máximo registrado: 1.335 minutos, un viaje de 22 horas.
- ▶ ¿Error de digitación? ¿Turno nocturno mal anotado?
- ▶ **Los valores extremos se investigan y la decisión se declara.**




La partición modal del Gran Santiago


► Dos merges y un groupby ponderado por factor.

- Caminata: 34% de los viajes.
- Transporte público (Bip!): 24%.
- Auto: 23%.

► **Calculada desde los microdatos, con los factores de un día laboral.**



El reparto modal difiere entre comunas



Normalizar por comuna permite comparar proporciones entre comunas de tamaños muy distintos.

Los propósitos de viaje según el día de la semana



El heatmap muestra 14 propósitos por 7 días en una sola figura: útil para tablas completas.

Cuando los datos crecen

El concepto de DataFrame se conserva; la herramienta cambia con el tamaño



PySpark se usa con SQL o con sus propios DataFrames; Dask reparte operaciones estilo Pandas; Polars y DuckDB rinden en una sola máquina.

Síntesis

- ▶ Un modelo es una simplificación con decisiones incorporadas; estimarlo puede buscar inferencia o predicción.
- ▶ Las asociaciones se reportan como asociaciones: la causalidad exige más que datos observacionales.
- ▶ El tipo de la variable, no su dtype, determina qué resúmenes tienen sentido.
- ▶ Con distribuciones asimétricas, la mediana y los percentiles describen mejor lo típico que la media.
- ▶ En una encuesta, primero se define la población y luego se pondera por los factores: la cifra ingenua del 23% sin viajes era en realidad un 15%

Segundo bloque: comienza la Tarea 1

- ▶ El retrato de tu comuna: cada pareja adopta una comuna del Gran Santiago.
 - Hoy: elegir la comuna y construir su retrato numérico.
 - Próxima clase: el retrato gráfico, con métodos de visualización.
 - Entrega del retrato completo: jueves 10 de septiembre, por Aula.
- ▶ El enunciado está en evaluaciones/tareas/ y la guía de hoy en actividades/.
- ▶ **Lo que avancen en este bloque ya es parte de la tarea.**

Referencias

- ▶ James, G., Witten, D., Hastie, T. y Tibshirani, R. (2023). An Introduction to Statistical Learning with Applications in Python. Springer. Capítulo 2. Descarga gratuita en statlearning.com.
- ▶ Bruce, P., Bruce, A. y Gedeck, P. (2020). Practical Statistics for Data Scientists, 2ª ed. O'Reilly. Capítulo 1.
- ▶ Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.
- ▶ Horvitz, D. G. y Thompson, D. J. (1952). A Generalization of Sampling Without Replacement from a Finite Universe. JASA 47(260).
- ▶ Chambers, J. M. y Hastie, T. J. (1992). Statistical Models in S. Wadsworth & Brooks/Cole.