

¿Cómo se mueve Santiago?

**Clase 2 · Pandas (repaso) y análisis
exploratorio**

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · viernes 21 de agosto, 2026

Qué veremos hoy

- ▶ Le haremos preguntas reales a la Encuesta Origen Destino de Santiago.
- ▶ Cada pregunta trae su herramienta: el repaso de Pandas va en el camino.
 - Cargar y mirar, derivar columnas, filtrar, merge, groupby.
 - Lo probablemente nuevo: tablas de códigos y factores de expansión.
- ▶ Inicio del análisis exploratorio: qué número resume bien una respuesta.
- ▶ **En el segundo bloque parte la Tarea 1: el retrato de tu comuna.**

¿De quién habla este número?

El concepto que nos llevamos hoy

La pregunta que ordena toda la clase

- ▶ Pandas ya lo conocen: hoy no es el aprendizaje, es la herramienta.
- ▶ Lo que se llevan es un hábito: interrogar cada cifra antes de creerle.
 - Un promedio puede describir una situación en la que casi nadie está.
 - Contar filas de una encuesta habla de la muestra, no de la ciudad.
 - Hay personas de las que la tabla no dice nada, y ese silencio informa.
- ▶ **Al final de la clase volveremos a esta pregunta con cuatro respuestas.**

Los datos de hoy

Encuesta Origen Destino de Santiago 2012

La EOD 2012

- ▶ La encuesta de movilidad más completa de Chile (SECTRA y U. Alberto Hurtado).
- ▶ Registra todos los viajes de un día de los hogares encuestados.
 - 18.264 hogares, 60.054 personas, 113.591 viajes.
 - Es la base de la planificación de transporte de Santiago.
- ▶ Es una base relacional: varias tablas conectadas por identificadores.
- ▶ **El mismo diseño que van a encontrar en la Casen, el Censo o la ENUSC.**

Las tablas y sus llaves

- ▶ Hogares.csv: una fila por hogar. Llave: Hogar.
- ▶ personas.csv: una fila por persona. Llave: Hogar + Persona.
- ▶ viajes.csv: una fila por viaje. Llave: Hogar + Persona + Viaje.
- ▶ tablas_parametros/: el significado de cada código.
- ▶ **Equivocarse de llave es la fuente clásica de merges malos.**

Repaso de Pandas

Cinco preguntas, cinco herramientas

¿A quiénes les preguntaron? Cargar y mirar

```
personas = pd.read_csv('datos/eod_stgo/personas.csv',  
                        sep=';', decimal=',')  
  
personas.shape      # 60.054 filas, 39 columnas  
personas.info()     # tipos y no nulos, siempre antes de calcular
```

- Estos archivos usan punto y coma como separador y coma decimal: primer hallazgo.

¿Quiénes son? Derivar una columna

```
personas['Edad'] = 2013 - personas['AnoNac']  
  
personas['Edad'].describe()  
personas['Sexo'].value_counts()    # devuelve 1 y 2...
```

- No hay columna de edad: se deriva. Y el sexo son códigos que no significan nada solos.

¿Qué significan los códigos? El merge motivado

```
sexo = pd.read_csv('tablas_parametros/Sexo.csv', sep=';')
personas = personas.merge(sexo, left_on='Sexo',
                          right_on='Id', how='left')

personas['Sexo'].isna().sum()    # regla de oro: contar los sin
pareja
```

- ▶ Los significados viven en otra tabla: así se diseñan las bases de datos reales.

¿Cuántos viajes hace una persona? groupby y una trampa


```
viajes_por_persona = viajes.groupby(['Hogar', 'Persona']).size()

conteo = personas.set_index(['Hogar', 'Persona']).assign(
    n_viajes=viajes_por_persona)['n_viajes'].fillna(0)
```

- ▶ Quien no viajó no aparece en la tabla de viajes: si solo agrupamos, lo perdemos.

Quien no viaja también es dato

- ▶ El 23% de las personas no viajó ese día.
- ▶ Media: 1,9 viajes. Mediana: 2 viajes.
- ▶ Aquí la media quedó BAJO la mediana: el bloque de ceros la arrastra.
- ▶ **La asimetría no siempre empuja hacia el mismo lado: se mira, no se adivina.**



¿A quién representa la encuesta?

Los factores de expansión

De 37 mil encuestados a 6,7 millones de personas


- ▶ Cada encuestado representa a un número de personas parecidas a él.
- ▶ Ese número es su factor de expansión (Factor_LaboralNormal).
 - 37.326 personas con factor de día laboral en temporada normal.
 - La suma de sus factores: 6.651.735 personas representadas.
- ▶ Contar filas responde por la muestra; sumar factores responde por la ciudad.
- ▶ **Toda cifra oficial de la EOD, la Casen o la ENUSC está ponderada así.**

Análisis exploratorio

¿Qué número resume bien una respuesta?


¿Cuánto gana un hogar típico?

- ▶ Media: \$688.274. Mediana: \$507.826.
- ▶ La media es un 36% más alta que la mediana.
- ▶ Unos pocos hogares de ingresos muy altos arrastran el promedio.
- ▶ **'El hogar promedio gana \$688 mil' describe una situación en la que la mayoría no está.**



¿Cuánto dura un viaje?

- ▶ Mediana: 30 minutos. Percentil 95: 98 minutos.
- ▶ Máximo registrado: 1.335 minutos, un viaje de 22 horas.
- ▶ ¿Error de digitación? ¿Turno nocturno mal anotado?
- ▶ **Los valores extremos no se borran por molestos: se investigan y la decisión se declara.**




¿En qué se mueve Santiago?

► Dos merges y un groupby ponderado por factor.

- Caminata: 34% de los viajes.
- Transporte público (Bip!): 24%.
- Auto: 23%.

► **Esta es la partición modal oficial, calculada por nosotros desde los microdatos.**



Síntesis: ¿de quién habla este número?

- ▶ 'El hogar promedio gana \$688 mil': de casi nadie; la mediana habla del hogar típico.
- ▶ 'El 53% de los encuestados...': de la muestra; los factores de expansión hablan de la ciudad.
- ▶ '1,9 viajes en promedio': solo si contamos a quienes no viajaron y no estaban en la tabla.
- ▶ 'El sexo es 1 o 2': sin su tabla de códigos, un número no habla de nada.
- ▶ **La técnica era repaso; el hábito de interrogar cada cifra es lo que se llevan.**

Segundo bloque: parte la Tarea 1

- ▶ El retrato de tu comuna: cada pareja adopta una comuna del Gran Santiago.
 - Hoy: elegir la comuna y construir su retrato numérico.
 - Próxima clase: el retrato gráfico, con métodos de visualización.
 - Entrega del retrato completo: jueves 10 de septiembre, por Aula.
- ▶ El enunciado está en evaluaciones/tareas/ y la guía de hoy en actividades/.
- ▶ **Lo que hagan en este bloque ya es parte de la tarea.**