

Análisis exploratorio de datos

Clase 2 · Modelos, tipos de datos y Pandas

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · viernes 21 de agosto, 2026

Contenidos de la clase

- ▶ 1. Qué es un modelo.
- ▶ 2. Inferencia y predicción: dos objetivos distintos.
- ▶ 3. Correlación (Pearson y Spearman) y causalidad.
- ▶ 4. Tipos de datos.
- ▶ 5. El análisis exploratorio de datos.
- ▶ 6. Aplicación: la Encuesta Origen Destino de Santiago, con Pandas.
- ▶ **El concepto de la clase es el EDA: examinar los datos antes de modelarlos. Los puntos 1 a 4 entregan los lentes; el 6 lo pone en práctica.**

Marco conceptual

Modelos, inferencia y tipos de datos

¿Qué es un modelo?

- ▶ Una representación simplificada del proceso que genera los datos (James et al., 2023, cap. 2).
- ▶ Formalmente, se postula $Y = f(X) + \varepsilon$:
 - Y es la variable de interés; X , las variables observadas.
 - f es la relación sistemática que se quiere estimar.
 - ε es el error irreducible: lo que X no explica de Y .
- ▶ Ejemplo: el tiempo de un viaje en función de la distancia, el modo y la hora.
- ▶ **Construir un modelo implica decidir qué variables entran, qué se omite y qué se considera éxito (clase 1: esas decisiones incorporan las opiniones de quien modela).**

Inferencia y predicción

- ▶ Al estimar f puede buscarse una de dos cosas (James et al., cap. 2):
- ▶ Inferencia: comprender la relación entre X e Y .
 - Qué variables se asocian con Y , con qué magnitud y signo.
 - La forma de f importa: se prefieren modelos interpretables.
 - Ejemplo: ¿cómo se asocia el nivel socioeconómico con el uso de transporte público?
- ▶ Predicción: estimar Y para casos nuevos.
 - f puede tratarse como caja negra si predice con precisión.
 - Ejemplo: ¿cuántos viajes tendrá esta zona un día laboral?
- ▶ **En el curso: unidades 2 a 5 son descriptivas e inferenciales; unidades 6 a 9, predictivas.**

El coeficiente de correlación de Pearson

► Mide la asociación lineal entre dos variables numéricas: qué tan bien se ajustan los puntos a una recta. Se denota r (Bruce, Bruce y Gedeck, 2020).


► En la fórmula: x_i e y_i son los valores del par i ; $\bar{x}$ e $\bar{y}$, sus medias; n , el número de pares.

- $r = 1$: recta creciente exacta; $r = -1$: decreciente exacta.

- $r = 0$: sin asociación lineal (puede existir asociación de otra forma).

► **Su cuadrado anticipa el R^2 de la regresión (unidad 7).**

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$



Antes de Spearman: cómo se calculan los rangos

Cinco viajes de la EOD: rango = posición al ordenar cada variable

Distancia (km)	Duración (min)	Rango dist.	Rango dur.	d	d ²
0.2	20	1	2	-1	1
0.5	5	2	1	1	1
5.0	60	3	3	0	0
8.7	75	4	4	0	0
17.8	90	5	5	0	0

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} = 1 - \frac{6 \cdot 2}{5(25 - 1)} = 0.90$$

Cada variable se ordena por separado y cada valor recibe su posición; d compara las posiciones de un mismo viaje.

El coeficiente de Spearman


► El mismo Pearson, calculado sobre los rangos: la posición de cada valor al ordenar (1 = el menor). Se denota ρ (rho).

► En la fórmula: d_i es la diferencia entre los rangos del caso i en ambas variables; n , el número de pares. Vale sin empates.


○ Los valores 5, 12, 8 y 200 tienen rangos 1, 3, 2 y 4: la magnitud desaparece, queda el orden.

► **Mide asociación monotónica: robusto a extremos, invariante ante transformaciones monótonas, válido para ordinales.**

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$



La correlación, vista en los datos completos



La mediana por tramo sube de forma sostenida (Spearman 0,76) pero no recta y con extremos (Pearson 0,43).

Cuando la relación no es lineal, el coeficiente puede ocultarla


► Los viajes por persona según la edad: suben hasta los 30 a 40 años y luego bajan.

► La asociación es clara, pero $r = 0,04$ y $p = 0,05$.

- La relación no es monótona: el tramo que sube y el que baja se cancelan.


- Ni Pearson ni Spearman están diseñados para esta forma.

► **Un coeficiente cercano a cero no demuestra ausencia de asociación: el gráfico sí la muestra.**



¿Cuándo usar cada coeficiente?


- ▶ Pearson: relación aproximadamente recta, sin extremos dominantes; antesala del modelo lineal.
- ▶ Spearman: asimetrías, extremos, curvas crecientes, o variables ordinales.
 - La brecha entre ambos es un diagnóstico: 0,43 contra 0,76 indica curva o extremos.
 - Tras el logaritmo, Pearson llega a 0,73, casi igual a Spearman.
- ▶ **Calcule ambos; si difieren mucho, mire el gráfico antes de reportar.**



Correlación y causalidad

- ▶ Causalidad: intervenir X cambiaría Y. Es una afirmación más fuerte que la asociación.
 - Una asociación observada admite varias explicaciones: X causa Y, Y causa X, o una variable de confusión Z afecta a ambas.
 - Los datos observacionales, como los de una encuesta, muestran asociación; no bastan para establecer causalidad.
 - La inferencia causal tiene métodos propios; este curso no los cubre.
- ▶ **Regla de trabajo: una asociación se reporta como asociación, sin verbos causales que los datos no respaldan.**

Tipos de datos



El tipo de la variable determina qué operaciones tienen sentido (Bruce, Bruce y Gedeck, 2020, cap. 1).

El tipo estadístico no es el tipo computacional

- ▶ En la EOD el sexo viene codificado 1 o 2: para Pandas es un entero (int64).
- ▶ El tipo computacional permite operar; el tipo estadístico decide si la operación significa algo.
 - El promedio de Sexo en la EOD es 1,53: aritméticamente correcto, sin significado.
 - El promedio de Edad sí es interpretable: la variable es numérica.
- ▶ **Identificar el tipo de cada variable es un paso del análisis, no una formalidad.**

El análisis exploratorio de datos (EDA)

- ▶ La etapa en que se examinan los datos antes de modelarlos (EDA, por exploratory data analysis; Tukey, 1977).
- ▶ Responde cuatro tipos de pregunta:
 - La forma: cómo se distribuye cada variable.
 - Lo típico y lo extremo: qué es frecuente y qué es anómalo.
 - Lo que falta: qué datos están ausentes y con qué patrón.
 - Las relaciones: qué variables se asocian con qué otras.
- ▶ Genera hipótesis; el análisis confirmatorio (unidad 5) las pone a prueba.
- ▶ **Una pregunta transversal para toda cifra resumen: ¿de quién habla este número? ¿De la muestra, de un subgrupo, de la ciudad?**


Los datos

Encuesta Origen Destino de Santiago 2012

La EOD 2012

- ▶ Encuesta de movilidad del Gran Santiago (SECTRA y U. Alberto Hurtado).
- ▶ Registra todos los viajes de un día de los hogares encuestados.
 - 18.264 hogares, 60.054 personas, 113.591 viajes.
 - Se usa en la planificación de transporte de la ciudad.
- ▶ **El mismo diseño relacional de la Casen, el Censo o la ENUSC.**

Una encuesta, varias tablas



Llaves: Hogar · Hogar + Persona · Hogar + Persona + Viaje. Los códigos se resuelven contra tablas_parametros/.

Repaso de Pandas

Dos casos concretos con la EOD

El DataFrame: la estructura central de Pandas

viajes.csv cargado como DataFrame: filas indexadas, columnas con nombre y tipo

	Hogar	Persona	Viaje	ComunaOrigen	Proposito	TiempoViaje
0	173431	17343102	1734310202	94	7	70
1	173441	17344101	1734410101	94	1	105
2	173441	17344101	1734410102	71	7	90
3	173441	17344103	1734410301	94	1	55
4	173441	17344103	1734410302	91	7	150
5	173451	17345101	1734510101	94	6	60
6	173451	17345101	1734510102	70	7	45
7	173451	17345101	1734510103	94	7	20

Los códigos (ComunaOrigen, Proposito) se resuelven contra tablas_parametros/ con merge.

El DataFrame: origen y propiedades

- ▶ Estructura tabular bidimensional: columnas con nombre y tipo propio, filas indexadas.
- ▶ El concepto viene del lenguaje S: los objetos `data.frame` (Chambers y Hastie, 1992). Wes McKinney lo llevó a Python con `pandas` (McKinney, 2010).
 - Cada columna es un arreglo tipado y contiguo en memoria.
 - Por eso las operaciones se ejecutan en código compilado sobre la columna completa, en vez de interpretar un ciclo elemento por elemento: sumar `TiempoViaje` toma 0,08 ms contra 7 ms del ciclo equivalente.
 - El índice alinea los datos automáticamente en operaciones entre tablas y series.
 - Implementa el álgebra relacional en memoria: selección, proyección, join (merge) y agregación (`groupby`).

Abrir el dataset

```
import pandas as pd

viajes = pd.read_csv('datos/eod_stgo/viajes.csv',
                     sep=';', decimal=',')
```


- Todo el código de la clase está en el notebook 02_pandas_eda.ipynb del repositorio.

Las variantes del merge: qué filas se conservan

Qué filas sobreviven a cada tipo de merge

how="inner"


izquierda derecha



solo las llaves
que están en ambas

how="left"


izquierda derecha



todas las de la izquierda;
sin pareja quedan NaN

how="right"


izquierda derecha



todas las de la derecha;
sin pareja quedan NaN

how="outer"

izquierda derecha



todas las llaves
de ambas tablas

El valor por defecto es inner: descarta sin aviso las filas sin pareja.

El efecto del parámetro how sobre la población analizada

- ▶ Personas con viajes, merge inner: 113.591 filas (una por viaje).
- ▶ El mismo merge en left: 127.379 filas.
 - La diferencia son 13.788 personas que no viajaron ese día.
 - Con inner desaparecen; con left quedan, con NaN en el viaje.
- ▶ **Un promedio calculado sobre el resultado del inner excluye a quienes no viajaron.**

Exploración de la EOD

EDA sobre la EOD: estadística descriptiva ponderada

Los factores de expansión: de la muestra a la ciudad

El factor de expansión: de la muestra a la ciudad


37.326 encuestados con factor laboral · la suma de factores estima 6.651.735 personas



Contar filas responde por la muestra; sumar factores responde por la ciudad.


Viajes por persona: los ausentes también cuentan

- ▶ El 23% de las personas no viajó ese día.
- ▶ Media: 1,9 viajes. Mediana: 2 viajes.
- ▶ La media quedó bajo la mediana: la masa de ceros la desplaza.
- ▶ **La dirección del sesgo depende de la forma de la distribución.**




El ingreso de los hogares: media y mediana

- ▶ Media: \$688.274. Mediana: \$507.826.
- ▶ La media es un 36% más alta que la mediana.
- ▶ Los ingresos altos desplazan el promedio; la mayoría gana menos.
- ▶ **El promedio describe una situación en la que la mayoría no está.**



La duración de los viajes: valores extremos

- ▶ Mediana: 30 minutos. Percentil 95: 98 minutos.
- ▶ Máximo registrado: 1.335 minutos, un viaje de 22 horas.
- ▶ ¿Error de digitación? ¿Turno nocturno mal anotado?
- ▶ **Los valores extremos se investigan y la decisión se declara.**




La partición modal del Gran Santiago


► Dos merges y un groupby ponderado por factor.

- Caminata: 34% de los viajes.
- Transporte público (Bip!): 24%.
- Auto: 23%.

► **Calculada desde los microdatos, con los factores de un día laboral.**



El reparto modal difiere entre comunas




Normalizar por comuna permite comparar proporciones entre comunas de tamaños muy distintos.

Ingreso y uso de transporte público

► Cada punto es una comuna: ingreso medio contra proporción de viajes en transporte público.

- Periferia (Buin, Melipilla): poco transporte público; la red no llega.
- Ingresos altos (Vitacura, Lo Barnechea): conectadas, con poco uso.
- Correlación de Pearson: -0,17. La asociación lineal es débil.

► **Como vimos en el marco conceptual: el coeficiente no reemplaza al gráfico, y la asociación no autoriza verbos causales.**



Los propósitos de viaje según el día de la semana



El heatmap muestra 14 propósitos por 7 días en una sola figura: útil para tablas completas.

Cuando los datos crecen

El concepto de DataFrame se conserva; la herramienta cambia con el tamaño



PySpark se usa con SQL o con sus propios DataFrames; Dask reparte operaciones estilo Pandas; Polars y DuckDB rinden en una sola máquina.

Síntesis

- ▶ Un modelo es una simplificación con decisiones incorporadas; estimarlo puede buscar inferencia o predicción.
- ▶ Las asociaciones se reportan como asociaciones: la causalidad exige más que datos observacionales.
- ▶ El tipo de la variable, no su dtype, determina qué resúmenes tienen sentido.
- ▶ Con distribuciones asimétricas, la mediana y los percentiles describen mejor lo típico que la media.
- ▶ **El concepto de la clase: el EDA, examinar los datos antes de modelarlos, preguntando ante cada cifra de quién habla.**

Segundo bloque: comienza la Tarea 1

- ▶ El retrato de tu comuna: cada pareja adopta una comuna del Gran Santiago.
 - Hoy: elegir la comuna y construir su retrato numérico.
 - Próxima clase: el retrato gráfico, con métodos de visualización.
 - Entrega del retrato completo: jueves 10 de septiembre, por Aula.
- ▶ El enunciado está en evaluaciones/tareas/ y la guía de hoy en actividades/.
- ▶ **Lo que avancen en este bloque ya es parte de la tarea.**

Referencias

- ▶ James, G., Witten, D., Hastie, T. y Tibshirani, R. (2023). An Introduction to Statistical Learning with Applications in Python. Springer. Capítulo 2. Descarga gratuita en statlearning.com.
- ▶ Bruce, P., Bruce, A. y Gedeck, P. (2020). Practical Statistics for Data Scientists, 2ª ed. O'Reilly. Capítulo 1.
- ▶ Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.
- ▶ Chambers, J. M. y Hastie, T. J. (1992). Statistical Models in S. Wadsworth & Brooks/Cole.
- ▶ McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference.