

Manipulación de datos y análisis exploratorio

Clase 2 · Pandas y EDA

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · viernes 21 de agosto, 2026

Qué veremos hoy

- ▶ Cargar datos reales y describir su estructura.
- ▶ Seleccionar, filtrar y tratar los datos faltantes.
- ▶ Resumir con groupby y combinar tablas con merge.
- ▶ Empezar el análisis exploratorio: medidas de resumen y primeras figuras.
- ▶ **Cerramos con la actividad en parejas, en el segundo bloque.**

Los datos de hoy

Emisiones al aire declaradas en Chile

De dónde vienen los datos

- ▶ Registro de Emisiones y Transferencias de Contaminantes (RETC), del Ministerio del Medio Ambiente.
- ▶ Emisiones al aire de fuentes puntuales, año 2020.
 - Una fila es un contaminante emitido por un establecimiento.
 - 27.015 filas, 16 regiones, 287 comunas y 19 rubros.
 - MP2,5, MP10 y SO2: los contaminantes de los planes de descontaminación.
- ▶ **Son datos reales, con faltantes y con una distribución muy despareja.**

Pandas

La herramienta para manipular tablas

Las dos estructuras de Pandas

- ▶ DataFrame: una tabla, con filas y columnas con nombre.
- ▶ Series: una columna, con su índice.
 - Al seleccionar una columna de un DataFrame se obtiene una Series.
 - El índice es lo que permite alinear datos entre tablas distintas.
- ▶ **Casi todo el trabajo del curso pasa por estas dos estructuras.**

Cargar y mirar antes de calcular

```
emisiones = pd.read_csv('datos/emisiones_aire_2020.csv')  
  
emisiones.shape      # cuántas filas y columnas  
emisiones.head()     # las primeras filas  
emisiones.info()     # tipo de cada columna y cuántos no nulos
```

- Nunca calcule nada antes de saber qué tiene entre manos.

Seleccionar columnas

```
emisiones['region']           # una Series  
emisiones[['region', 'comuna']] # un DataFrame
```

- ▶ Los dobles corchetes son la lista de nombres dentro de la selección.

loc y iloc: no confundirlos

```
emisiones.iloc[0:3]                # por posición  
emisiones.loc[0:2, ['region', 'comuna']] # por etiqueta
```

- ▶ iloc excluye el extremo derecho, como las listas de Python; loc lo incluye.

Filtrar con condiciones

```
mp25 = emisiones[emisiones['contaminante'] == 'MP2,5']  
  
rm = emisiones[  
    (emisiones['contaminante'] == 'MP2,5')  
    & (emisiones['region'] == 'Metropolitana')  
]
```

- Cada condición va entre paréntesis, y se combinan con & y con |.

Datos faltantes

- ▶ Pandas los representa como NaN, y en datos reales siempre hay.
- ▶ En este archivo faltan 58 valores de toneladas y 12 pares de coordenadas.
 - `isna().sum()` cuenta cuántos faltan en cada columna.
 - `dropna()` elimina filas; `fillna()` las rellena.
- ▶ **Qué hacer con ellos no es automático: depende de la pregunta.**


groupby: separar, resumir y juntar

```
mp25.groupby('region')['cantidad_toneladas'].sum()

mp25.groupby('region')['cantidad_toneladas'].agg(
    total='sum', promedio='mean', mediana='median',
)
```

- Responde la mayoría de las preguntas descriptivas de un conjunto de datos.

Emisiones de MP2,5 por región



Antofagasta y O'Higgins están arriba con mucha menos población: pesa el perfil productivo.

merge: combinar dos tablas

```
mp25_zonas = mp25.merge(macrozonas, on='region', how='left')  
mp25_zonas['macrozona'].isna().sum()    # revisar siempre
```

- Un nombre escrito distinto en las dos tablas produce NaN sin avisar.

Análisis exploratorio


Mirar los datos antes de modelarlos

Qué es el análisis exploratorio

- ▶ El término lo acuña John Tukey en 1977, en el libro Exploratory Data Analysis.
- ▶ La idea: mirar los datos antes de suponer un modelo.
 - Describir la forma de la distribución, no solo su centro.
 - Detectar errores, valores extremos y patrones inesperados.
- ▶ **Es la etapa donde uno se entera de con qué está trabajando.**

El promedio puede engañar

- ▶ En las emisiones de MP2,5:
 - Media: 0,382 toneladas.
 - Mediana: 0,006 toneladas.
 - Máximo: 299 toneladas.
- ▶ La media es unas 66 veces la mediana.
- ▶ **Decir 'el establecimiento promedio emite 0,38 t' describe a casi ninguno.**




Medidas robustas

- ▶ Una medida es robusta cuando los valores extremos no la alteran demasiado.
 - Media completa: 0,382 toneladas.
 - Media truncada al 10%: 0,017 toneladas.
 - Mediana: 0,006 toneladas.
- ▶ La media truncada descarta un porcentaje de cada extremo antes de promediar.
- ▶ **Con distribuciones asimétricas, la mediana describe mejor el caso típico.**


Percentiles: la forma completa

- ▶ El percentil 90 es el valor bajo el cual queda el 90% de las observaciones.
 - Percentil 50: 0,006 t.
 - Percentil 90: 0,153 t.
 - Percentil 95: 0,672 t.
 - Percentil 99: 5,809 t.
- ▶ **El 95% emite menos de 0,7 t al año, y el máximo llega a 299.**


Un histograma que no se puede leer



El mismo histograma en escala logarítmica



Comparar grupos con diagramas de caja



Síntesis

- ▶ Antes de calcular: shape, info() y datos faltantes.
- ▶ loc es por etiqueta, iloc por posición, y los filtros son condiciones booleanas.
- ▶ groupby más una función de resumen responde casi todas las preguntas descriptivas.
- ▶ Después de un merge, revise si quedaron filas sin pareja.
- ▶ **Con distribuciones asimétricas, la mediana y los percentiles son más honestos que la media.**

Actividad de hoy

- ▶ En parejas, en el segundo bloque, sobre el mismo archivo de emisiones.
 - Cargar los datos y describir su estructura.
 - Comparar MP10 y MP2,5 por región.
 - Encontrar los establecimientos que más emiten SO₂.
 - Decidir qué medida de resumen reportar y justificarlo.
- ▶ **El enunciado está en actividades/clase02_actividad.md.**