

Análisis exploratorio de datos

Clase 2 · Modelos, tipos de datos y Pandas

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · viernes 21 de agosto, 2026

Contenidos de la clase

- ▶ 1. Qué es un modelo.
- ▶ 2. Inferencia y predicción: dos objetivos distintos.
- ▶ 3. Correlación (Pearson y Spearman) y causalidad.
- ▶ 4. Tipos de datos.
- ▶ 5. El análisis exploratorio de datos.
- ▶ 6. Aplicación: la Encuesta Origen Destino de Santiago, con Pandas.
- ▶ **En el segundo bloque comienza la Tarea 1.**

Marco conceptual

Modelos, inferencia y tipos de datos

¿Qué es un modelo?

- ▶ Una representación simplificada del proceso que genera los datos (James et al., 2023, cap. 2).
- ▶ Formalmente, se postula $Y = f(X) + \varepsilon$:
 - Y es la variable de interés; X , las variables observadas.
 - f es la relación sistemática que se quiere estimar.
 - ε es el error irreducible: lo que X no explica de Y .
- ▶ Ejemplo: el tiempo de un viaje en función de la distancia, el modo y la hora.
- ▶ **Construir un modelo implica decidir qué variables entran, qué se omite y qué se considera éxito (clase 1: esas decisiones incorporan las opiniones de quien modela).**

Inferencia y predicción

- ▶ Al estimar f puede buscarse una de dos cosas (James et al., cap. 2):
- ▶ Inferencia: comprender la relación entre X e Y .
 - Qué variables se asocian con Y , con qué magnitud y signo.
 - La forma de f importa: se prefieren modelos interpretables.
 - Ejemplo: ¿cómo se asocia el nivel socioeconómico con el uso de transporte público?
- ▶ Predicción: estimar Y para casos nuevos.
 - f puede tratarse como caja negra si predice con precisión.
 - Ejemplo: ¿cuántos viajes tendrá esta zona un día laboral?
- ▶ **En el curso: unidades 2 a 5 son descriptivas e inferenciales; unidades 6 a 9, predictivas.**


El coeficiente de correlación de Pearson

- ▶ Mide la asociación lineal entre dos variables numéricas: qué tan bien se ajustan los puntos a una recta. Toma valores entre -1 y 1 (Bruce, Bruce y Gedeck, 2020, cap. 1).
- ▶ Es la covarianza estandarizada: $r = \text{cov}(X, Y) / (\sigma_X \cdot \sigma_Y)$.
 - Cada punto aporta el producto de sus desviaciones respecto de la media, en unidades de desviación estándar.
 - Un valor extremo entra multiplicando y puede dominar el resultado.
 - Una relación curva produce un coeficiente bajo aunque la asociación sea fuerte.
 - Transformar los datos (por ejemplo con logaritmo) cambia su valor.
- ▶ **Su cuadrado anticipa el R^2 de la regresión lineal (unidad 7).**

El coeficiente de Spearman


- ▶ Es el mismo Pearson, pero calculado sobre los rangos: la posición de cada valor al ordenar la variable.
- ▶ Sin empates equivale a: $\rho = 1 - 6 \cdot \sum d^2 / (n \cdot (n^2 - 1))$, con d la diferencia de rangos de cada caso.
 - Los valores 5, 12, 8 y 200 tienen rangos 1, 3, 2 y 4: el 200 pasa a ser solo el cuarto.
 - Mide si al crecer una variable crece la otra, sin importar la forma de la relación.
- ▶ **Consecuencias: robusto a extremos, invariante ante transformaciones monótonas, y válido para variables ordinales, donde Pearson no tiene sentido.**

Spearman es Pearson sobre los rangos



Los mismos 60 viajes en ambos paneles: al pasar a rangos, la curva se endereza y el extremo deja de dominar.

La correlación, vista en los datos completos



La mediana por tramo sube de forma sostenida (Spearman 0,76) pero no recta y con extremos (Pearson 0,43).


¿Cuándo usar cada coeficiente?

- ▶ Pearson: variables numéricas, relación aproximadamente recta en el gráfico, sin extremos dominantes.
- ▶ Spearman: distribuciones asimétricas o con extremos, relaciones curvas pero crecientes, o variables ordinales.
- ▶ En el EDA conviene calcular ambos: la diferencia entre ellos es un diagnóstico.
 - Distancia y duración: Pearson 0,43 contra Spearman 0,76. La brecha indica relación monótona pero no lineal.
 - Tras aplicar logaritmo a ambas variables, Pearson sube a 0,73, casi igual a Spearman: el logaritmo endereza la curva.
- ▶ **Si los dos coeficientes difieren mucho, mire el gráfico antes de reportar cualquiera**

Correlación y causalidad

- ▶ Causalidad: intervenir X cambiaría Y. Es una afirmación más fuerte que la asociación.
 - Una asociación observada admite varias explicaciones: X causa Y, Y causa X, o una variable de confusión Z afecta a ambas.
 - Los datos observacionales, como los de una encuesta, muestran asociación; no bastan para establecer causalidad.
 - La inferencia causal tiene métodos propios; este curso no los cubre.
- ▶ **Regla de trabajo: una asociación se reporta como asociación, sin verbos causales que los datos no respaldan.**

Tipos de datos



El tipo de la variable determina qué operaciones tienen sentido (Bruce, Bruce y Gedeck, 2020, cap. 1).

El tipo estadístico no es el tipo computacional

- ▶ En la EOD el sexo viene codificado 1 o 2: para Pandas es un entero (int64).
- ▶ El tipo computacional permite operar; el tipo estadístico decide si la operación significa algo.
 - El promedio de Sexo en la EOD es 1,53: aritméticamente correcto, sin significado.
 - El promedio de Edad sí es interpretable: la variable es numérica.
- ▶ **Identificar el tipo de cada variable es un paso del análisis, no una formalidad.**

El análisis exploratorio de datos

- ▶ La etapa en que se examinan los datos antes de modelarlos (Tukey, 1977).
- ▶ Responde cuatro tipos de pregunta:
 - La forma: cómo se distribuye cada variable.
 - Lo típico y lo extremo: qué es frecuente y qué es anómalo.
 - Lo que falta: qué datos están ausentes y con qué patrón.
 - Las relaciones: qué variables se asocian con qué otras.
- ▶ Genera hipótesis; el análisis confirmatorio (unidad 5) las pone a prueba.
- ▶ **Una pregunta transversal para toda cifra resumen: ¿de quién habla este número? ¿De la muestra, de un subgrupo, de la ciudad?**


Los datos

Encuesta Origen Destino de Santiago 2012

La EOD 2012

- ▶ Encuesta de movilidad del Gran Santiago (SECTRA y U. Alberto Hurtado).
- ▶ Registra todos los viajes de un día de los hogares encuestados.
 - 18.264 hogares, 60.054 personas, 113.591 viajes.
 - Se usa en la planificación de transporte de la ciudad.
- ▶ **El mismo diseño relacional de la Casen, el Censo o la ENUSC.**

Una encuesta, varias tablas



Los códigos no significan nada sin sus tablas de parámetros: unirlos es parte del análisis.

Repaso de Pandas

Dos casos concretos con la EOD

Abrir el dataset

```
import pandas as pd

viajes = pd.read_csv('datos/eod_stgo/viajes.csv',
                     sep=';', decimal=',')
```

- Todo el código de la clase está en el notebook 02_pandas_eda.ipynb del repositorio.


El DataFrame: la estructura central de Pandas

viajes.csv cargado como DataFrame: filas indexadas, columnas con nombre y tipo

	Hogar	Persona	Viaje	ComunaOrigen	Proposito	TiempoViaje
0	173431	17343102	1734310202	94	7	70
1	173441	17344101	1734410101	94	1	105
2	173441	17344101	1734410102	71	7	90
3	173441	17344103	1734410301	94	1	55
4	173441	17344103	1734410302	91	7	150
5	173451	17345101	1734510101	94	6	60
6	173451	17345101	1734510102	70	7	45
7	173451	17345101	1734510103	94	7	20

Una tabla con filas indexadas y columnas con nombre y tipo. Los códigos (comuna, propósito) se traducen con las tablas de parámetros, uniéndolas con merge.

Las variantes del merge: qué filas se conservan



El valor por defecto es inner: descarta sin aviso las filas sin pareja.

El efecto del parámetro how sobre la población analizada

- ▶ Personas con viajes, merge inner: 113.591 filas (una por viaje).
- ▶ El mismo merge en left: 127.379 filas.
 - La diferencia son 13.788 personas que no viajaron ese día.
 - Con inner desaparecen; con left quedan, con NaN en el viaje.
- ▶ **Un promedio calculado sobre el resultado del inner excluye a quienes no viajaron.**

Exploración de la EOD

Estadística descriptiva sobre datos reales

Viajes por persona: los ausentes también cuentan


- ▶ El 23% de las personas no viajó ese día.
- ▶ Media: 1,9 viajes. Mediana: 2 viajes.
- ▶ La media quedó bajo la mediana: la masa de ceros la desplaza.
- ▶ **La dirección del sesgo depende de la forma de la distribución.**



Los factores de expansión: de la muestra a la ciudad

El factor de expansión: de la muestra a la ciudad


37.326 encuestados con factor laboral · la suma de factores estima 6.651.735 personas



Contar filas responde por la muestra; sumar factores responde por la ciudad.


El ingreso de los hogares: media y mediana

- ▶ Media: \$688.274. Mediana: \$507.826.
- ▶ La media es un 36% más alta que la mediana.
- ▶ Los ingresos altos desplazan el promedio; la mayoría gana menos.
- ▶ **El promedio describe una situación en la que la mayoría no está.**



La duración de los viajes: valores extremos

- ▶ Mediana: 30 minutos. Percentil 95: 98 minutos.
- ▶ Máximo registrado: 1.335 minutos, un viaje de 22 horas.
- ▶ ¿Error de digitación? ¿Turno nocturno mal anotado?
- ▶ **Los valores extremos se investigan y la decisión se declara.**




La partición modal del Gran Santiago


► Dos merges y un groupby ponderado por factor.

- Caminata: 34% de los viajes.
- Transporte público (Bip!): 24%.
- Auto: 23%.

► **Calculada desde los microdatos, con los factores de un día laboral.**



El reparto modal difiere entre comunas




Normalizar por comuna permite comparar proporciones entre comunas de tamaños muy distintos.

Ingreso y uso de transporte público


► Cada punto es una comuna: ingreso medio contra proporción de viajes en transporte público.

- Periferia (Buin, Melipilla): poco transporte público; la red no llega.
- Ingresos altos (Vitacura, Lo Barnechea): conectadas, con poco uso.
- Correlación de Pearson: -0,17. La asociación lineal es débil.

► **Como vimos en el marco conceptual: el coeficiente no reemplaza al gráfico, y la asociación no autoriza verbos causales.**



Los propósitos de viaje según el día de la semana



El heatmap muestra 14 propósitos por 7 días en una sola figura: útil para tablas completas.

Cuando los datos crecen

El concepto de DataFrame se conserva; la herramienta cambia con el tamaño



PySpark se usa con SQL o con sus propios DataFrames; Dask reparte operaciones estilo Pandas; Polars y DuckDB rinden en una sola máquina.

Síntesis

- ▶ Un modelo es una simplificación con decisiones incorporadas; estimarlo puede buscar inferencia o predicción.
- ▶ Las asociaciones se reportan como asociaciones: la causalidad exige más que datos observacionales.
- ▶ El tipo de la variable, no su dtype, determina qué resúmenes tienen sentido.
- ▶ Con distribuciones asimétricas, la mediana y los percentiles describen mejor lo típico que la media.
- ▶ **Ante toda cifra resumen: ¿de quién habla este número? ¿Muestra, subgrupo o ciudad?**

Segundo bloque: comienza la Tarea 1

- ▶ El retrato de tu comuna: cada pareja adopta una comuna del Gran Santiago.
 - Hoy: elegir la comuna y construir su retrato numérico.
 - Próxima clase: el retrato gráfico, con métodos de visualización.
 - Entrega del retrato completo: jueves 10 de septiembre, por Aula.
- ▶ El enunciado está en evaluaciones/tareas/ y la guía de hoy en actividades/.
- ▶ **Lo que avancen en este bloque ya es parte de la tarea.**

Referencias

- ▶ James, G., Witten, D., Hastie, T. y Tibshirani, R. (2023). An Introduction to Statistical Learning with Applications in Python. Springer. Capítulo 2. Descarga gratuita en statlearning.com.
- ▶ Bruce, P., Bruce, A. y Gedeck, P. (2020). Practical Statistics for Data Scientists, 2ª ed. O'Reilly. Capítulo 1.
- ▶ Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.
- ▶ SECTRA (2014). Encuesta Origen Destino de Viajes Santiago 2012.
- ▶ Material inspirado en el curso de visualización de E. Graells-Garrido (github.com/zorzalerrante/aves).