

Visualización y análisis exploratorio gráfico

**Clase 3 · Marcas y canales, dispersión,
boxplots y calidad de datos**

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · viernes 28 de agosto, 2026

Contenidos de la clase

- ▶ 1. Codificación visual: marcas y canales.
- ▶ 2. La percepción: qué canal es más efectivo, y cómo se sabe.
- ▶ 3. El color: canales y paletas.
- ▶ 4. Ejemplos: barras, áreas y tortas.
- ▶ 5. EDA descriptivo: dispersión y forma de una variable.
- ▶ 6. El boxplot y los valores atípicos.
- ▶ 7. Calidad y limpieza de datos.

Codificación visual

Cómo un dato se convierte en un elemento gráfico

La codificación visual


- ▶ **La codificación visual es el proceso de asignar propiedades gráficas (posición, forma, color, tamaño) a los atributos de los datos.**
- ▶ Ese proceso se describe con dos piezas: marcas y canales (Munzner, 2014, cap. 5).

Las marcas

► Una marca es el elemento geométrico básico que representa una observación o un vínculo.

- Punto: una observación (cada viaje del scatter).
- Línea: una conexión o una trayectoria.
- Área: una región (una barra, una comuna en un mapa).

► **Las marcas son los bloques de construcción; por sí solas todavía no codifican valores.**




Los canales

- ▶ Un canal controla la apariencia de una marca: posición, largo, área, forma, inclinación, color.
- ▶ Se combinan: una misma marca puede llevar varios canales a la vez (posición y color, por ejemplo).
- ▶ Interactúan con la marca: el tipo de marca determina qué canales admite (una línea tiene largo; un punto, no).




Canales de forma e inclinación



Cada canal define una familia de variaciones perceptibles de la marca.

Marcas y canales, combinados



Un gráfico se describe como: qué marca usa, y qué canal codifica cada variable. Agregar una variable es agregar un canal sobre la misma marca.

Principios de diseño: efectividad y expresividad


- ▶ Efectividad: codificar los atributos más importantes de los datos con los canales más efectivos.
- ▶ Expresividad: coherencia entre el tipo de canal (magnitud o identidad) y la semántica del atributo (cuantitativo, ordinal, categórico).
- ▶ **Aplicar ambos exige saber qué canales son más efectivos y de qué tipo es cada uno: eso lo responde la percepción, a continuación.**

¿Qué canal usar? La percepción se puede medir

- ▶ **No todos los canales se perciben igual de bien, y eso se ha medido en experimentos controlados.**
- ▶ Cuatro propiedades para comparar canales:
 - Precisión: qué tan fiel es la percepción al valor real.
 - Discriminabilidad: cuántos niveles distintos se alcanzan a distinguir.
 - Separabilidad: si dos canales juntos se leen por separado o se interfieren.
 - Saliencia: qué tan fácil es detectar un cambio a simple vista.


Precisión: la ley de Stevens

- ▶ La sensación percibida crece como una potencia del estímulo físico: $S = I^n$.
 - Largo: $n \approx 1$, se percibe casi proporcional.
 - Área: $n \approx 0,7$ y brillo: $n \approx 0,5$, se subestiman.
- ▶ **Consecuencia directa: comparar largos (barras) es más preciso que comparar áreas o colores.**





Discriminabilidad

- ▶ Cuántos valores distintos de un canal se pueden percibir y cuantificar.
- ▶ En el mapa, el grosor de cada línea codifica el tamaño del flujo telefónico entre dos países, y se usan solo tres grosores.
- ▶ **¿Qué pasaría si fuesen 10 grosores?**
¿Diferenciaríamos valores intermedios?
- ▶ Si el atributo tiene más niveles que los que el canal distingue, conviene agrupar o cambiar de canal.




Discriminabilidad: ¿cuánto es el doble?



- ▶ Con el largo, una barra del doble se lee como el doble.
- ▶ Con la saturación, nadie puede decir cuánto más rojo es el segundo cuadrado: se percibe la diferencia, no la cantidad.
- ▶ Diagrama: Denis Parra.




Separabilidad: ¿cuántos grupos pueden identificar?







Separabilidad: ¿cuántos grupos pueden identificar?




Separabilidad: ¿cuántos grupos pueden identificar?



Separabilidad: ¿cuántos grupos pueden identificar?




Separabilidad: la respuesta



Posición con tonalidad se leen por separado y los grupos saltan a la vista; tamaño con tonalidad interfiere, y ancho con alto o rojo con verde se perciben como un solo canal. Al combinar canales hay que verificar que sigan siendo legibles por separado.

Saliencia (pop-out)

- ▶ Qué tan fácil es detectar un cambio de un canal a simple vista, sin buscar.
- ▶ No depende solo del canal: también del contexto y de lo que rodea a la visualización.
- ▶ La velocidad de detección sí depende del canal y de cómo interactúa con otros canales (segunda columna de la figura).
- ▶ El color y el movimiento destacan de inmediato; úselos para lo que de verdad importa destacar.



Los canales, ordenados por efectividad

Canales de identidad	Canales de magnitud
1. Posición espacial  2. Tonalidad de color  3. Forma 	1. Posición en escala común  2. Posición en escalas distintas  3. Largo (una dimensión)  4. Inclínación (ángulo)  5. Tamaño (dos dimensiones)  6. Profundidad (posición 3D)  7. Iluminación de color  8. Saturación de color  9. Curvatura  10. Volumen (tres dimensiones) 

Canales de identidad para atributos categóricos; canales de magnitud para ordinales y cuantitativos. Dentro de cada grupo, ordenados de más a menos efectivo (Munzner, 2014).

El color son tres canales

► El modelo HSL separa el color en tono (hue), saturación y luminosidad, y cada uno funciona como un canal distinto.

- Tono: canal de identidad, para categorías.
- Luminosidad y saturación: canales de magnitud, para cantidades.

► **Elegir colores no es una decisión estética: es elegir qué canal codifica qué atributo.**




Paleta secuencial


- ▶ Para datos con orden y gradación, de menos a más: un tono con luminosidad creciente.
- ▶ Es la paleta de un mapa de ingresos por comuna, o de los heatmaps de la clase pasada.
- ▶ El orden de los colores se percibe sin leer la leyenda: más oscuro es más.

Pick a color scheme:

Multi-hue:



Single hue:



Paleta divergente

- ▶ Para datos con orden y un centro con significado: cero, el promedio, o un valor de referencia.
- ▶ Dos tonos que se alejan de un neutro central: cada dirección tiene su color, y la distancia al centro, su intensidad.
- ▶ Ejemplo: diferencia de viajes de una comuna respecto del promedio de la ciudad.

Number of data classes:

3




Nature of your data:



☐ sequential ☒ diverging ☐ qualitative

Pick a color scheme:




Paleta cualitativa

- ▶ Para categorías sin orden: tonos bien distintos, con luminosidad y saturación parecidas para que ninguna categoría domine.
- ▶ La discriminabilidad manda: entre 6 y 12 categorías es el máximo distinguible; con más, agrupar en "otros".
- ▶ Usar una paleta secuencial para categorías sin orden viola la expresividad: sugiere un orden que no existe.


Number of data classes: ⓘ

Nature of your data: ⓘ
☐ sequential ☐ diverging ☒ qualitative

Pick a color scheme:



ColorBrewer

- ▶ Herramienta para elegir paletas de los tres tipos: colorbrewer2.org.
- ▶ Permite filtrar por paletas aptas para daltonismo, impresión y fotocopia.
- ▶ Matplotlib y seaborn ya traen estas paletas y otras equivalentes (viridis, Set2, RdBu): basta nombrarlas.



El razonamiento visual es relativo


- ▶ La percepción opera comparando, no midiendo valores absolutos (ley de Weber).
- ▶ La precisión aumenta con una escala común y con los ítems alineados: por eso las barras comparten base.
- ▶ Evidencia experimental: Cleveland y McGill (1984), Journal of the American Statistical Association.



Ejemplos


Barras, áreas y tortas, a la luz de los canales

¿Qué comunica este gráfico?




Un buen ejemplo de lo que no se debe hacer: doce categorías, tramas, flechas y porcentajes anotados a mano. Los canales elegidos (ángulo, área, textura) no permiten comparar ni ordenar los valores. Fuente: Giga Research, filial de Forrester Research.

¿Qué comunica este gráfico?




Un buen ejemplo de lo que no se debe hacer: las 500 empresas del S&P 500 en una torta (Michael Batnick, 2018). Fuera de las cinco o seis tajadas mayores, ángulos y áreas son indistinguibles y las etiquetas ilegibles; la prensa lo difundió igual como un gráfico asombroso.

Barras: base común, comparación precisa




El eje alinea las barras sobre una base común y el largo codifica el valor: una barra del doble de largo representa el doble.

Áreas contra largos



El mismo dato (el valor de mercado de una empresa) codificado como área de un círculo y como largo de una barra: las proporciones se perciben con precisión distinta.


Tres tortas parecidas, tres distribuciones distintas




Los ángulos y las áreas no se comparan bien: estos gráficos de torta se ven similares, pero codifican distribuciones distintas. Las barras de abajo lo muestran de inmediato. Fuente: Wikipedia, Pie chart.

Cuándo sirve una torta

- ▶ Con pocas categorías y un mensaje único (una fracción contra el resto), un gráfico de torta comunica bien.
- ▶ La partición modal de la clase pasada, con nueve categorías, no es ese caso: por eso la mostramos con barras.
- ▶ Gráfico: xkcd 290.



Una visualización también puede ser una marca



En este mapa histórico, cada torta es una marca ubicada con el canal de posición: bien usadas, las visualizaciones circulares comunican sobre un mapa.

Recreo

15 minutos

EDA descriptivo


Dispersión, forma y calidad de una variable

Dónde estamos

- ▶ La clase pasada: resúmenes ponderados (media, mediana, cuantiles) y correlación sobre la EOD.
- ▶ Hoy completamos la descripción de una variable: dispersión, forma y valores atípicos, y el gráfico que resume todo eso: el boxplot.
- ▶ Y el paso previo a cualquier análisis: la calidad de los datos.
- ▶ **Explorar es trabajo estadístico serio, no un trámite previo (Tukey, 1977).**

Los datos de la clase: iris y la EOD

- ▶ **iris para aprender los conceptos; la EOD para aplicarlos a datos reales.**
- ▶ iris: 150 flores de tres especies, con el largo y el ancho del pétalo y del sépalo en centímetros. Publicado por Fisher (1936).
- ▶ Chico y ordenado: los resúmenes se pueden verificar a mano.
- ▶ La EOD ya la conocen: 113.591 viajes, con faltantes, colas y códigos.



Las tres especies

setosa



versicolor



virginica



Fotografías: Radomil, D. Gordon E. Robertson y Frank Mayfield, Wikimedia Commons, licencias CC BY-SA.

Cargar iris

```
from sklearn.datasets import load_iris
iris = load_iris()
iris_df = pd.DataFrame(iris.data, columns=iris.feature_names)
nombres = {0: "setosa", 1: "versicolor", 2: "virginica"}
iris_df["species"] = pd.Series(iris.target).map(nombres)
```

- Viene incluido en scikit-learn, así que no requiere descarga. La especie llega como códigos 0, 1 y 2; un diccionario los traduce con map().

iris_df: las primeras filas

sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	species
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
4.7	3.2	1.3	0.2	setosa
4.6	3.1	1.5	0.2	setosa
5.0	3.6	1.4	0.2	setosa
5.4	3.9	1.7	0.4	setosa


150 filas y 5 columnas: cuatro medidas numéricas y la especie como variable categórica.

Media, mediana y moda

Medida	Definición	iris: largo de sépalo	EOD: duración
Media	El promedio: la suma de los valores dividida por el número de datos.	5,84 cm	36,9 min
Mediana	El valor central: deja el 50% de los datos a cada lado.	5,80 cm	30 min
Moda	El valor más frecuente; el único resumen posible para variables cualitativas.	5,0 cm (10 flores)	30 min


Las cifras de la EOD son muestrales, sin ponderar; las ponderadas (34,7 y 25 minutos) las calculamos la clase pasada. La moda de 30 minutos delata que la gente declara tiempos redondeados.

Iris: el caso simétrico



En una distribución simétrica, media y mediana cuentan la misma historia.

La EOD: el caso asimétrico




Los ingresos de la clase pasada, ahora como contraste: la cola de ingresos altos arrastra la media; por eso el ingreso se reporta con la mediana.

Dispersión y forma


Cuánto varían los datos alrededor del centro

Percentiles y cuartiles



El percentil p es el valor bajo el cual queda el $p\%$ de los datos. Los cuartiles son los percentiles 25, 50 y 75: cortan los datos ordenados en cuatro partes con la misma cantidad de observaciones cada una.

Los cuartiles de la duración



Los mismos cortes en la EOD: cada tramo tiene la misma cantidad de viajes, pero anchos muy distintos. La asimetría, contada por los percentiles.

Medir la dispersión

Rango

$$\text{máx} - \text{mín}$$

simple, pero dominado por los extremos

Varianza

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Desviación estándar

$$s = \sqrt{s^2} \quad (\text{unidades originales})$$

iris: 0,83 cm · EOD: 36,1 min


IQR

$$IQR = Q_3 - Q_1 \quad (\text{el 50\% central})$$

EOD: de 15 a 50 min


Los percentiles completan el cuadro: $\text{quantile}([0, 0.25, 0.5, 0.75, 1])$ entrega el mínimo, los cuartiles y el máximo (en iris: 4,3 · 5,1 · 5,8 · 6,4 · 7,9).

El IQR en iris




Entre Q1 y Q3 queda el 50% central de las flores. El IQR es el ancho de ese tramo: $6,4 - 5,1 = 1,3$ cm.

El IQR en la duración




El 50% central de los viajes cabe en 35 minutos. La mitad central es angosta; lo que se estira es la cola, y al IQR eso no lo afecta.

La media no basta



Providencia y Talagante tienen la misma duración media de viaje (40,7 minutos), pero la desviación estándar de Talagante es el doble: dos realidades distintas detrás del mismo promedio.

El boxplot




Cinco números en un solo gráfico: mediana, cuartiles, bigotes y valores atípicos. La regla de los bigotes (1,5 veces el IQR) es una convención para marcar valores inusuales, no un veredicto.


Valores atípicos (outliers)

- ▶ **Un valor atípico es una observación que se aleja notoriamente del resto.**
- ▶ Convención de Tukey: fuera de $Q1 - 1,5 \cdot IQR$ y de $Q3 + 1,5 \cdot IQR$.
- ▶ Atípico no significa error: puede ser un caso real e informativo. Distinguirlo exige criterio del dominio.
- ▶ Es la decisión que declaramos la clase pasada con el viaje de 1.335 minutos: investigar, decidir y documentar.

iris: ancho de sépalo (150 flores)




EOD: duración del viaje



Otros criterios para marcar atípicos


- ▶ **La regla de Tukey es una convención entre varias; marcar no es eliminar.**
- ▶ Tres sigmas: distancia a la media, en desviaciones estándar.
- ▶ Z-score modificado: lo mismo, pero robusto, medido desde la mediana (Iglewicz y Hoaglin, 1993).
- ▶ Criterio del dominio: qué valores son posibles. El más defendible.

Boxplots para comparar grupos: iris



El largo del pétalo separa casi perfectamente a las tres especies: centros y dispersiones distintas en una sola figura.

Boxplots para comparar grupos: la EOD



La duración del viaje según el modo. En términos de la primera parte: la marca es la caja, y los canales son la posición (mediana y cuartiles) sobre una escala común.

Calidad y limpieza de datos

Los resúmenes valen lo que valen los datos


Valores faltantes

- ▶ Detección: `isna().sum()`, o el count de `describe()` contra `len`.
- ▶ En la EOD: `TiempoViaje` tiene 278 faltantes entre 113.591 viajes.
- ▶ **Un NaN no siempre es error: en los factores de expansión significa "no aplica".**
- ▶ Opciones: eliminar, imputar o dejar que cada cálculo los excluya. Lo obligatorio: decidir y documentar.

Duplicados

- ▶ `duplicate()` marca filas repetidas; `drop_duplicates()` las elimina.
- ▶ Dos niveles: la fila completa y la llave que debería ser única.
- ▶ En la EOD ambos chequeos dan cero; un cero también es un hallazgo.
- ▶ El riesgo típico ya lo conocen de los merges: una llave repetida en la tabla de parámetros multiplica filas.

Valores sospechosos



116 viajes declaran más de 5 horas y el máximo es de 22 horas. ¿Error de registro o viaje real? La respuesta exige criterio del dominio; la decisión (mantener, corregir o excluir) se toma en el código y se documenta.

Checklist de calidad antes de analizar

Revisión	Con qué
Dimensiones y tipos	shape, info()
Faltantes por columna relevante	isna().sum(), count contra len
Duplicados	duplicated(): fila completa y llave única
Rangos válidos de cada variable	min, max, describe(), valores sospechosos
Merges verificados	filas antes y después, NaN nuevos, llaves únicas

Se aplica siempre: hasta iris, con sus 150 filas, trae una fila duplicada. Cada decisión de limpieza queda escrita en el código, con su justificación.

Síntesis

- ▶ **Un gráfico es una elección: qué marca y qué canal codifican cada variable, y la percepción decide cuáles funcionan.**
- ▶ Efectividad y expresividad: canales de magnitud para lo cuantitativo, de identidad para lo categórico; posición y largo antes que área y color.
- ▶ El color se elige por tipo de dato: paleta secuencial con orden, divergente con centro, cualitativa para categorías.
- ▶ Describir una variable exige tres miradas: centro, dispersión (IQR, desviación) y forma (boxplot).
- ▶ La limpieza es parte del análisis: faltantes, duplicados y rangos válidos, con decisiones documentadas.

Referencias

Munzner, T. (2014). Visualization Analysis and Design. CRC Press. Capítulo 5, "Marks and Channels".
www.cs.ubc.ca/~tmm/vadbook/

Cleveland, W. S. y McGill, R. (1984). Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods. Journal of the American Statistical Association, 79(387), 531-554.

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

Fisher, R. A. (1936). The Use of Multiple Measurements in Taxonomic Problems. Annals of Eugenics, 7(2), 179-188.

Iglewicz, B. y Hoaglin, D. C. (1993). How to Detect and Handle Outliers. ASQC Quality Press.

Material de la primera parte adaptado del curso de Visualización de Información de D. Opitz (UDD, 2024), que incorpora láminas del curso de Denis Parra (PUC) y figuras del libro de Munzner.