

Regresión lineal

Clase 4 · Matriz de correlación, regresión simple, múltiple y ponderada

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · viernes 4 de septiembre, 2026

Contenidos de la clase

- ▶ 1. La matriz de correlación: todos los pares de una vez.
- ▶ 2. La primera regresión: mínimos cuadrados.
- ▶ 3. Muchos puntos y colas largas.
- ▶ 4. Regresión múltiple con statsmodels: R^2 y valor p.
- ▶ 5. Variables categóricas en la regresión: dummies.

El norte: los modelos

- ▶ En la clase 02 definimos el modelo: $Y = f(X) + \varepsilon$. Hoy, por primera vez, estimamos f .
- ▶ La correlación que ya conocen dice si dos variables se mueven juntas; la regresión dice cuánto.
- ▶ Y la regresión múltiple responde la pregunta que la correlación no puede: el efecto de cada variable con las demás fijas.

La matriz de correlación

Todos los pares de una vez


La correlación en Pandas

```
# Entre dos columnas (clase 02)
iris_df["petal length (cm)"].corr(iris_df["petal width (cm)"])
0.9629

# Lo nuevo: todas contra todas
iris_df.drop(columns="species").corr()
```


► `corr()` usa Pearson por defecto. En iris, largo y ancho del pétalo correlacionan

La matriz de correlación



Todos los pares de una vez: diagonal en 1 y matriz simétrica, dibujada con la paleta divergente de la clase pasada. El 0,96 entre largo y ancho del pétalo dice que son casi redundantes: evidencia para decidir qué variables entran a un modelo.

Siempre graficar: el cuarteto de Anscombe



Los cuatro conjuntos comparten medias, correlación y recta, y solo el primero es lo que el número sugiere. El resumen no reemplaza al gráfico.

El impacto de una sola fila

El impacto de una sola fila sobre la correlación (nubes de ejemplo)

Sin el punto extremo: $r = 0,21$



Con un solo punto extremo: $r = 0,82$



Cuarenta puntos sin relación ($r = 0,05$) y un solo punto extremo fabrican $r = 0,72$. La correlación de Pearson es tan sensible a los atípicos como la media.

¿Las comunas de menor ingreso viajan más tiempo?

La relación que queremos explicar en la primera parte: el ingreso del hogar y la duración media de los viajes, comuna por comuna, con las 45 comunas ponderadas por su factor

La tabla por comuna, ponderada

```
lab["w_ingreso"] = lab["Factor"] * lab["IngresoHogar"]
suma = lab.groupby("Comuna").sum()

# La media ponderada de la clase 02, ahora por comuna
suma["w_ingreso"] / suma["Factor"]
```

- Las conclusiones son sobre la ciudad, así que se pondera: cada media por comuna es suma de w por x , dividida por suma de w , con el factor del día laboral.


La tabla por comuna, construida

La tabla por comuna: una fila por comuna (45), medias ponderadas

Comuna	ingreso	duracion
BUIN	611.585	27.8
CALERA DE TANGO	609.312	39.7
CERRILLOS	578.683	34.8
CERRO NAVIA	457.759	36.0
COLINA	636.525	32.6


El resultado del groupby: 45 filas, una por comuna, con el ingreso y la duración como medias ponderadas. Esta tabla alimenta la primera recta.

Ingreso y duración, por comuna



Cada punto es una comuna (medias ponderadas por factor). La asociación es negativa ($r = -0,34$): las comunas de menor ingreso promedian viajes más largos. Providencia, 25 minutos; Puente Alto, 40.

La matriz de las comunas




Cuatro variables, seis pares (todo ponderado): el ingreso correlaciona fuerte con los vehículos (0,94), y el mejor acompañante de la duración no es el ingreso (-0,34) sino las personas por hogar (0,65).

La primera regresión

El primer modelo del curso

Mínimos cuadrados



La correlación mide la asociación; la regresión la dibuja: la recta que deja la menor suma de errores al cuadrado. La pendiente dice cuánto cambia y por cada unidad de x .

Las fórmulas de la recta


Mínimos cuadrados (OLS): la recta que minimiza la suma de los errores al cuadrado

$$b = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} \quad a = \bar{y} - b\bar{x}$$

b : la pendiente · a : el intercepto · x_i, y_i : los valores del caso i · $\bar{x}, \bar{y}$: sus medias


El método se llama mínimos cuadrados ordinarios (OLS): `np.polyfit` implementa exactamente esta fórmula, y `statsmodels` le agrega los diagnósticos que veremos hoy.

Pendiente e intercepto, dibujados



El intercepto es donde la recta corta el eje: el valor de y cuando x es 0. La pendiente es cuánto sube y por cada unidad de x . En nuestra recta: 38,3 minutos de base y -4,8 por cada millón de ingreso.

La recta: ingreso y duración



$\text{duración} = 38,3 - 4,8 \cdot \text{ingreso}$ (ponderada por factor): por cada millón adicional, la duración media baja casi 5 minutos. Y $r^2 = 0,12$: la recta captura el 12% de la variación; la asociación es real pero moderada, y así se reporta.

La recta en NumPy

```
# La recta  $y = a + b \cdot x$ : polyfit devuelve [b, a], en ese orden
pendiente, intercepto = np.polyfit(por_comuna["ingreso"],
                                   por_comuna["duracion"], 1)

ax.plot(x, intercepto + pendiente * x)
```

- polyfit ajusta un polinomio por mínimos cuadrados; el 1 pide grado 1, una recta. Es el único que haremos así: el resto de la clase usa statsmodels, que entrega los diagnósticos completos

Usar la recta: predecir y medir residuos

```
# El residuo e =  $y - (a + b \cdot x)$ : lo observado menos lo predicho  
prediccion = intercepto + pendiente * ingreso  
residuo = duracion - prediccion  
  
por_comuna.nlargest(5, "residuo")
```

- La Pintana viaja 13 minutos más de lo predicho y Santiago 7 menos: el residuo revela periferia y centralidad. ¿Azar? El valor p de hoy y la inferencia de la próxima clase responden

El intervalo de confianza de la pendiente

- ▶ La pendiente $-4,8$ salió de estas 45 comunas: otra muestra habría dado otro número. La estimación tiene ruido.
- ▶ statsmodels entrega el rango de pendientes compatibles con los datos: entre $-8,9$ y $-0,8$ minutos por millón.
 - El signo es sólido: todo el rango es negativo (por eso $p < 0,05$: el cero queda fuera).
 - La magnitud es imprecisa: el efecto va de 1 a 9 minutos por millón; la mejor estimación es 5.
- ▶ **El 95% describe al método, no a este intervalo: construido así, atrapa el valor verdadero en el 95% de las muestras. La próxima clase lo vemos en detalle.**

El impacto de sacar una fila

- ▶ **Medirlo: recalculamos cada resumen sin la fila, y comparar.**
- ▶ Sin Lo Barnechea, r casi no se mueve (sigue en $-0,34$), pero la pendiente cambia en un quinto: de $-4,8$ a $-5,8$ minutos por millón.
- ▶ Un mismo punto puede pesar poco en un resumen y mucho en otro: la decisión sobre los extremos (clase 03) también afecta al modelo.

La regresión con pesos: las fórmulas con factor de expansión

Con factores de expansión, cada término se pesa por su w_i

$$b_w = \frac{\sum_i w_i (x_i - \bar{x}_w)(y_i - \bar{y}_w)}{\sum_i w_i (x_i - \bar{x}_w)^2} \quad a_w = \bar{y}_w - b_w \bar{x}_w$$


w_i : el factor de expansión de la fila i · $\bar{x}_w, \bar{y}_w$: las medias ponderadas

La misma recta de mínimos cuadrados, con cada término pesado por su factor: cuando la conclusión es sobre la ciudad, la regresión también se pondera. En statsmodels se llama WLS (weighted least squares).

Muchos puntos y colas largas


Dos problemas al graficar los 90 mil viajes

Graficar 90 mil puntos: overplotting



Con todos los puntos sólidos, el scatter se satura y miente. Los remedios: transparencia (alpha), muestreo, o hexbin, donde el color cuenta los viajes (la distancia viene en DistanciaViaje.csv; sus -1 son faltantes disfrazados).

Cuándo usar escala logarítmica



La misma distancia tiene cola larga: en lineal se aplasta; en log, la forma aparece. Es la transformación de la clase pasada, ahora al servicio del modelo: vuelve lineales las relaciones multiplicativas.

Regresión múltiple

Varias variables a la vez, con statsmodels

La fórmula de la regresión múltiple

El mismo método de mínimos cuadrados, con varias variables a la vez

$$\hat{y} = a + b_1 x_1 + b_2 x_2 + \dots + b_k x_k$$

$\hat{y}$: el valor predicho · x_j : cada variable explicativa · b_j : cambio de $\hat{y}$ por unidad de x_j , con las demás constantes · a : intercepto

Cada coeficiente aísla el efecto de su variable: cuánto cambia la predicción por una unidad de esa x , manteniendo las demás constantes.

¿Cuántos vehículos tiene un hogar según su ingreso?

El modelo de partida, ponderado por el factor del hogar: $\text{vehículos} = 0,20 + 0,50 \cdot \text{ingreso}$ (18.264 hogares). ¿Qué variable agregamos, y cómo se decide?


Los datos: Hogares.csv

Hogares.csv: una fila por hogar (18.264)

Hogar	Comuna	IngresoHogar	NumVeh	NumPer	Factor
100010	BUIN	450.845	1	3	136.4
100020	BUIN	1.019.369	1	5	73.8
100030	BUIN	80.000	0	1	180.7
100041	BUIN	559.259	0	5	150.4
100052	BUIN	710.309	0	3	122.0

Las columnas de este modelo: el ingreso y el número de vehículos y de personas del hogar, con su factor de expansión y su comuna.

El mapa para elegir variables



La matriz de correlación como mapa: la fila de NumVeh manda. El ingreso (0,47) es el motor; las personas (0,13) son la única candidata con algo; las bicicletas casi nada (0,06) y redundantes entre sí (0,83). Decisión: agregar las personas.

La motorización, con dos variables

```
# Explicar los vehículos del hogar con el ingreso y las personas
X = sm.add_constant(pd.DataFrame({
    "ingreso": h["IngresoHogar"] / 1e6,
    "personas": h["NumPer"]}))
modelo = sm.WLS(h["NumVeh"], X, weights=h["Factor"]).fit()
```

- Ponderado con WLS: 0,48 vehículos por millón (era 0,50 a solas) y 0,03 por persona extra. El R^2 sube apenas, de 0,261 a 0,266: agregar variables no siempre aporta

El summary: los coeficientes y el valor p

	los coeficientes			el valor p		
	coef	std err	t	P> t	[0.025	0.975]
const	0.1058	0.011	9.537	0.000	0.084	0.128
ingreso	0.4839	0.006	75.243	0.000	0.471	0.496
personas	0.0330	0.003	10.725	0.000	0.027	0.039

coef es el modelo ajustado: de ahí sale la ecuación que sigue. $P>|t|$ responde, por variable: si en la ciudad el ingreso (o las personas) no tuviera efecto sobre los vehículos, ¿qué tan raro sería este coeficiente por azar de la muestra? Ambos dan 0,000.

La ecuación ajustada y su lectura

El modelo ajustado, con los números de los 18.264 hogares

$$\widehat{\text{vehículos}} = 0,106 + 0,484 \cdot \text{ingreso} + 0,033 \cdot \text{personas}$$

0,484: vehículos extra por cada millón de ingreso, con las personas fijas

0,033: vehículos extra por cada persona del hogar, con el ingreso fijo

0,106: el punto de partida (intercepto), con ingreso 0 y hogar de 0 personas

La fórmula de la múltiple con nuestros números: cada coeficiente se lee con las demás variables fijas.

Leer el modelo: R^2


Cuánta de la variabilidad de y explica el modelo

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

y_i : lo observado · $\hat{y}_i$: lo que predice el modelo · $\bar{y}$: la media de y · 0 = no explica nada, 1 = predice exacto

Nuestro 0,266: ingreso y personas explican un cuarto de la variabilidad de los vehículos entre hogares. Agregar variables nunca baja el R^2 ; por eso no basta con mirarlo.

Los coeficientes al agregar variables



El ingreso apenas se mueve (0,50 a 0,48) al agregar personas y bicicletas: es un efecto robusto. Las variables nuevas entran con coeficientes minúsculos y el R^2 casi no cambia.

¿De qué depende la duración de un viaje?

La distancia es la candidata natural (la correlación de la clase 02). Primera decisión: partir por ella, con los 102 mil viajes de la EOD


Los datos: viajes.csv y su distancia

viajes.csv + DistanciaViaje.csv: una fila por viaje (113.591)

Hogar	Viaje	TiempoViaje	DistEuclidiana	FactorLaboralNormal
173431.0	1734310202.0	70.0	5387.0	1.0
173441.0	1734410101.0	105.0	18841.0	1.1
173441.0	1734410102.0	90.0	18841.0	1.1
173441.0	1734410301.0	55.0	13392.0	1.1
173441.0	1734410302.0	150.0	13392.0	1.1


Del viaje usaremos la duración (minutos), la distancia (metros, desde DistanciaViaje.csv por la llave Viaje) y el factor del día laboral.

La misma regresión, tres veces




Decisión 1: transformar con log, porque las dos variables tienen cola larga y en log la nube se endereza: R^2 de 0,32 a 0,53. La distancia sola no basta.

El mapa, también para la duración



Primero el mapa. La distancia (en log) es el motor: 0,73. El ingreso da 0,00 por viaje: el -0,34 de la recta por comuna era entre promedios, y un promedio esconde a los individuos. Al modo, que es texto, el mapa no lo ve.

¿Qué más podría explicar la duración?



Las categóricas se miran con groupby: el modo sí importa, Bip! 62 min contra 15 de caminata. Pero Bip! también va más lejos (7,5 km contra 0,4): hay que comparar a igual distancia.

Decisión 2: agregar el modo

- ▶ **El modo es la candidata de mayor contraste y responde una pregunta de equidad: ¿cuánto más tarda un viaje según el modo, a igual distancia?**
- ▶ Comparar duraciones a secas mezcla el modo con la distancia; la regresión múltiple controla la distancia y aísla el modo.
- ▶ Como el modo es texto, no puede entrar tal cual a la fórmula: primero hay que convertirlo en números.

Una categórica, convertida en columnas 0/1

Antes: una columna de texto		Después: una columna 0/1 por modo (dummies)							
		<code>pd.get_dummies</code>							
Viaje	ModoAgrupado (texto)	➔	Auto (referencia)	Bip! (solo o comb.)	Caminata	Bicicleta	Taxi Colectivo	Taxi	Otros
1734510101	Auto		1	0	0	0	0	0	0
1734310202	Bip! (solo o combinado)		0	1	0	0	0	0	0
1734620301	Caminata		0	0	1	0	0	0	0
1001800101	Bicicleta		0	0	0	1	0	0	0
1735020302	Taxi Colectivo		0	0	0	0	1	0	0
1734710101	Taxi		0	0	0	0	0	1	0
1734620501	Otros		0	0	0	0	0	0	1

Cada viaje tiene un solo 1, en la columna de su modo. El auto es la referencia: su columna se saca y un viaje en auto queda con todo en 0.

El modo es texto y la fórmula solo suma números: `pd.get_dummies` crea una columna por categoría, y cada viaje tiene un solo 1, en la de su modo. Regla obligatoria: una categoría se saca y queda de referencia (aquí, el auto). Si entraran todas, las columnas sumarían siempre 1, igual que el intercepto, y el modelo no podría distinguir sus efectos.

Las dummies, en código

```
# Una columna 0/1 por modo; el auto queda de referencia
dummies = pd.get_dummies(viajes["ModoAgrupado"])
dummies = dummies.drop(columns=["Auto"])

# Explicar la duración (log) con la distancia (log) y el modo
```

- Las dummies se agregan a la X junto al log de la distancia. Cada coeficiente se lee comparado con la referencia: ese modo frente al auto, a igual distancia.

La ecuación de la duración, leída

El modelo ajustado, sobre los 102 mil viajes


$$\log_{10}(\text{duración}) = 1,15 + 0,37 \cdot \log_{10}(\text{dist}) + 0,27 \cdot \text{Bip!} + \dots$$

1,15: el intercepto, la referencia (un viaje en auto)

0,37: el coeficiente de la distancia (en log), el mismo para todos los modos

0,27 · Bip!: la dummy de Bip!, que vale 1 solo si el viaje es en Bip! y 0 si no

los puntos suspensivos son las dummies de los demás modos, cada una con su coeficiente

El modelo ajustado como ecuación: la distancia con su coeficiente y una dummy por modo con el suyo; el auto es la referencia y no lleva término.

El resultado: distancia y modo

$$\log_{10}(\text{duración}) \sim \log_{10}(\text{distancia}) + \text{modo} \cdot R^2 = 0,60$$

Modo (vs. auto)	Coeficiente	Tiempo, a igual distancia
Bip! (solo o combinado)	0,27	× 1,87
Otros	0,20	× 1,57
Taxi Colectivo	0,13	× 1,35
Bicicleta	0,07	× 1,16
Caminata	0,03	× 1,08
Taxi	0,01	× 1,03

A igual distancia, un viaje en Bip! tarda 1,87 veces lo que uno en auto; taxi y caminata quedan casi iguales al auto. El R^2 sube de 0,53 a 0,60.

Cómo se lee la dummy, con el logaritmo

La ecuación completa, y el mismo viaje de 5 km ($\log_{10} 5 = 0,70$) en auto y en Bip!

$$\log_{10}(\text{dur}) = 1,15 + 0,37 \cdot \log_{10}(\text{dist}) + 0,07 \cdot \text{Bici} + 0,27 \cdot \text{Bip!} + 0,03 \cdot \text{Cam} + 0,20 \cdot \text{Otros} + 0,01 \cdot \text{Taxi} + 0,13 \cdot \text{Colect}$$

En auto, todas las dummies valen 0:

$$\log_{10}(\text{dur}) = 1,15 + 0,37 \cdot 0,70 + 0,07 \cdot 0 + 0,27 \cdot 0 + 0,03 \cdot 0 + 0,20 \cdot 0 + 0,01 \cdot 0 + 0,13 \cdot 0 = 1,41$$

$$\text{dur} = 10^{1,41} = 25,6 \text{ min}$$

En Bip!, solo la dummy de Bip! vale 1:

$$\log_{10}(\text{dur}) = 1,15 + 0,37 \cdot 0,70 + 0,07 \cdot 0 + 0,27 \cdot 1 + 0,03 \cdot 0 + 0,20 \cdot 0 + 0,01 \cdot 0 + 0,13 \cdot 0 = 1,68$$

$$\text{dur} = 10^{1,68} = 47,8 \text{ min}$$

47,8 / 25,6 = 1,87 = $10^{0,27}$: sumar 0,27 en log es multiplicar el tiempo por 1,87

La regla para leer una dummy

- ▶ **El coeficiente de una dummy solo se considera si el viaje es en ese modo de transporte; si no, la dummy vale 0 y el término desaparece.**
- ▶ Como el modelo está en log, el coeficiente se suma al log, y sumar en log es multiplicar: $10 \text{ elevado a } 0,27 = 1,87$. Por eso los dos tiempos se dividen y no se restan.
- ▶ Lectura: un viaje en Bip! tarda 1,87 veces lo que uno en auto, a igual distancia.

Advertencia: el R^2 ajustado

R^2 ajustado = $1 - (1 - R^2) \cdot (n - 1) / (n - k - 1)$: descuenta cada variable extra

Modelo	n	k	R^2	R^2 ajustado
vehículos ~ ingreso	18.264	1	0,2613	0,2612
vehículos ~ ingreso + personas	18.264	2	0,2659	0,2658
vehículos ~ ingreso + personas + bicicletas	18.264	3	0,2672	0,2671
log duración ~ log distancia	102.223	1	0,5334	0,5334
log duración ~ log distancia + modo	102.223	7	0,6023	0,6023
el mismo 0,266 con pocos datos	30	3	0,2660	0,1813

El R^2 nunca baja al agregar variables; el ajustado descuenta cada una (en statsmodels, rsquared_adj). Con nuestros n es idéntico; con pocos datos, no. Para comparar modelos, el ajustado.

Síntesis

- ▶ **La regresión pone números a la asociación: cuánto cambia y por unidad de x ; la múltiple, con las demás variables fijas.**
- ▶ La matriz de correlación es el mapa para elegir variables; Anscombe recuerda que el número no reemplaza al gráfico.
- ▶ Cuando la conclusión es sobre la ciudad, la regresión se pondera: WLS con el factor de expansión.
- ▶ R^2 dice cuánto explica el modelo; el valor p , si un coeficiente se distingue del azar; las categóricas entran como dummies.
- ▶ El valor p y el intervalo de confianza se ven en detalle la próxima clase (inferencia).

Próxima clase

- ▶ **La Tarea 1 se entrega el jueves 10 de septiembre por Aula.**
- ▶ No hay clases el 11 (actividades de Fiestas Patrias) ni el 18 (vacaciones).
- ▶ Viernes 25 de septiembre: inferencia estadística (qué significa el valor p que statsmodels ya nos mostró), control Q2 (Cairo, Introducción + cap. 2) y entrega de la propuesta de proyecto.

Referencias

Anscombe, F. J. (1973). Graphs in Statistical Analysis. The American Statistician, 27(1), 17-21.

Seabold, S. y Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. Proceedings of the 9th Python in Science Conference.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Capítulo 5 (regresión lineal).

Datos: Encuesta Origen Destino Santiago 2012 (Sectra) e iris (Fisher, 1936).