Evaluar y regularizar modelos

Clase 7 · Umbral, curva ROC y AUC · Ridge y Lasso

Daniela Opitz
INF-396 · Departamento de Informática · UTFSM · viernes 23 de octubre, 2026

Avisos

- **El Control Q3 es el viernes 30 de octubre, al inicio de la clase: los informes de OpenAI y del AISI sobre los agentes que se salieron de sus evaluaciones. Las dos lecturas son de acceso libre y están enlazadas en el repositorio.**
- La Tarea 2 se entrega el viernes 13 de noviembre por Aula (fecha por confirmar); el enunciado se publica en el repositorio y se avisa por Aula.
- El avance de proyecto es opcional y se presenta el viernes 6 de noviembre: quienes lo presenten parten con 10 puntos de base.
- Las notas del Certamen 1 se publican por Aula.

Contenidos de la clase

- 1. Medir los dos errores de un clasificador: sensibilidad, especificidad y precisión.
- 2. Elegir el umbral según el costo de cada error.
- 3. Comparar clasificadores: la curva ROC y el AUC.
- 4. Muchas variables: qué dicen las correlaciones, el error en datos de prueba y el sobreajuste.
- 5. Regularizar: para qué sirve, Ridge y Lasso, y cómo elegir cuánto castigar.

¿Cuánto cuesta equivocarse?

- **La clase 06 dejó dos preguntas abiertas: si con un sí raro la exactitud engaña, ¿qué se mide? Y el umbral 0,5, ¿por qué 0,5?**
- El primer bloque las responde: medidas que miran cada error por separado, y un umbral que sale del costo de cada error.
- El segundo bloque vuelve a la regresión: con muchas variables, el modelo se ajusta al azar de su muestra y se equivoca más en datos nuevos. Regularizar lo corrige.
- El hilo de los dos: un modelo se juzga por sus errores donde importan, con el costo correcto y en datos que no vio.

Bloque 1 · Los dos errores de un clasificador

Continuación de la regresión logística de la clase 06: medir cada error, elegir el umbral y comparar modelos

El mapa de la clase

Un modelo se juzga por sus errores donde importan: con el costo correcto y en datos que no vio



clasificar: los clientes de la tarjeta

regresión: los salarios de béisbol

Recordatorio: los datos de la clase 06

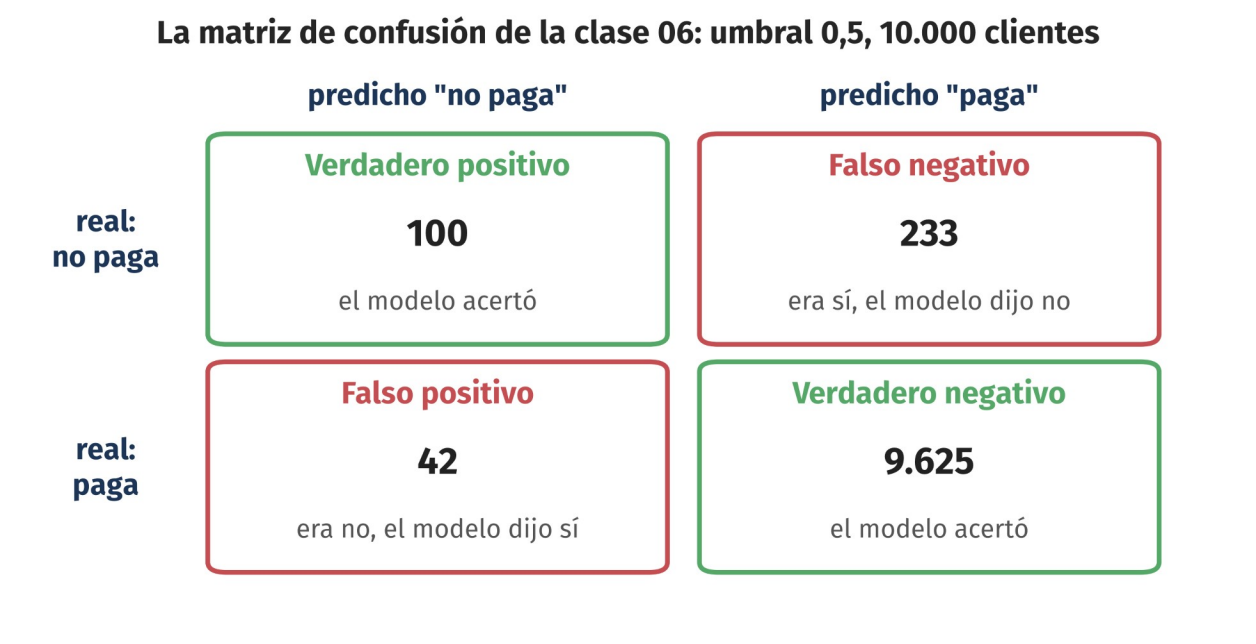
Los datos de la clase 06: 10.000 clientes de tarjeta de crédito (Default. James et al.)

cliente	default	student	balance	income	no_paga
0	No	No	730	44.362	0
1	No	Yes	817	12.106	0
2	No	No	1.074	31.767	0
3	No	No	529	35.704	0
136	Yes	Yes	1.487	17.854	1
173	Yes	Yes	2.206	14.271	1

default: si dejó de pagar (Yes o No) · student: si es estudiante · balance: deuda en la tarjeta. en dólares · income: ingreso anual. en dólares
no_paga: la columna que creamos en la clase 06. 1 si no pagó y 0 si pagó. Solo 333 de los 10.000 clientes no pagaron (3.3%): el sí es raro.

Datos del libro de James et al.: 10.000 clientes, su deuda en la tarjeta (lo que deben después del pago mensual), su ingreso anual y si son estudiantes. En la clase 06 ajustamos la regresión logística de no pagar según la deuda; solo 333 dejaron de pagar, y por eso la exactitud engaña.

Recordatorio: la matriz de confusión



Lo real en las filas, lo predicho en las columnas. Con umbral 0,5 acierta el 97,3%; decir que todos pagan, el 96,7%: la exactitud mezcla los dos errores. Aquí no se parte en entrenamiento y prueba: con una variable y 10.000 clientes da lo mismo (clase 06); con muchas variables no, y eso viene en el segundo bloque.

Sensibilidad: ¿cuántos morosos detecta?



Mira solo a los clientes que no pagan. Es la medida que importa cuando dejar pasar un sí es caro: un moroso sin detectar, una enfermedad sin diagnosticar.

Especificidad: ¿a cuántos deja en paz?

	predicho "no paga"	predicho "paga"
real: no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no
real: paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó

Especificidad

De los clientes que pagan, ¿qué fracción deja en paz?

Se mira la fila de los que pagan.

especificidad = VN / (VN + FP)

= 9.625 / (9.625 + 42) = 0,996

El modelo casi no molesta a los que pagan:
de cada 1.000, a 996 no los declara morosos.

Mira solo a los clientes que pagan. Importa cuando molestar a un no es caro: negarle la tarjeta a un buen cliente, alarmar a un paciente sano.

Precisión: de los que marca, ¿cuántos lo son?



Precisión

De los clientes que declara morosos, ¿qué fracción lo es?

Se mira la columna del predicho "no paga" (en inglés, precision).

precisión = VP / (VP + FP)

= 100 / (100 + 42) = 100 / 142 = 0,70

De cada 10 clientes que el modelo declara morosos, 7 lo son de verdad.

Mira solo a los clientes que el modelo declara morosos. Importa cuando actuar sobre cada sí cuesta: en el libro, una aseguradora que llama solo a los clientes que el modelo marca logra que compre el 33% de los llamados, contra el 6% llamando al azar (James et al., pp. 165 a 167).

Cuatro medidas, una sola matriz

medida	la pregunta que responde	fórmula	qué parte mira	umbral 0,5
Exactitud (accuracy)	De todos, ¿qué fracción acertó?	(VP + VN) / total	toda la matriz	**0,973**
Sensibilidad (recall)	De los que no pagan, ¿qué fracción detecta?	VP / (VP + FN)	la fila del sí	**0,30**
Especificidad	De los que pagan, ¿qué fracción deja en paz?	VN / (VN + FP)	la fila del no	**0,996**
Precisión (precision)	De los que declara morosos, ¿qué fracción lo es?	VP / (VP + FP)	la columna del sí	**0,70**

Todas salen de contar las celdas de la matriz. La exactitud mira todo junto; las otras tres miran un error por vez, y por eso no engañan cuando el sí es raro.

El mapa de la clase

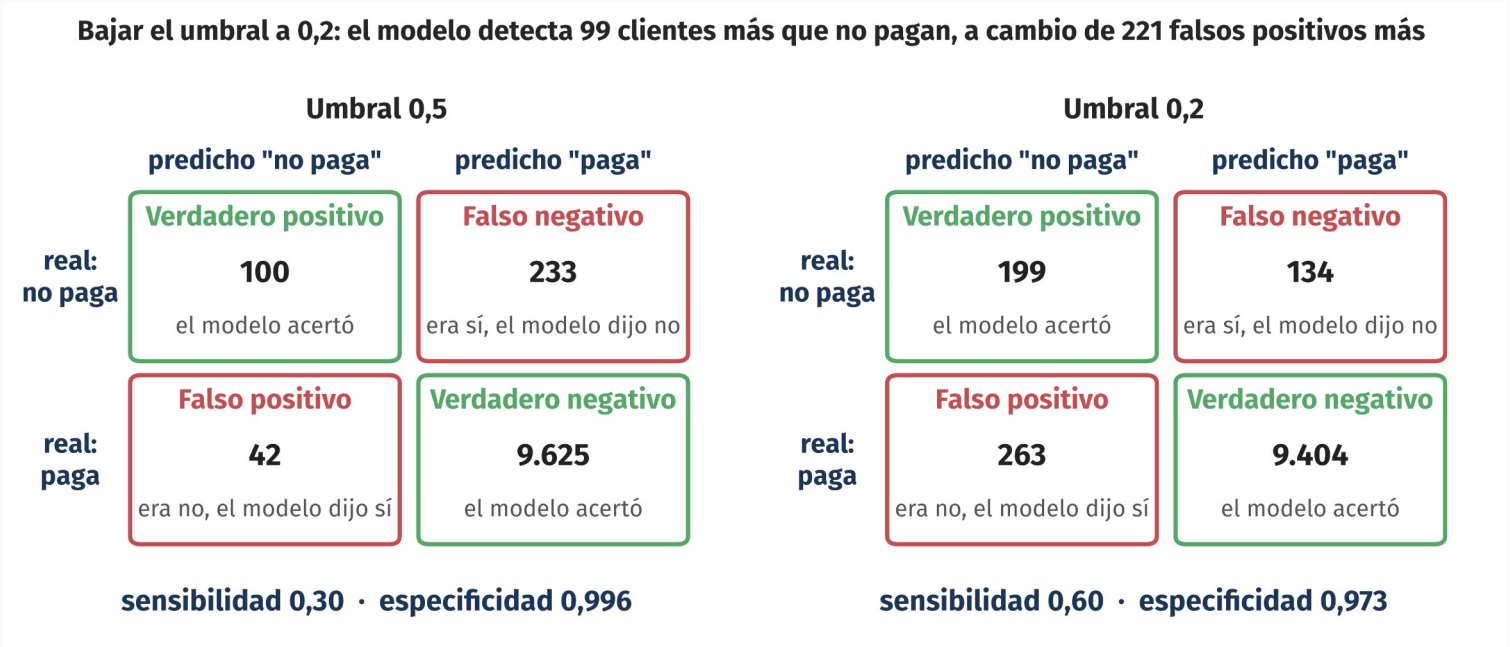
Un modelo se juzga por sus errores donde importan: con el costo correcto y en datos que no vio



clasificar: los clientes de la tarjeta

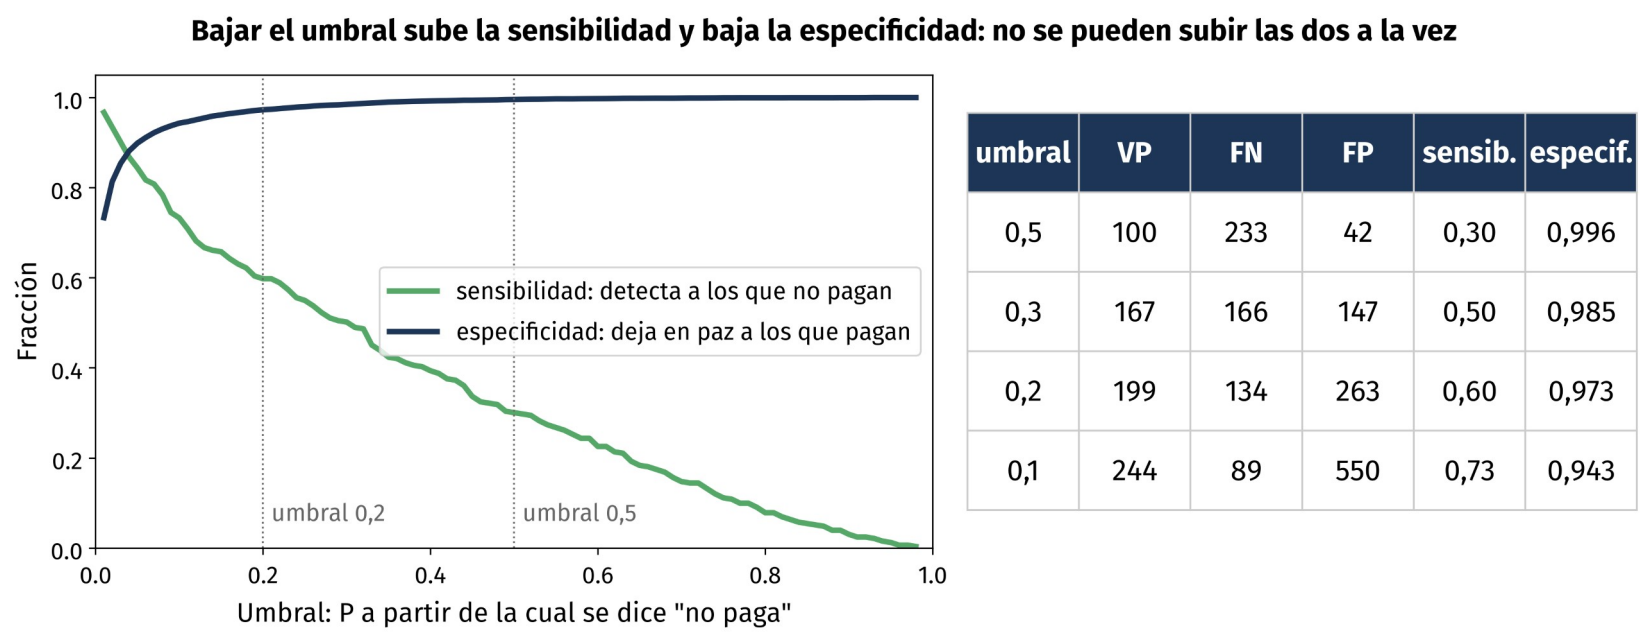
regresión: los salarios de béisbol

Mover el umbral cambia los errores



El modelo es el mismo: solo cambia desde qué probabilidad se dice "no paga". Con 0,2 se detectan 199 morosos en vez de 100, y se molesta a 263 buenos clientes en vez de 42.

Sensibilidad y especificidad según el umbral



umbral	VP	FN	FP	sensib.	especif.
0,5	100	233	42	0,30	0,996
0,3	167	166	147	0,50	0,985
0,2	199	134	263	0,60	0,973
0,1	244	89	550	0,73	0,943

Cada umbral es un balance entre los dos errores. ¿Cuál elegir? Depende de cuánto cuesta cada error, y eso no lo dice el modelo: lo dice el problema.

El costo de cada error

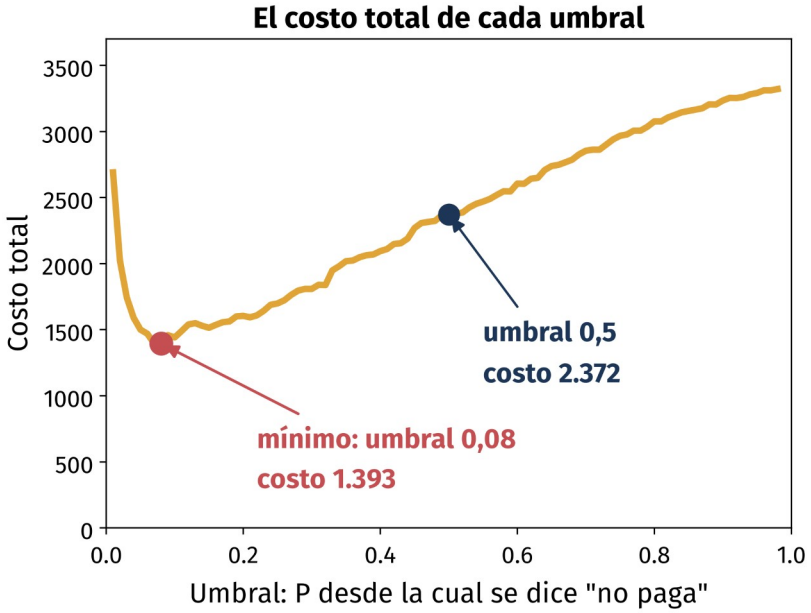
Supuesto: los dos errores no cuestan lo mismo

Falso negativo: darle la tarjeta a quien no paga
cuesta 10

Falso positivo: negársela a quien sí paga
cuesta 1

costo total = 10 · FN + 1 · FP

umbral 0,5: 10 · 233 + 42 = 2.372
umbral 0,08: 10 · 72 + 673 = 1.393



Con estos costos, el umbral 0,5 no es el mejor: el costo total baja de 2.372 a 1.393 con umbral 0,08. Los costos son un supuesto: los define el problema, no el modelo.

Cliente por cliente: ¿aprobar o rechazar?

P: la probabilidad de no pagar que el modelo le da al cliente. Cada decisión tiene un costo esperado

aprobar: pierde 10 si el cliente no paga (probabilidad P) **costo esperado = 10 · P**

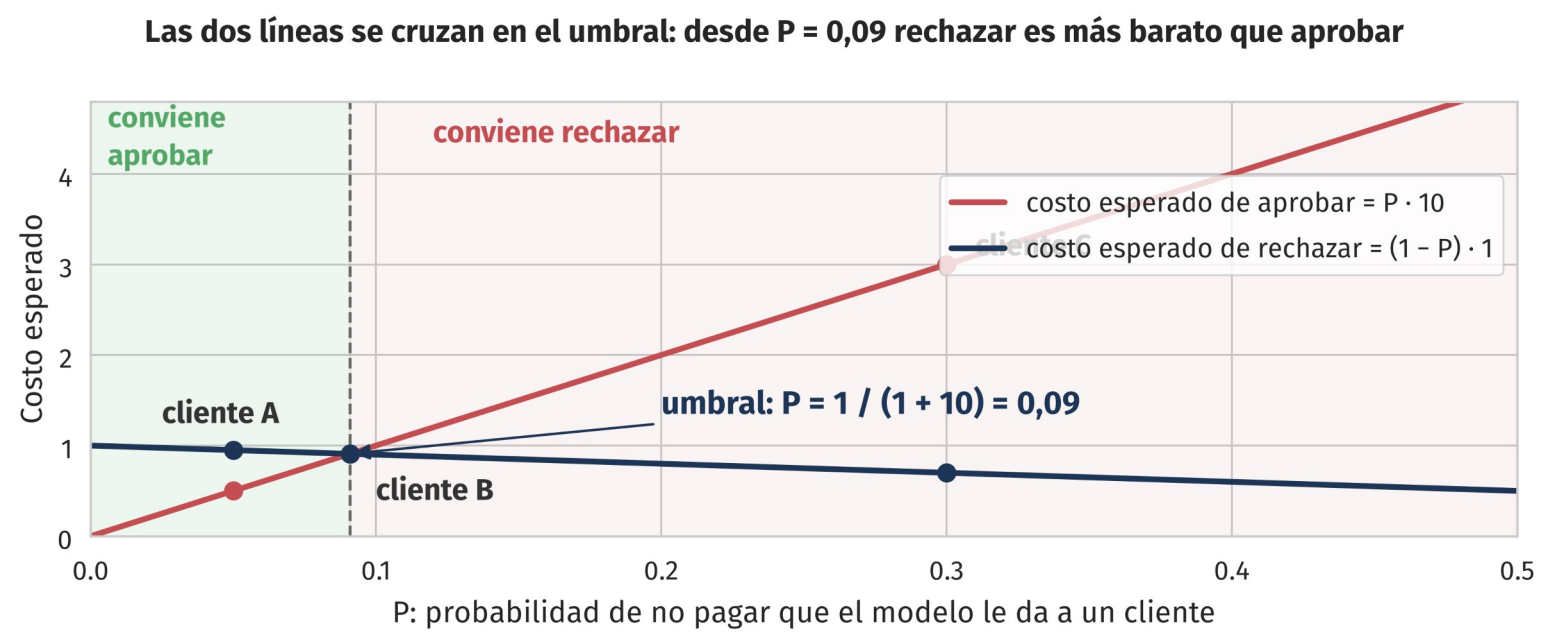
rechazar: pierde 1 si el cliente iba a pagar (probabilidad 1 − P) **costo esperado = (1 − P) · 1**

cliente	P del modelo	aprobar: 10 · P	rechazar: (1 − P) · 1	conviene
A	0,05	**0,50**	0,95	aprobar
B	0,09	**0,91**	**0,91**	da lo mismo
C	0,30	3,00	**0,70**	rechazar

Se elige la decisión más barata para cada cliente: al A conviene aprobarlo, al C rechazarlo, y con el B da lo mismo. Ese P del cliente B es el umbral.

El umbral de menor costo

El umbral según los costos
FP / (FP + FN)



Las mismas cuentas para todos los P posibles. El umbral es el P del cliente B, donde aprobar y rechazar cuestan lo mismo: 1 / (1 + 10) = 0,09. Con costos iguales, las líneas se cruzarían en 1 / (1 + 1) = 0,5: por eso 0,5 es el umbral por defecto.

De dónde sale la regla del umbral

De dónde sale la regla del umbral: igualar los dos costos y despejar P

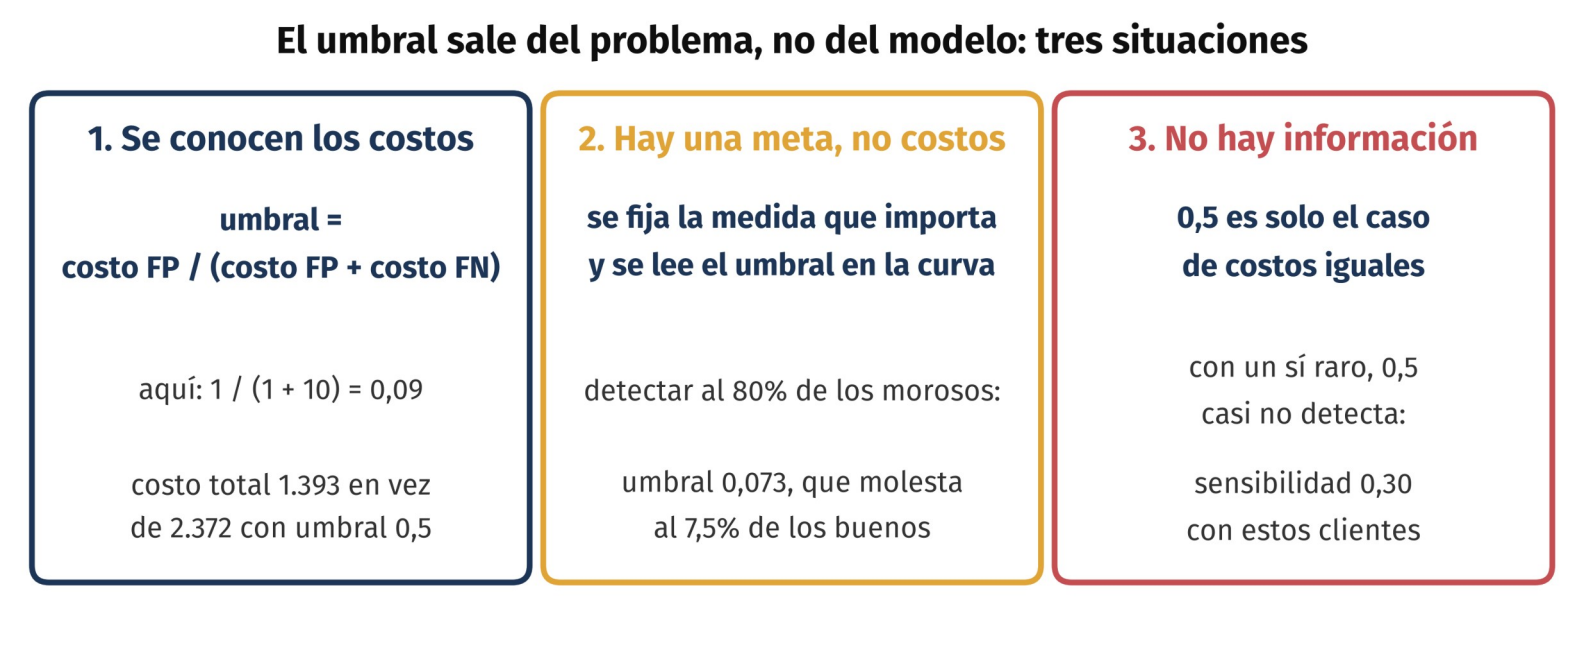
El umbral es la P en que aprobar y rechazar cuestan lo mismo. Se igualan los dos costos y se despeja P:

	en general	con costo FN = 10 y costo FP = 1
1. se igualan los dos costos	$(1-P)\cdot \text{costo FP} = P\cdot \text{costo FN}$	$(1-P)\cdot 1 = P\cdot 10$
2. se multiplica el paréntesis	$\text{costo FP} - P\cdot \text{costo FP} = P\cdot \text{costo FN}$	$1 - P = 10P$
3. los términos con P, a la derecha	$\text{costo FP} = P\cdot \text{costo FN} + P\cdot \text{costo FP}$	$1 = 10P + P$
4. P de factor común	$\text{costo FP} = P\cdot (\text{costo FN} + \text{costo FP})$	$1 = 11P$
5. se despeja P	$P = \dfrac{\text{costo FP}}{\text{costo FP} + \text{costo FN}}$	$P = \dfrac{1}{11} = 0{,}09$

Sobre esa P, aprobar cuesta más que rechazar: se rechaza. Bajo esa P, se aprueba. Con costos iguales, P = 1 / 2 = 0,5.

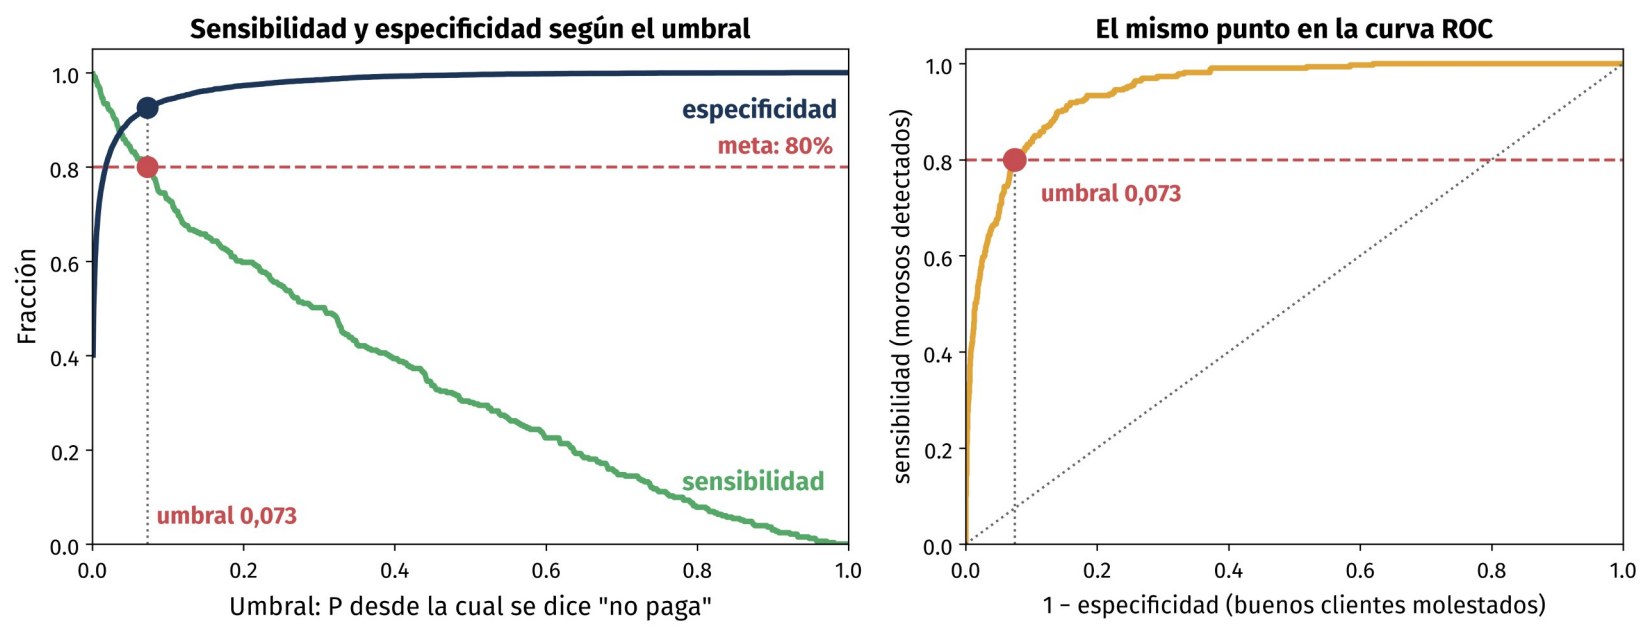
Cinco pasos de álgebra: igualar el costo de aprobar con el de rechazar y despejar P. Con 10 y 1 da 1 / 11 = 0,09; con costos iguales, 0,5.

Cómo elegir el umbral, en resumen



Con costos, la regla; con una meta, la curva de sensibilidad y especificidad; sin información, 0,5, sabiendo que es el caso de costos iguales y que con un sí raro detecta poco.

Con una meta: leer el umbral en la curva



Meta: detectar al 80% de los morosos. La curva da el umbral, 0,073, y el precio: molestar al 7,5% de los buenos. En la ROC es el mismo punto: detrás de cada punto hay un umbral.

El mapa de la clase

Un modelo se juzga por sus errores donde importan: con el costo correcto y en datos que no vio



Cómo elegir entre dos modelos

Los tres modelos de la clase 06 para predecir quién no paga, ajustados con los 10.000 clientes

Modelo 1: con la deuda

log odds(no paga) = -10,65 + 0,55 · deuda

deuda en cientos de dólares; e^0,55 = 1,73; P distinta para cada cliente

Modelo 2: solo estudiante

log odds(no paga) = -3,50 + 0,40 · estudiante

estudiante vale 1 o 0; P toma solo dos valores: 2,9% o 4,3%

Modelo 3: deuda y estudiante

log odds(no paga) = -10,75 + 0,57 · deuda − 0,71 · estudiante

con la deuda fija, ser estudiante baja los odds: e^-0,71 = 0,49

Los tres se comparan con el mismo umbral, 0,5: cada modelo dice "no paga" cuando su P es 0,5 o más.

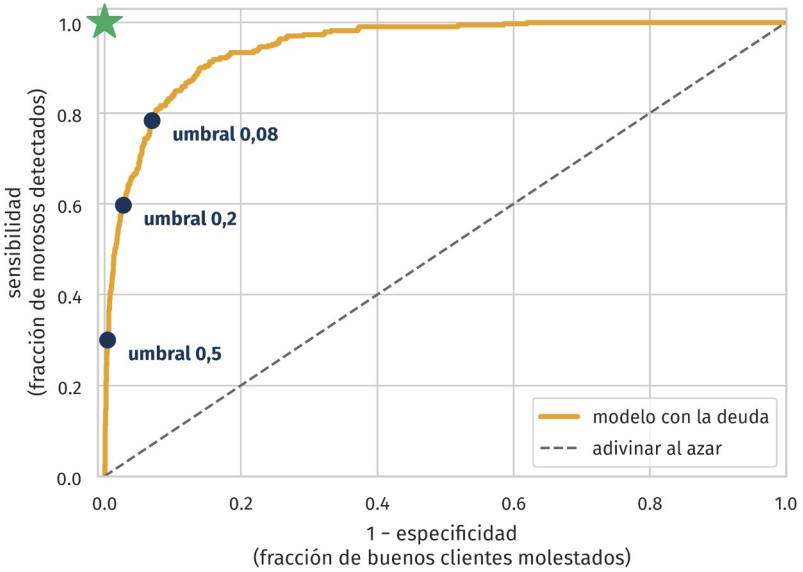
con umbral 0,5	sensibilidad (morosos detectados)	especificidad (buenos clientes en paz)
modelo 1: con la deuda	0,30	0,996
modelo 2: solo estudiante	0	1
modelo 3: deuda y estudiante	0,32	0,996

Con un solo umbral no se puede decidir: el 1 detecta más, el 2 molesta menos y el 3 se parece al 1. Hay que mirar todos los umbrales.

Los tres modelos de la clase 06. Antes de elegir el umbral hay que elegir el modelo, y a veces los costos todavía no se conocen: hay que compararlos con todos los umbrales.

La curva ROC: todos los umbrales a la vez

La curva ROC: cada umbral es un punto, con los morosos que detecta y los buenos clientes que molesta



Cada umbral es un punto de la curva:

umbral	sensibilidad (detectados)	1 – especificidad (molestados)
0,5	0,30	0,004
0,2	0,60	0,027
0,08	0,78	0,070

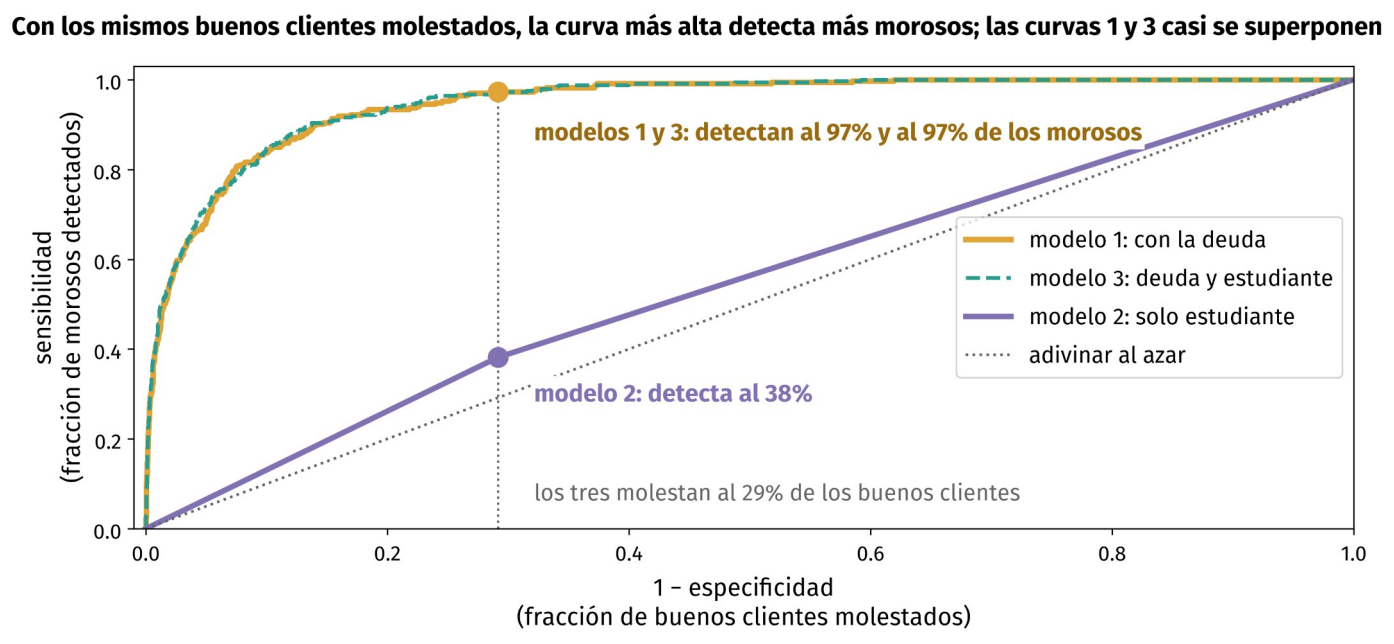
Bajar el umbral sube por la curva: más morosos detectados, pero más buenos clientes molestados.

La estrella verde es lo ideal: detectar a todos sin molestar a nadie. La diagonal es adivinar.

Mientras más se acerca la curva a la estrella, mejor separa el modelo.

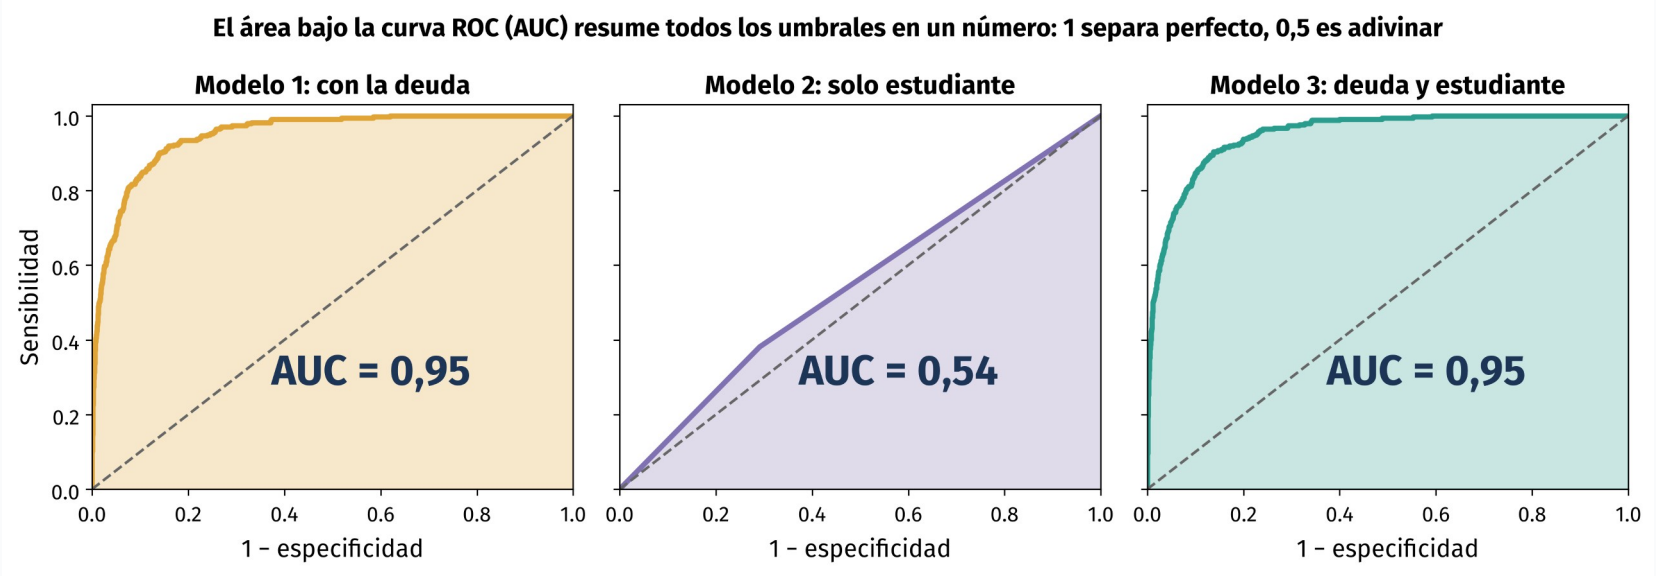
La curva muestra lo que el modelo puede ofrecer con cualquier umbral: cuántos morosos detecta a cambio de cuántos buenos clientes molesta. Sirve para juzgar el modelo antes de elegir el umbral.

Tres modelos, tres curvas



El modelo 2 solo distingue estudiantes de no estudiantes, por eso su curva tiene un solo quiebre: rechazar a todos los estudiantes. Las curvas de la deuda van siempre por encima, con cualquier umbral y sin importar los costos; agregar estudiante a la deuda casi no mueve la curva.

El AUC: la comparación en un número



Mientras más alta la curva, mayor el área. El AUC se lee así: si se toma al azar un cliente que no paga y uno que paga, el modelo de la deuda le da más probabilidad al que no paga en el 95% de los pares; el de estudiante, en el 54%, casi como adivinar. Sumar estudiante a la deuda apenas cambia el AUC.

Síntesis del bloque 1

- **Con un sí raro la exactitud engaña: sensibilidad, especificidad y precisión miden un error por vez.**
- El umbral no es 0,5 por naturaleza: es el P donde aprobar y rechazar cuestan lo mismo, costo FP / (costo FP + costo FN). Con costos iguales, 0,5.
- La curva ROC muestra lo que el modelo ofrece con todos los umbrales; el AUC lo resume en un número y permite comparar modelos antes de conocer los costos.
- En el notebook: secciones 2 a 6, con los mismos clientes de la clase 06.

Recreo

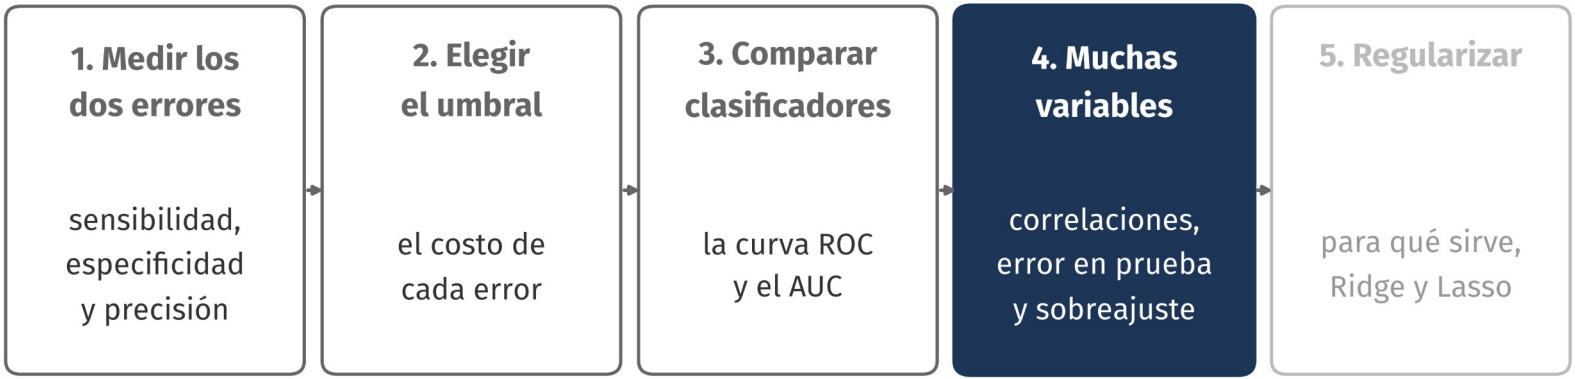
15 minutos · al volver: una regresión con 19 variables

Bloque 2 · Muchas variables y cómo regularizar

Primero el problema: un modelo que se ajusta al azar de su muestra; después el remedio: Ridge y Lasso

El mapa de la clase

Un modelo se juzga por sus errores donde importan: con el costo correcto y en datos que no vio



Otro problema: el salario de jugadores de béisbol

jugador	salario	temporadas	turnos	hits	jonrones	turnos_ carrera	hits_ carrera
1	475,0	14	315	81	7	3.449	835
2	480,0	3	479	130	18	1.624	457
3	500,0	11	496	141	20	5.628	1.575
4	91,5	2	321	87	10	396	101
5	750,0	11	594	169	4	4.408	1.133

263 jugadores y 19 variables; la tabla muestra 7. El salario es lo que queremos predecir.

263 jugadores de las grandes ligas, su salario de 1987 y 19 variables de la temporada 1986 y de su carrera (James et al.). La respuesta es un número: volvemos a la regresión lineal.

Las variables de bateo de la temporada 1986

Las seis variables de bateo de la temporada 1986, con los valores del jugador 1

variable	qué cuenta, en la temporada 1986	jugador 1
turnos	veces que fue a batear	315
hits	veces que golpeó la pelota y llegó a una base	81
jonrones	batazos que sacaron la pelota del campo: anota de una vez	7
anotadas	carreras que anotó: completó la vuelta y llegó a home	24
impulsadas	carreras de sus compañeros gracias a un batazo suyo	38
bases_bolas	veces que avanzó a primera base sin batear	39

Seis cuentas de lo que hizo el jugador al batear durante 1986.

Las mismas cuentas, en toda la carrera

Las mismas seis cuentas, sumadas en toda la carrera del jugador

temporada 1986	jugador 1	toda la carrera	jugador 1
turnos	315	**turnos_carrera**	3.449
hits	81	**hits_carrera**	835
jonrones	7	**jonrones_carrera**	69
anotadas	24	**anotadas_carrera**	321
impulsadas	38	**impulsadas_carrera**	414
bases_bolas	39	**bases_bolas_carrera**	375

temporadas: años en las grandes ligas (el jugador 1 lleva 14). Con más temporadas, más de todo en la carrera.

Siete variables más: las temporadas en las grandes ligas y los seis totales acumulados.

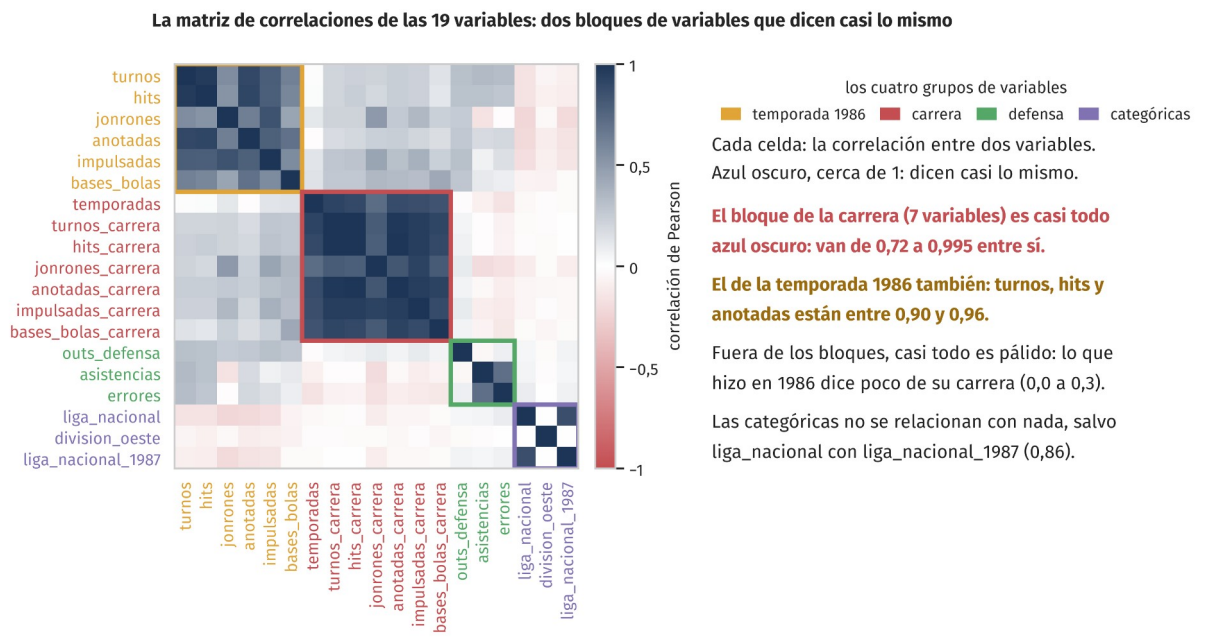
Defensa, categóricas y la respuesta

Las tres variables de defensa, las tres categóricas y la respuesta

variable	qué cuenta, en la temporada 1986	jugador 1
outs_defensa	rivales que eliminó cuando su equipo defendía	632
asistencias	jugadas en que ayudó a eliminar a un rival	43
errores	jugadas en defensa que falló	10
liga_nacional	1 si jugó en la Liga Nacional, 0 si en la Americana	1
division_oeste	1 si su equipo era de la división Oeste, 0 si de la Este	1
liga_nacional_1987	la misma variable de liga, pero al empezar 1987	1
salario	lo que queremos predecir: miles de dólares en 1987	**475,0**

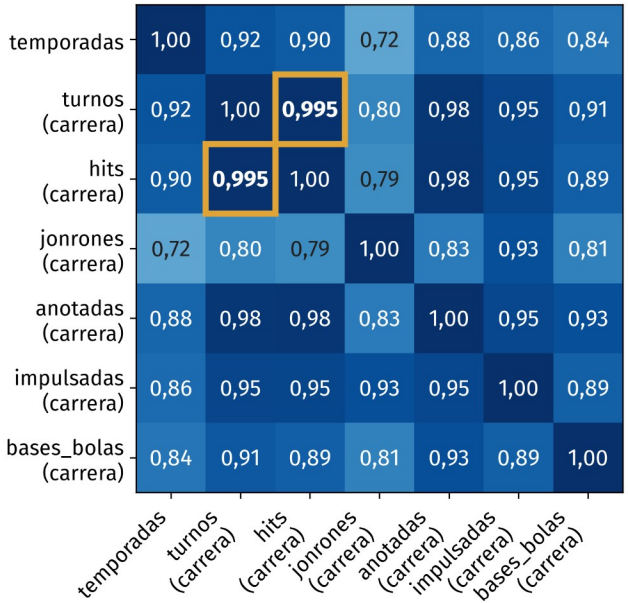
Con estas se completan las 19 variables. El salario es lo que el modelo debe predecir.

¿Qué variables dicen lo mismo?



Dos bloques oscuros: las seis de la temporada 1986 entre sí, y las siete de la carrera entre sí. Entre bloques, casi nada.

Multicolinealidad entre las variables de la carrera



Las siete variables de la carrera miden, en el fondo, lo mismo: cuánto ha jugado cada jugador.

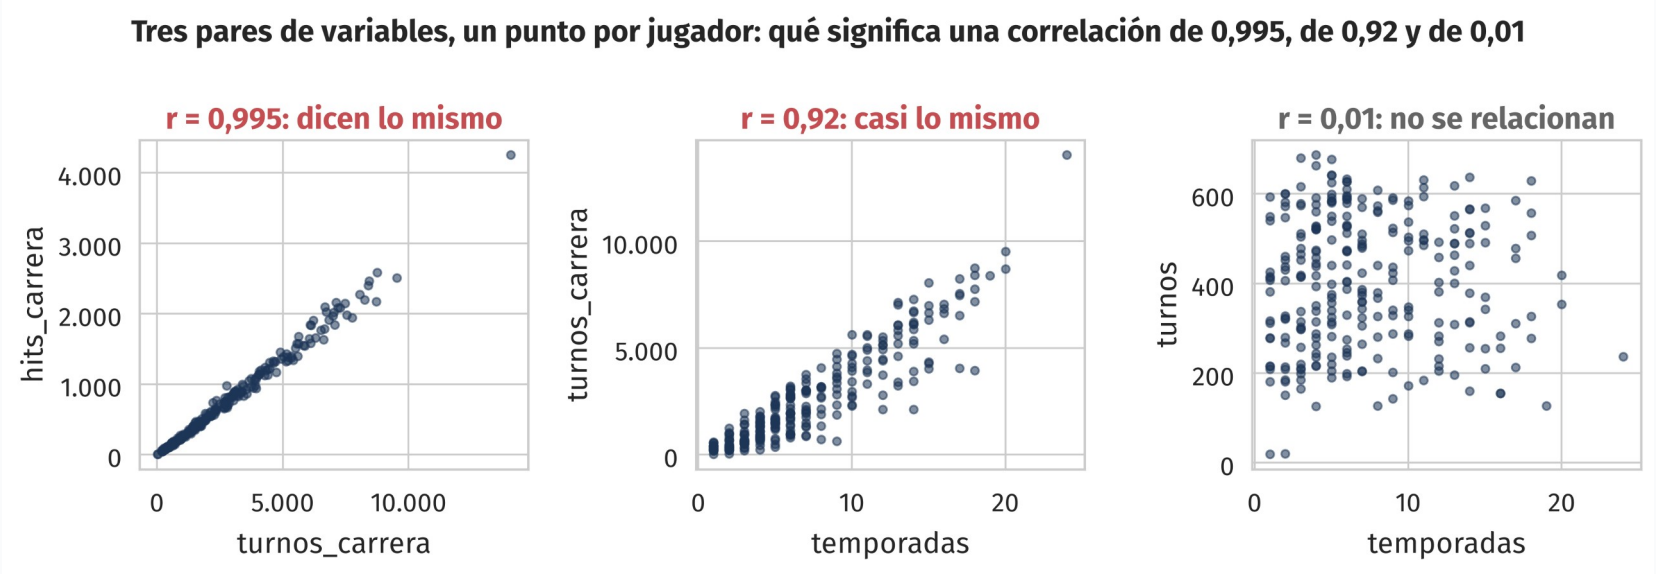
Con más temporadas se acumulan más turnos, más hits y más carreras: las correlaciones van de 0,72 a 0,995.

Turnos y hits de la carrera correlacionan 0,995: saber una es saber la otra.

Esto se llama multicolinealidad, y es un problema para el modelo: si dos variables dicen lo mismo, no hay cómo repartir el mérito entre ellas.

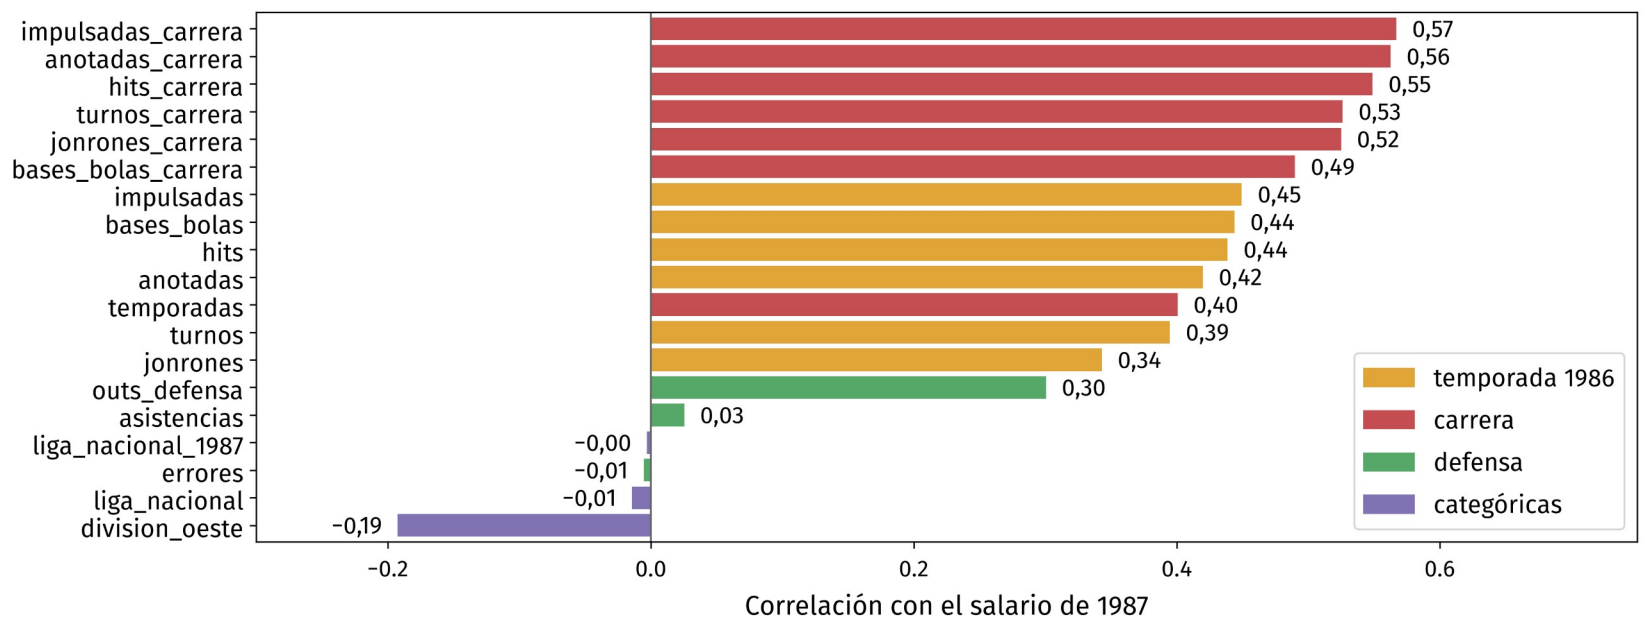
Las siete variables de la carrera están fuertemente correlacionadas entre sí, de 0,72 a 0,995. Esa multicolinealidad es la que volverá inestables los coeficientes de mínimos cuadrados.

Tres pares de variables, jugador por jugador



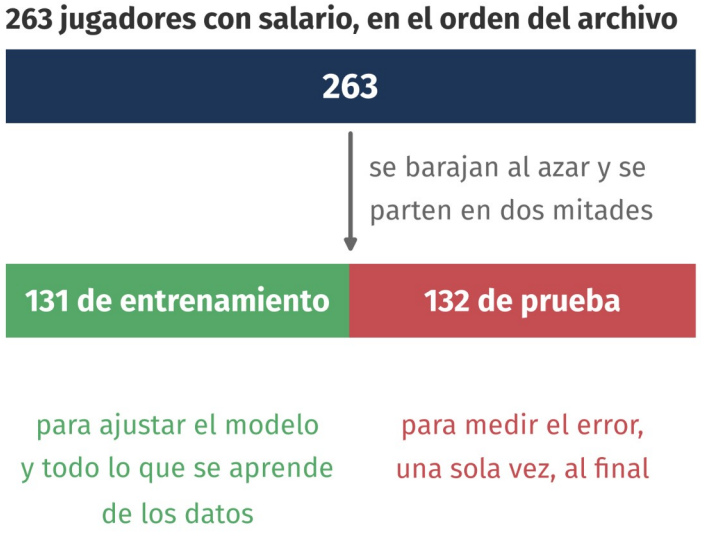
Con correlación 0,995, saber una variable es saber la otra: el modelo no tiene cómo repartir el mérito entre las dos.

¿Y con el salario?



Ninguna variable sola explica el salario. Las más relacionadas son las de la carrera: justo las que dicen lo mismo entre sí.

Entrenamiento y prueba: por qué se parte



El modelo se ajusta a los jugadores que ve, con el azar de esa muestra incluido.

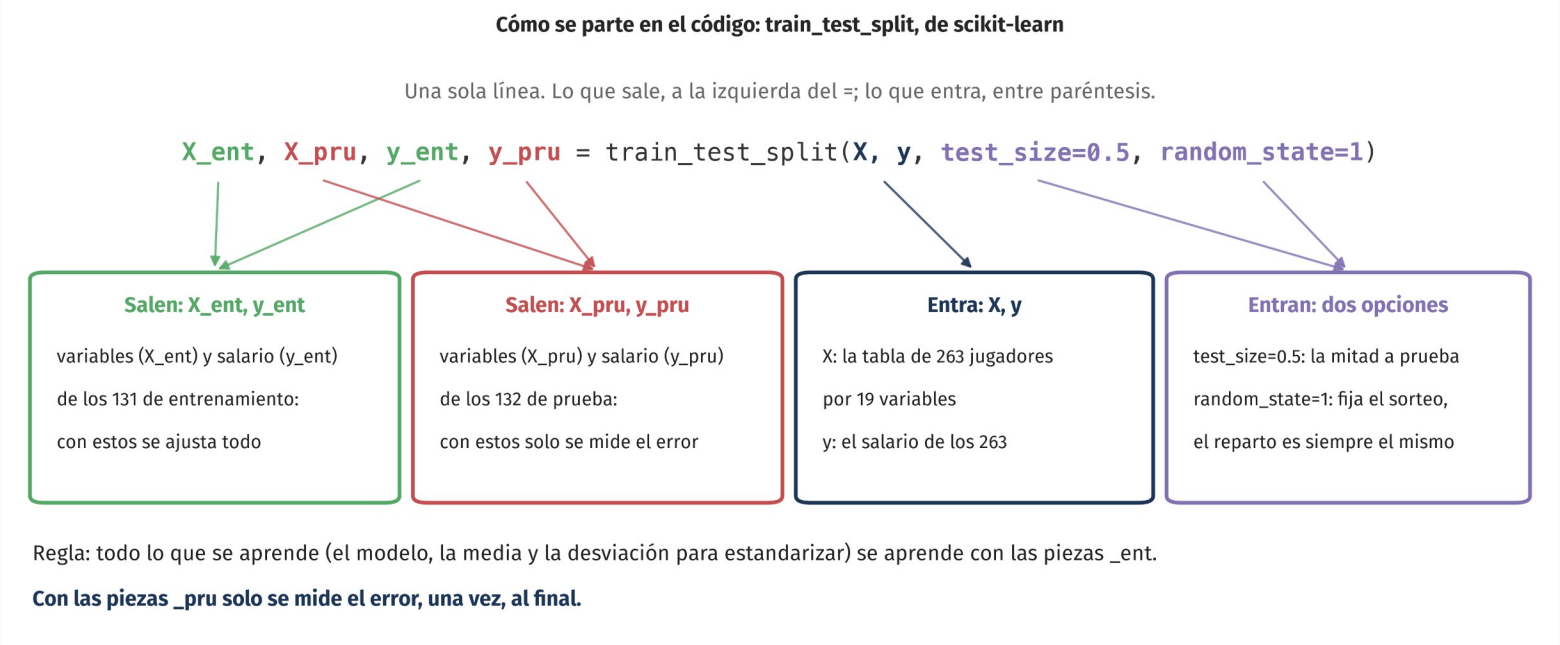
Si el error se midiera con esos mismos jugadores, saldría optimista: ya los vio.

Por eso se aparta una mitad antes de ajustar. El error que vale es el que se mide ahí.

La prueba no se toca hasta el final: ni para ajustar, ni para ninguna decisión del modelo.

Se barajan los 263 y se parten en dos mitades antes de ajustar nada: 131 para ajustar y 132 para medir. La prueba no se toca hasta el final.

Cómo se parte en el código



Entra la tabla X y el salario y; salen cuatro piezas, dos de entrenamiento y dos de prueba. En el notebook, esta línea abre la sección 8.

El error de una regresión: el RMSE

El RMSE: la raíz del promedio, sobre los jugadores, de los residuos al cuadrado

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

y_i	el salario real del jugador i
$\hat{y}_i$	el salario que el modelo predice para el jugador i
$y_i - \hat{y}_i$	el residuo: cuánto se equivocó el modelo con ese jugador
$(y_i - \hat{y}_i)^2$	el residuo al cuadrado: así los errores hacia arriba y hacia abajo no se cancelan
$\frac{1}{n}\sum_{i=1}^{n}$	el promedio sobre los n jugadores: se suman los n cuadrados y se divide por n
$\sqrt{\cdots}$	la raíz, para volver a miles de dólares

El RMSE es el tamaño típico del error del modelo, en miles de dólares, como el salario.

Como en la clase 06: 131 jugadores para ajustar y 132 de prueba, y el error se mide con los de prueba, que el modelo no vio.

El RMSE paso a paso

El RMSE paso a paso, con cinco jugadores de prueba y el modelo de mínimos cuadrados (salarios en miles de dólares)

jugador	salario real y	predicho $\hat{y}$	residuo $y - \hat{y}$	residuo² $(y - \hat{y})^2$
1	500	620	−120	**14.400**
2	700	315	385	**148.225**
3	700	753	−53	**2.809**
4	210	492	−282	**79.524**
5	105	341	−236	**55.696**
			suma	**300.654**

1. Promedio de los residuos al cuadrado:

300.654 / 5 = 60.131

la suma de la tabla, dividida por los 5 jugadores

2. Raíz, para volver a miles de dólares:

RMSE = √60.131 = 245

Con los 132 jugadores de prueba: RMSE = 342

Sin modelo, prediciendo siempre el salario medio: 416

El modelo se equivoca típicamente en 342 mil dólares.

Con los 132 jugadores de prueba, el error típico del modelo es de 342 mil dólares; sin modelo, de 416 mil.

Estandarizar las variables

jugador	temporadas	turnos carrera	temporadas (z)	turnos carrera (z)
1	17	4.061	2,01	0,62
2	11	5.562	0,75	1,27
3	5	2.364	-0,50	-0,11
media	**7,4**	**2.625**	**0**	**0**
desv. estándar	**4,8**	**2.313**	**1**	**1**

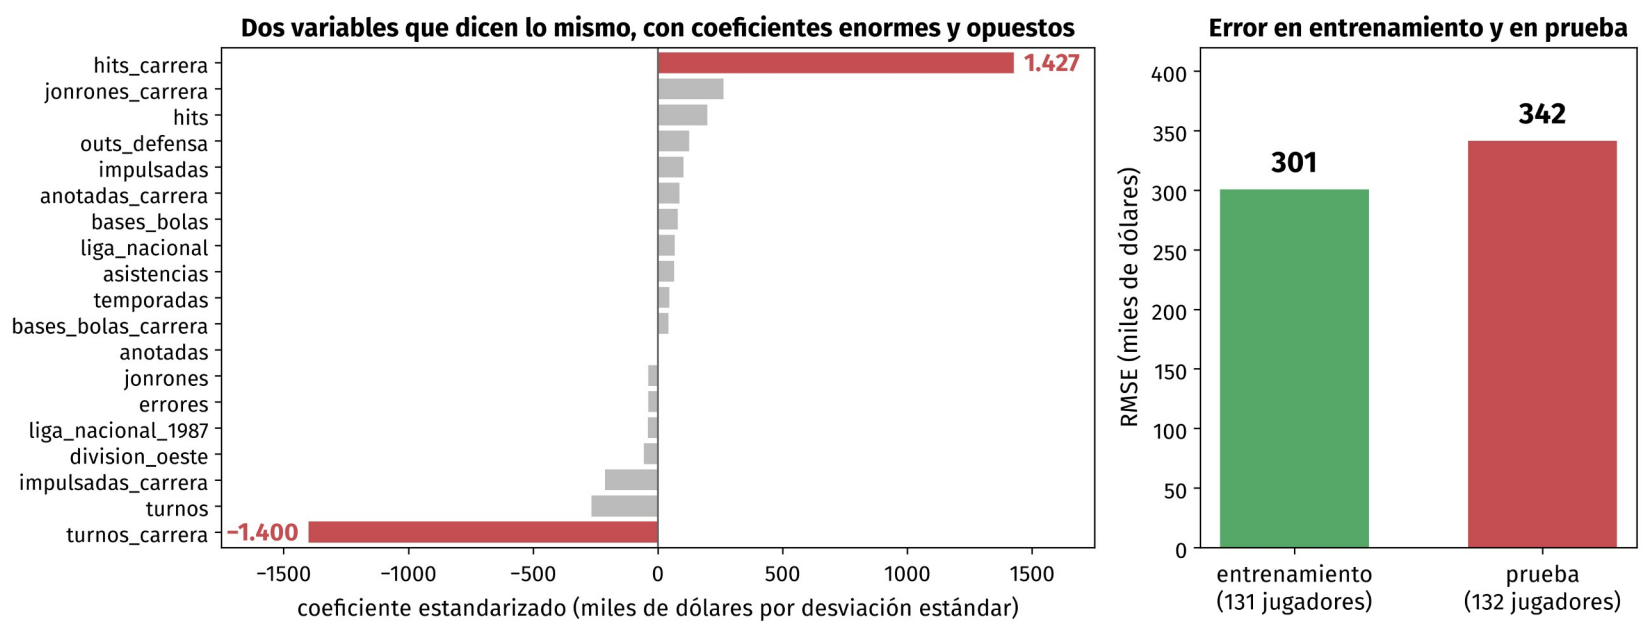
$$z = \frac{x - \text{media}}{\text{desviación estándar}}$$

Todas quedan con media 0 y desviación 1: los coeficientes se pueden comparar.

La media y la desviación salen del entrenamiento, también para la prueba.

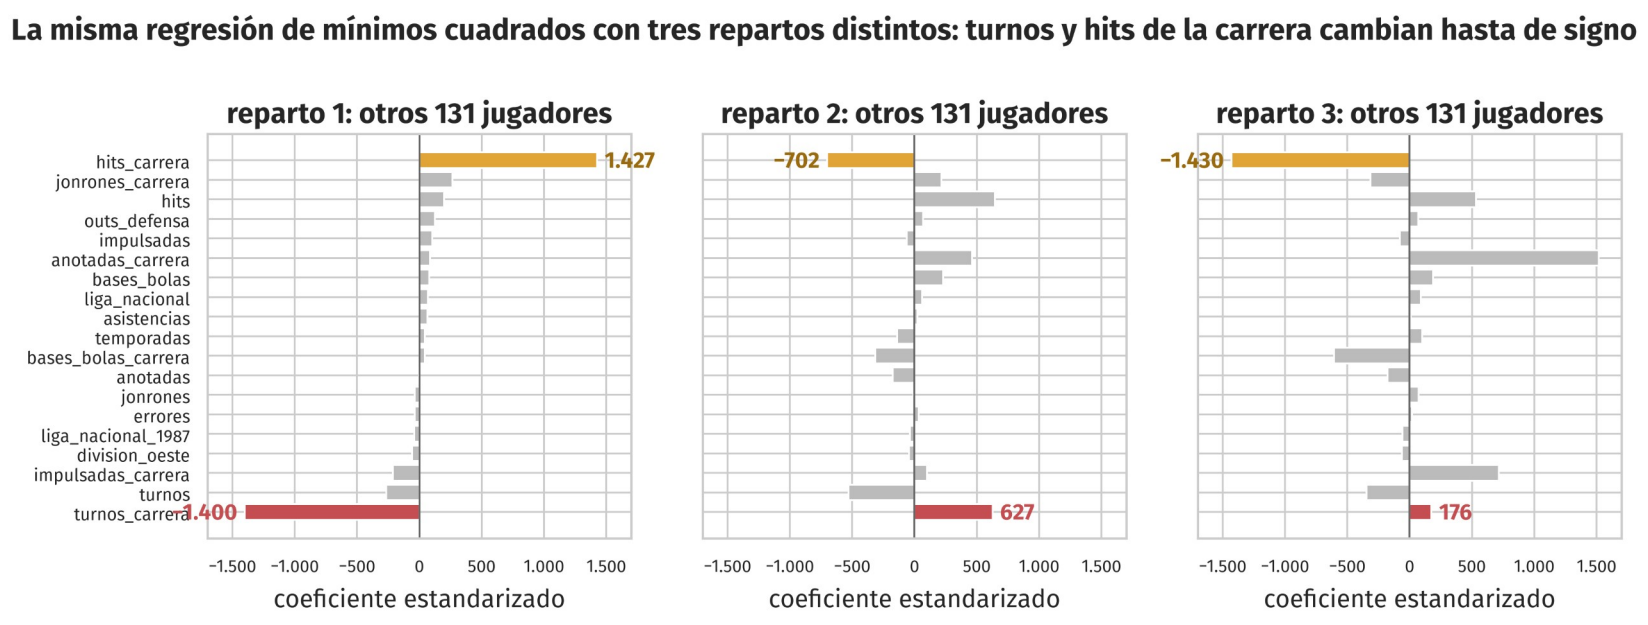
Estandarizadas, cada coeficiente dice cuánto cambia el salario por una desviación estándar, y se pueden comparar. La media y la desviación salen del entrenamiento.

Regresión lineal múltiple con 19 variables



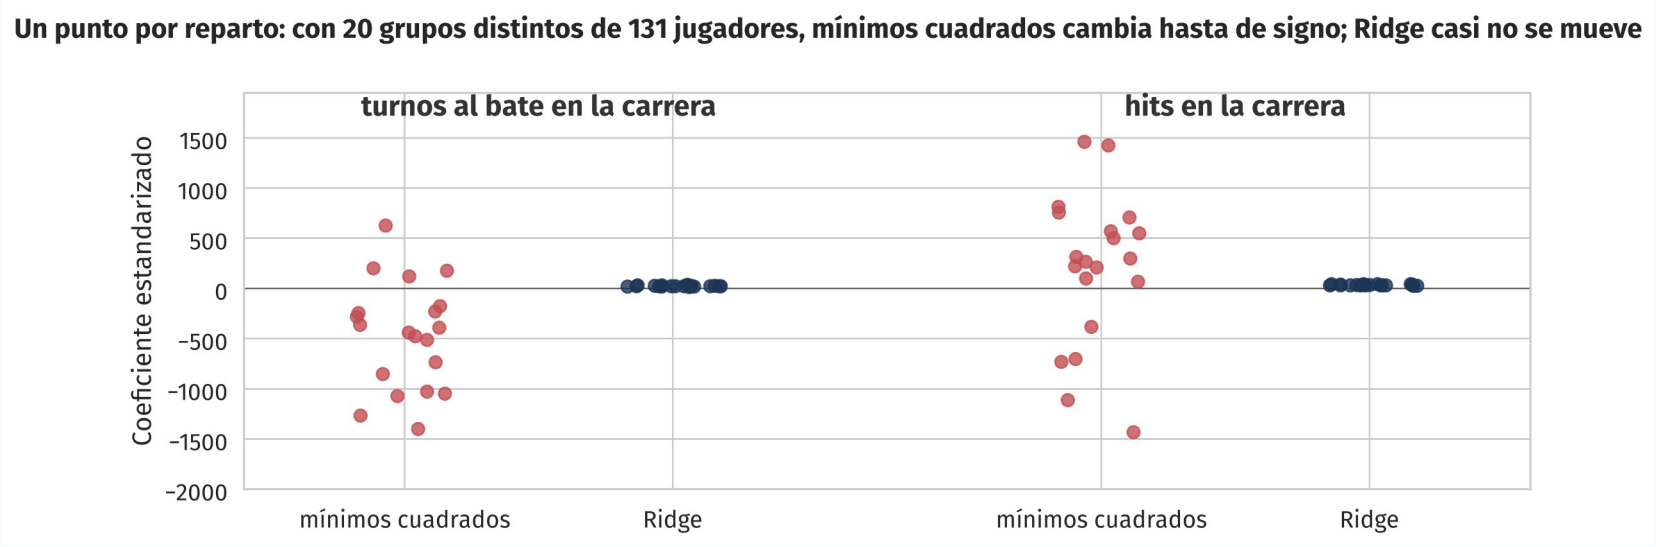
A turnos y hits de la carrera, con correlación 0,995, les da coeficientes enormes de signo opuesto que se cancelan. Su error típico (RMSE) es de 301 mil dólares con los jugadores que vio y de 342 mil con los nuevos.

Otros jugadores, otros coeficientes



Tres repartos distintos de los 263 jugadores y la misma regresión: turnos y hits de la carrera cambian de tamaño y hasta de signo según qué 131 jugadores tocaron.

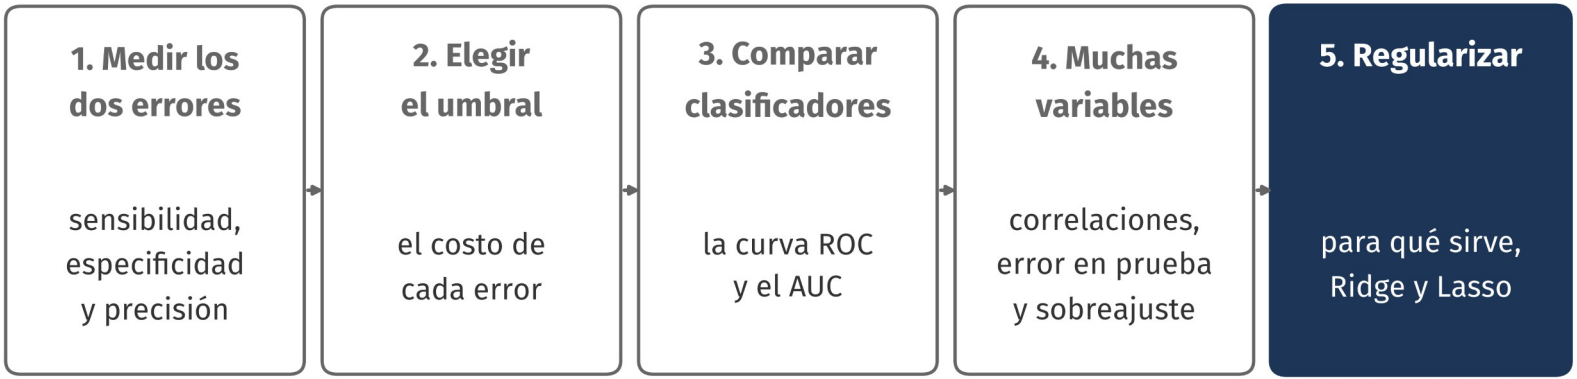
Los coeficientes varían mucho entre muestras



Cada punto es un reparto distinto. Con mínimos cuadrados, el coeficiente de turnos de la carrera va de −1.400 a 627 según qué 131 jugadores tocaron: ese es el problema. Con Ridge, de 15 a 36. Es la clase 06: todo número que sale de una muestra se mueve.

El mapa de la clase

Un modelo se juzga por sus errores donde importan: con el costo correcto y en datos que no vio

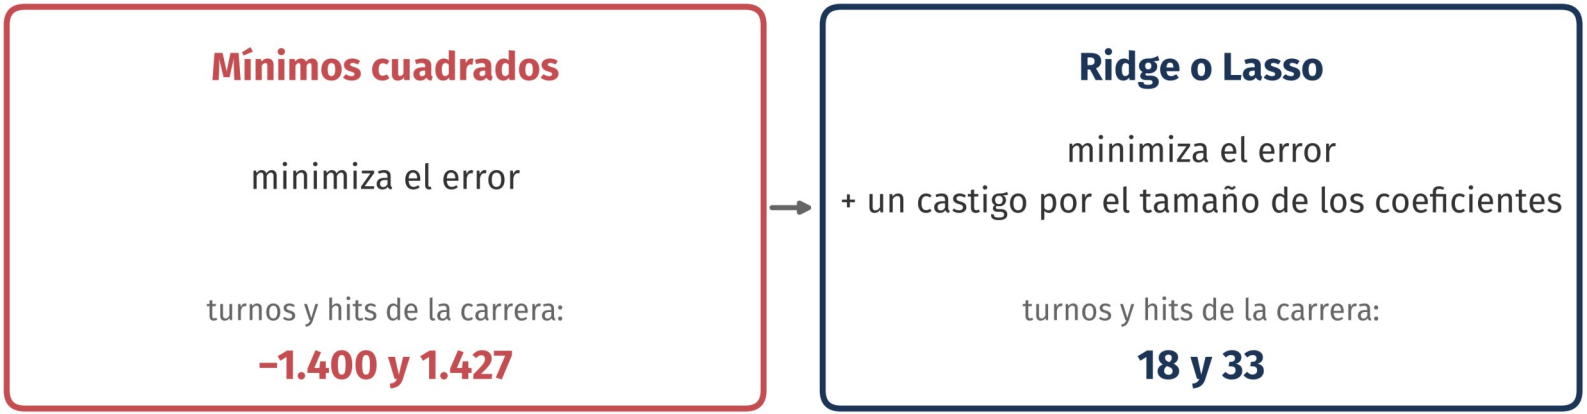


clasificar: los clientes de la tarjeta

regresión: los salarios de béisbol

¿Qué es regularizar?

Regularizar: ajustar con todas las variables, pero empujando los coeficientes hacia 0



Cuánto se empujan lo fija λ, un número que se elige con los datos.

¿Para qué regularizar?

Regularizar es obligar al modelo a usar coeficientes chicos. Lo que cambia con Ridge:

en miles de dólares; en verde, el mejor de cada fila	mínimos cuadrados	Ridge
coeficientes de turnos y hits de la carrera	−1.400 y 1.427	18 y 33
cuánto cambia la predicción de un jugador si se usa otra muestra	± 97	± 48
error con los 131 jugadores que el modelo vio	301	340
error con los 132 jugadores nuevos	342	316

Coeficientes chicos: el modelo depende menos de su muestra y se equivoca menos con lo nuevo.

Con coeficientes chicos, el modelo depende menos de su muestra: pierde un poco con los jugadores que vio y gana con los nuevos.

¿Cuándo conviene regularizar?

Conviene cuando

- el objetivo es predecir casos nuevos
- hay muchas variables para pocos datos
- hay variables que dicen casi lo mismo

Las señales, en este caso

- 19 variables para 131 jugadores
- correlación 0,995 y coeficientes enormes y opuestos: −1.400 y 1.427
- error 301 en entrenamiento y 342 en prueba
- coeficientes que cambian con la muestra

Si hay duda, se prueba: con λ elegido con los datos, un modelo que no lo necesitaba vuelve a mínimos cuadrados.

Con pocas variables y muchos datos da casi lo mismo que mínimos cuadrados. Y no sirve para leer coeficientes con valores p, como en la clase 06: aquí se achican a propósito.

Cómo se escribe: el error más un castigo

Cómo se escribe: al error del modelo se le suma un castigo por el tamaño de los coeficientes

Mínimos cuadrados (clase 04):

$$\text{minimizar} \quad \sum_i (y_i - \hat{y}_i)^2$$

el error del modelo

Ridge:

$$\text{minimizar} \quad \sum_i (y_i - \hat{y}_i)^2 \; + \; \lambda \sum_j b_j^2$$

más el castigo

Lasso:

$$\text{minimizar} \quad \sum_i (y_i - \hat{y}_i)^2 \; + \; \lambda \sum_j |b_j|$$

i recorre los jugadores, de 1 a 131: el error se suma sobre los jugadores. j recorre las variables, de 1 a 19: el castigo se suma sobre los coeficientes.

Con dos coeficientes, 3 y −4:

Ridge castiga $3^2 + (-4)^2 = 9 + 16 = 25$

Lasso castiga $|3| + |-4| = 3 + 4 = 7$

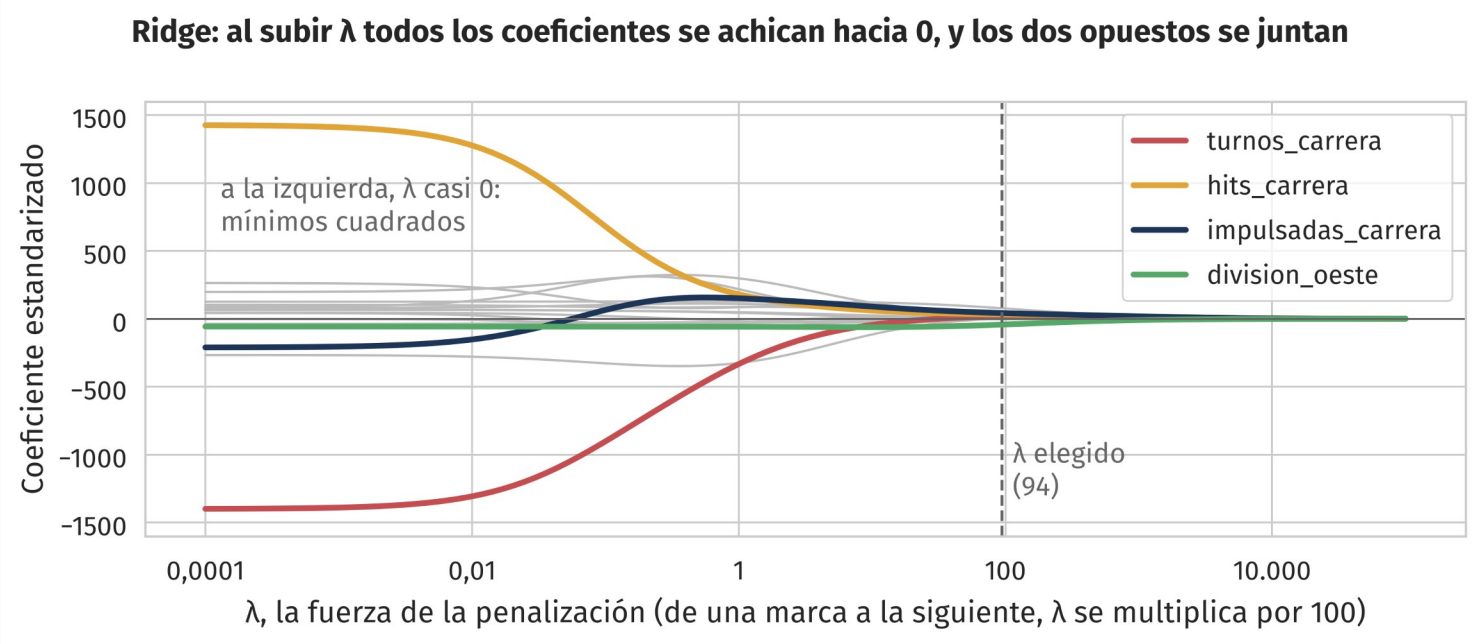
λ decide cuánto pesa el castigo: más λ, coeficientes más chicos. Como el castigo suma coeficientes de variables distintas, se usan las variables estandarizadas.

Qué es cada símbolo

Qué es cada símbolo

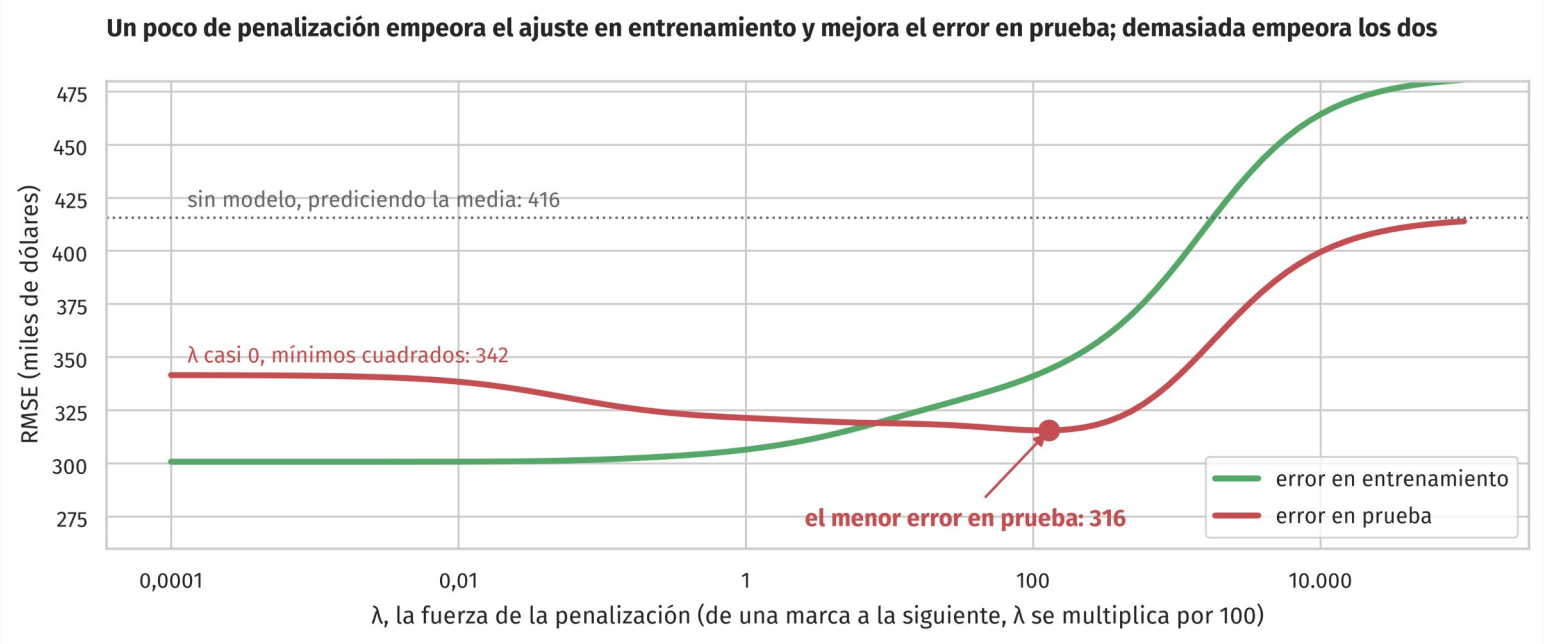
$\sum_i (y_i - \hat{y}_i)^2$	la suma de los residuos al cuadrado: qué tan bien se ajusta el modelo a los 131 jugadores
i	el número del jugador, de 1 a 131: la suma del error recorre los jugadores
b_j	el coeficiente de la variable j, con las variables estandarizadas (el intercepto no se castiga)
j	el número de la variable, de 1 a 19: la suma del castigo recorre los coeficientes
λ (lambda)	cuánto pesa el castigo: más λ, coeficientes más chicos (scikit-learn lo llama alpha)
$\lambda = 0$	no hay castigo: es mínimos cuadrados
λ muy grande	todos los coeficientes van a 0 y el modelo predice el salario promedio

Ridge: todos los coeficientes se achican



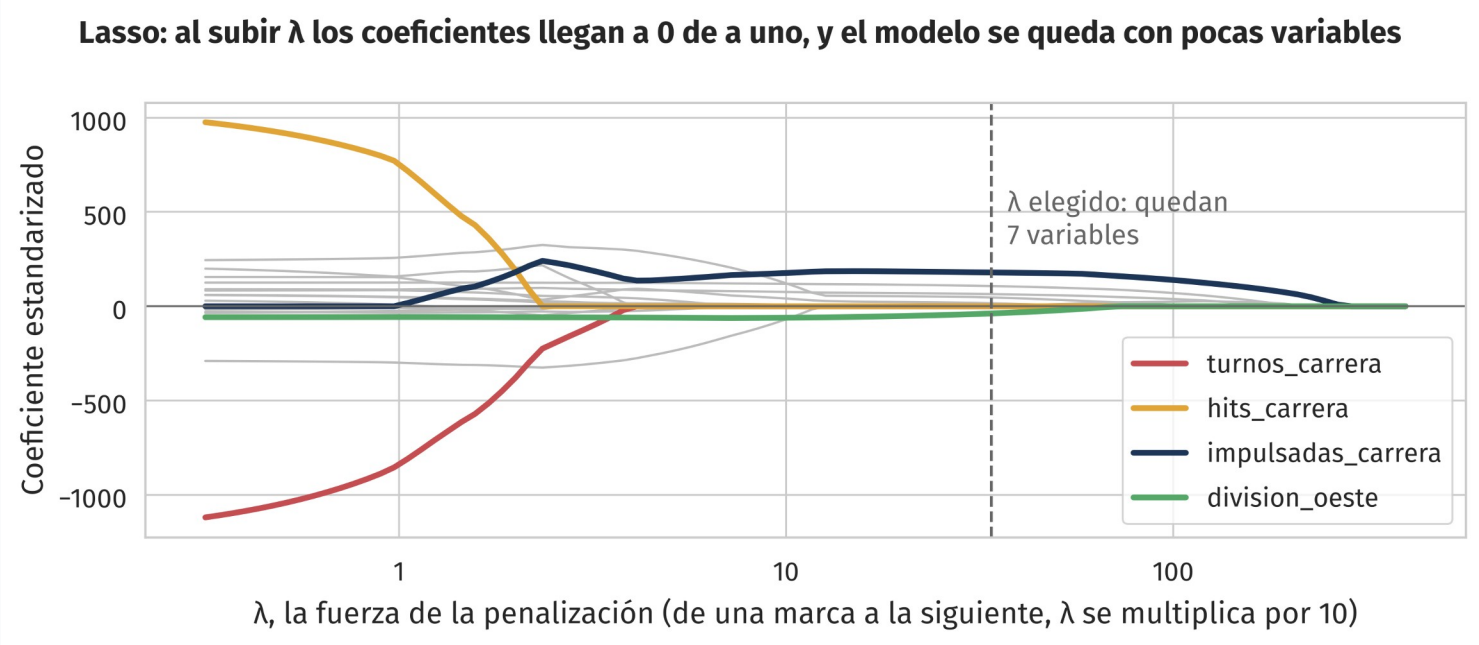
A la izquierda, λ casi 0: mínimos cuadrados, con los opuestos de −1.400 y 1.427. Al subir λ se achican y se juntan; ninguno llega exactamente a 0.

El error de Ridge según λ



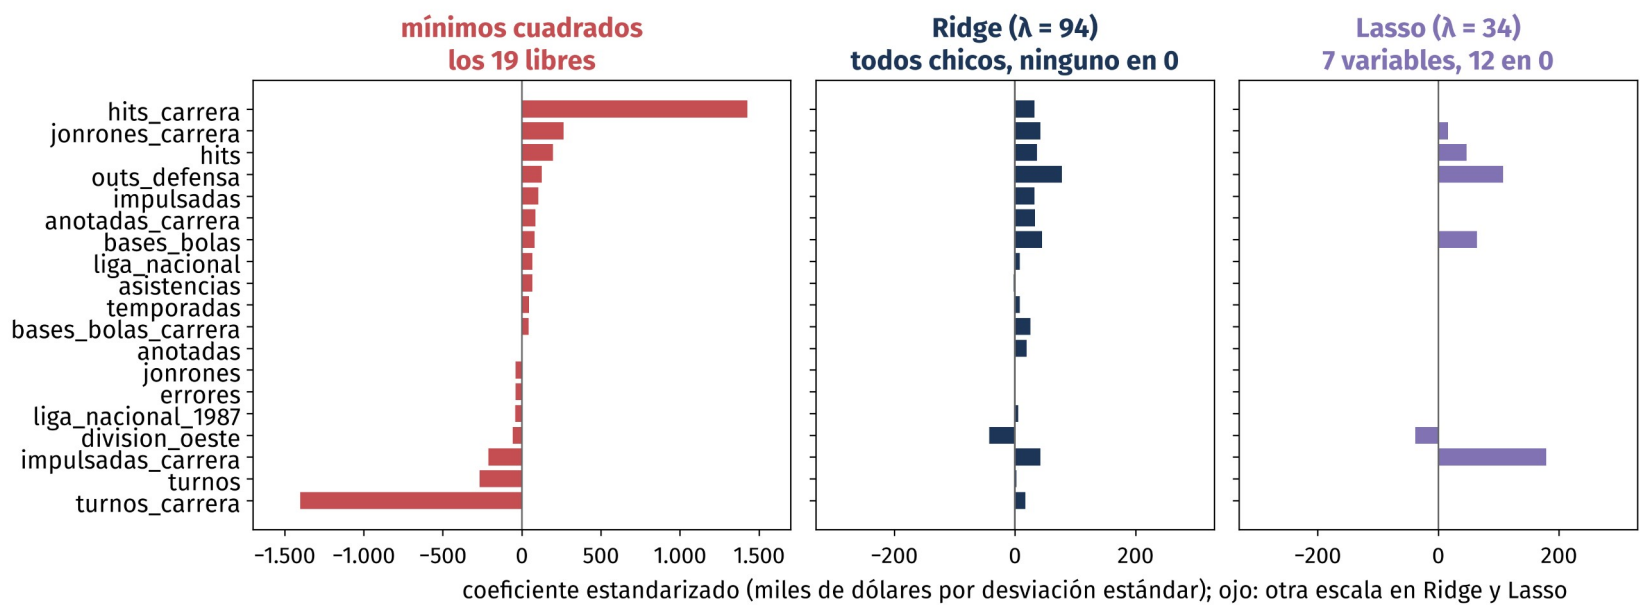
El error en entrenamiento solo sube con λ. El de prueba baja de 342 a 316 y después sube. El λ no se elige mirando la prueba, sino con validación cruzada.

Lasso: los coeficientes se apagan de a uno



Al subir λ, los coeficientes llegan exactamente a 0 de a uno: el modelo elige variables. Con el λ elegido quedan 7 de las 19, como en el libro.

Los 19 coeficientes con cada método

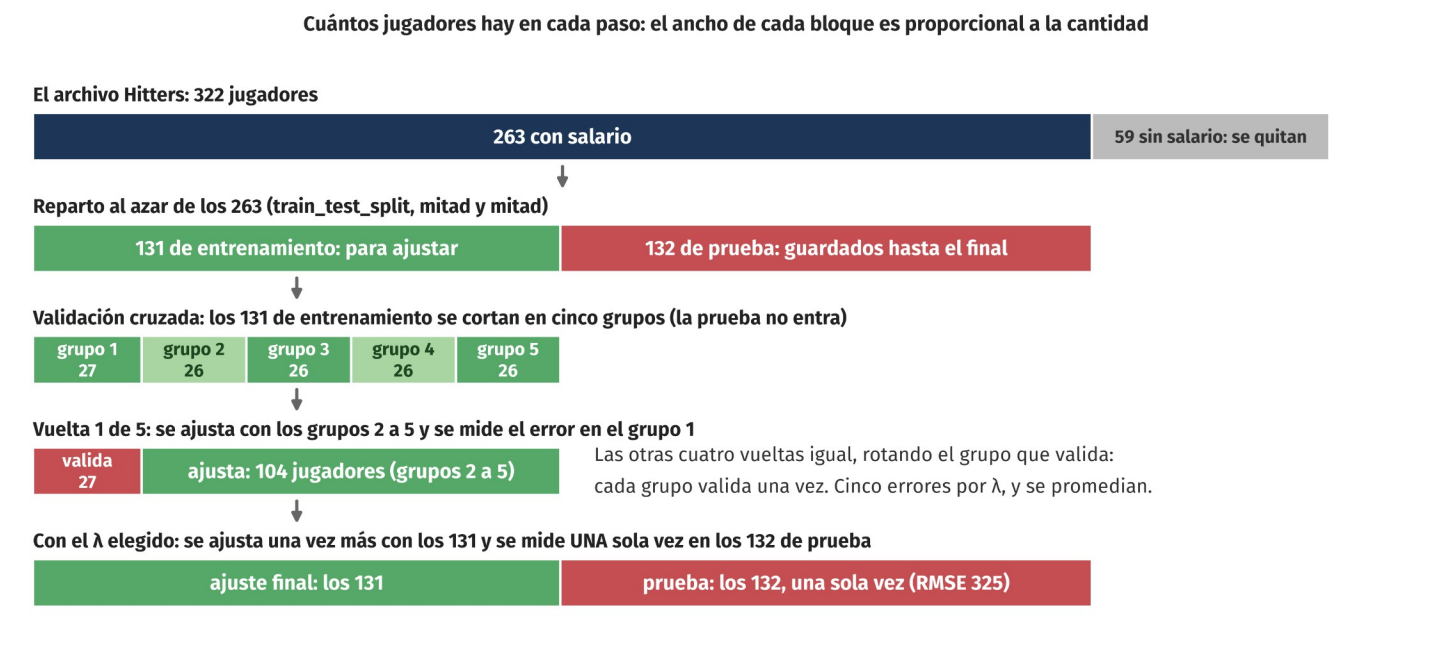


Ridge deja los 19 chicos y distintos de 0; Lasso deja 7 y lleva 12 exactamente a 0.

¿Qué es la validación cruzada?

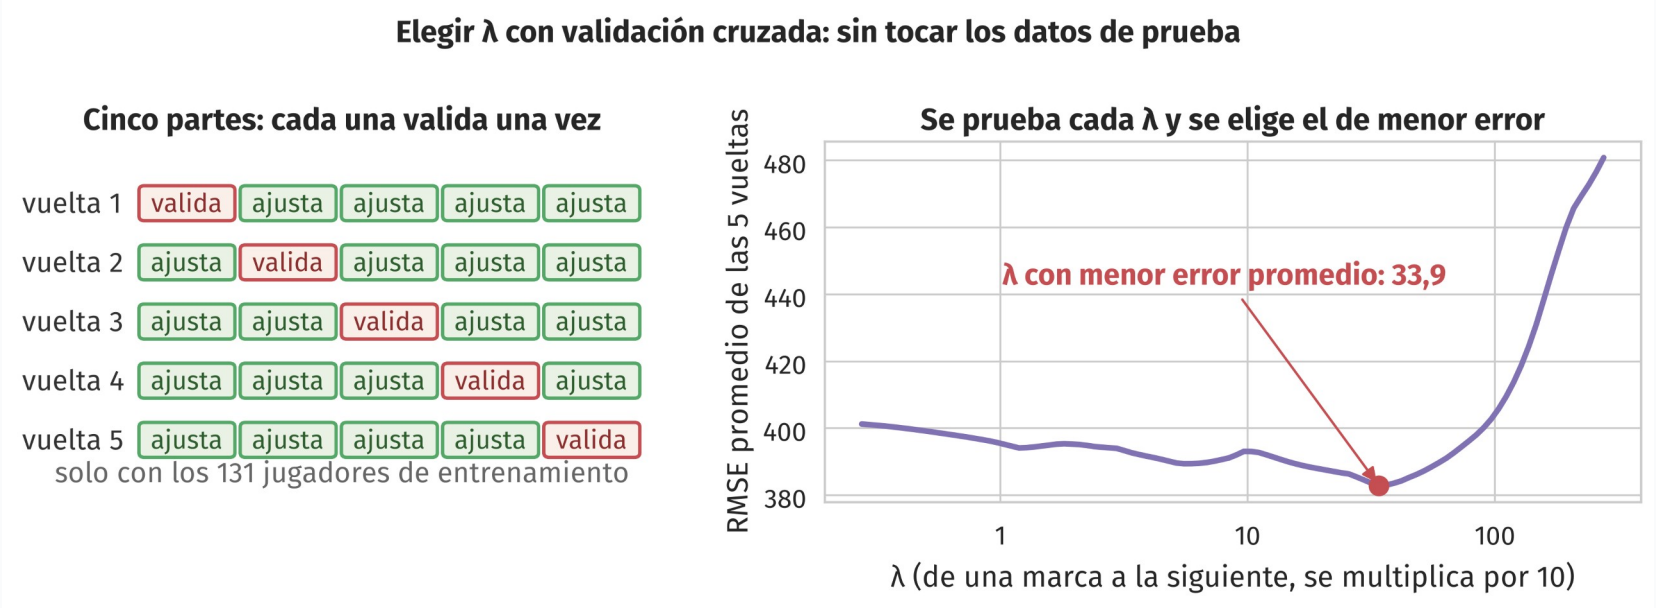
- **Una forma de elegir λ sin tocar los datos de prueba.**
- El problema: la prueba es para la medición final, y el error de entrenamiento siempre prefiere λ = 0.
- La idea: apartar un grupo de jugadores, ajustar el modelo con el resto y medir el error en el grupo apartado. Se repite rotando el grupo, de modo que cada grupo se use como conjunto de validación exactamente una vez.
- Con cinco grupos: por cada λ, cinco errores y su promedio. Gana el λ de menor promedio (James et al., 2013, p. 181).

Cuántos jugadores hay en cada paso



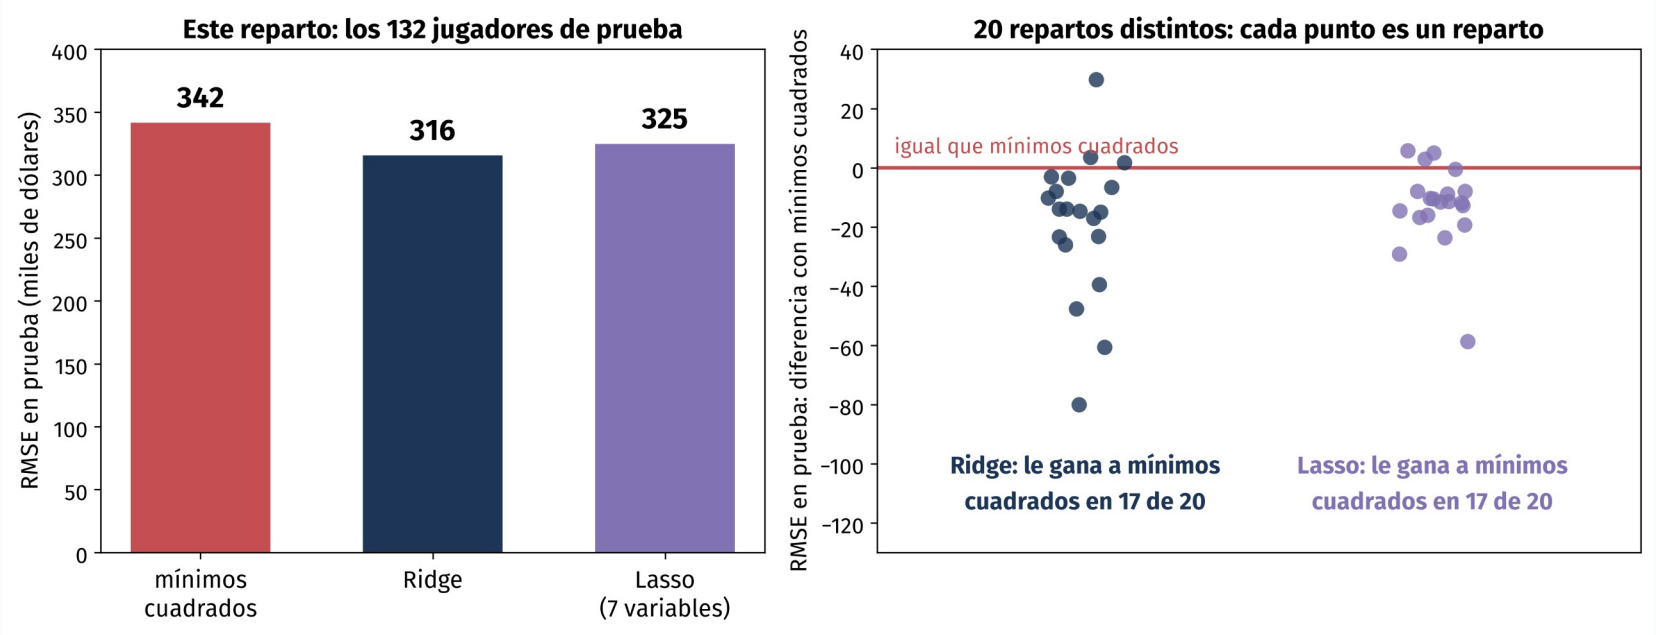
Los cinco grupos salen solo de los 131 de entrenamiento: 27, 26, 26, 26 y 26. En cada vuelta, cuatro grupos ajustan y uno valida. Los 132 de prueba se usan una sola vez, al final.

Cómo elegir λ: validación cruzada



Para cada λ se ajusta con cuatro partes del entrenamiento y se mide en la quinta, cinco veces, y se promedia. Se elige el λ de menor error; la prueba queda intacta.

El resultado en datos que no vio



Ridge baja el error de 342 a 316, y Lasso a 325 con 7 variables. En 20 repartos distintos de los 263 jugadores, Ridge le gana a mínimos cuadrados en 17 y Lasso también en 17: cada uno se compara con mínimos cuadrados, no entre sí.

Cómo quedan los modelos finales

Lasso (λ = 34): 7 variables; las otras 12 tienen coeficiente 0. 533 es el salario promedio de los 131 de entrenamiento.

```
salario = 533  + 47·z(hits)  + 2·z(impulsadas)  + 64·z(bases_bolas)
          + 16·z(jonrones_carrera)  + 179·z(impulsadas_carrera)  + 107·z(outs_defensa)
          − 38·z(division_oeste)
```

Ridge (λ = 94): las 19 variables, con coeficientes entre -43 y 77; las siete de la carrera, entre 8 y 42.

Cómo se lee el 179 de impulsadas_carrera

media en el entrenamiento	desviación estándar	la variable estandarizada
341 impulsadas	**353 impulsadas**	**z = (impulsadas − 341) / 353**

353 impulsadas más en la carrera (una desviación estándar) son 179 mil dólares más al año, con el resto igual.

Son coeficientes achicados a propósito: sirven para predecir y para ver qué pesa más, no para leer efectos con valores p.

Ridge y Lasso en scikit-learn

```
escala = StandardScaler().fit(X_ent)
Z_ent = escala.transform(X_ent)
Z_pru = escala.transform(X_pru)
lasso = LassoCV(cv=5).fit(Z_ent, y_ent)
lasso.predict(Z_pru)
```

- LassoCV elige λ con validación cruzada; Ridge es igual, con RidgeCV. scikit-learn llama alpha a λ.

¿Ridge o Lasso?

Ridge y Lasso: la misma idea, dos castigos, dos resultados

	Ridge	Lasso
castigo	suma de cuadrados: $\lambda \Sigma b^2$	suma de valores absolutos: $\lambda \Sigma \lvert b \rvert$
qué hace con los coeficientes	achica todos; ninguno llega a 0	achica todos y lleva algunos a 0
el modelo que deja	usa las 19 variables	usa 7: elige variables
cuándo conviene	muchas variables aportan un poco o dicen lo mismo	se sospecha que pocas variables importan; se quiere un modelo simple
error en prueba, este reparto	316 (mínimos cuadrados: 342)	325 (mínimos cuadrados: 342)

Ninguno es mejor en todos los casos (James et al., p. 224). En los dos, λ se elige con validación cruzada y el error se mide en prueba.

Conclusiones

- **Un modelo se juzga por sus errores donde importan, con el costo correcto y en datos que no vio.**
- En un clasificador, la matriz separa los dos errores; sensibilidad, especificidad y precisión miden cada uno, y el umbral se elige con el costo de cada error, no por defecto en 0,5.
- En una regresión con muchas variables, el error que vale es el de prueba: mínimos cuadrados se ajusta al azar de su muestra, y Ridge o Lasso lo corrigen castigando los coeficientes grandes, con λ elegido por validación cruzada.

Síntesis

- Sensibilidad, especificidad y precisión miden un error por vez; la exactitud los mezcla.
- El umbral de menor costo es costo FP / (costo FP + costo FN); con costos iguales, 0,5.
- La curva ROC compara modelos con todos los umbrales; el AUC la resume.
- El error que vale es el de prueba, en clasificación y en regresión; importa cuando hay muchas variables para pocos datos.
- Ridge achica todos los coeficientes; Lasso lleva algunos a 0; λ se elige con validación cruzada.

Próximas clases

- **Viernes 30 de octubre: Control Q3 al inicio (los informes de OpenAI y del AISI). Después, introducción al aprendizaje automático: tipos de aprendizaje, función de pérdida y riesgo esperado; validación cruzada; reducción de dimensionalidad con PCA.**
- Viernes 6 de noviembre: clustering (k-means y jerárquico) y el avance opcional de proyecto.
- Viernes 13 de noviembre (fecha por confirmar): se entrega la Tarea 2 por Aula.

Referencias

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2013). An Introduction to Statistical Learning. Springer. Pp. 145 a 149 (sensibilidad, especificidad y curva ROC, con los datos Default); pp. 165 a 167 (precisión, con los datos Caravan); sección 5.1.3, p. 181 (validación cruzada); sección 6.2, pp. 214 a 228 (Ridge y Lasso); laboratorio 6.6, pp. 251 a 255 (Ridge y Lasso con los datos Hitters). PDF gratuito en statlearning.com.

Documentación de scikit-learn sobre modelos lineales, Ridge y Lasso: scikit-learn.org/stable/modules/linear_model.html

Datos: Default y Hitters, del libro de James et al. (statlearning.com), en datos/clase06/ y datos/clase07/ del repositorio.