

¿Qué significa EDA?

Análisis Exploratorio de Datos

Daniela Opitz

INF-396 · Departamento de Informática · UTFSM · Material de apoyo, clases 2 y 3

Una situación conocida

- ▶ Nos entregan un archivo con 27.015 filas de emisiones industriales.
- ▶ La tentación: correr de inmediato un modelo, calcular un promedio, sacar una conclusión.
- ▶ El problema: todavía no sabemos qué hay adentro.
 - ¿Qué representa una fila?
 - ¿Qué columnas tienen datos y cuáles vienen vacías?
 - ¿Los valores son razonables o hay errores de registro?
- ▶ **El análisis exploratorio es la etapa que responde esas preguntas.**

El origen de la idea

John Tukey, 1977

Exploratory Data Analysis (Tukey, 1977)

- ▶ John Tukey, estadístico de Princeton y Bell Labs, publica en 1977 el libro que le da nombre al área.
- ▶ Su planteamiento fue una provocación para la estadística de la época:
 - La estadística se había concentrado en confirmar hipótesis ya formuladas.
 - Tukey reivindica el paso anterior: mirar los datos para descubrir qué preguntas vale la pena hacer.
- ▶ Para Tukey, la exploración es trabajo de detective: buscar pistas antes de acusar a nadie.
- ▶ **EDA no es una técnica: es una actitud frente a los datos.**

Exploratorio y confirmatorio: dos momentos distintos

- ▶ **Análisis exploratorio: generar hipótesis.**
 - Flexible, gráfico, iterativo.
 - La pregunta es abierta: ¿qué hay aquí que valga la pena entender?
- ▶ **Análisis confirmatorio: poner a prueba hipótesis.**
 - Formal, con supuestos y tests (lo veremos en inferencia, unidad 5).
 - La pregunta es cerrada: ¿es cierto este efecto que propuse?
- ▶ **Confundir los dos momentos es peligroso: la hipótesis que salió de los datos no puede confirmarse con los mismos datos.**

Qué se hace al explorar

Cuatro preguntas que guían el EDA


Las preguntas del explorador

- ▶ ¿Qué forma tienen los datos? Distribución de cada variable: centro, dispersión, asimetría.
- ▶ ¿Qué es típico y qué es extremo? Medidas de resumen y valores atípicos.
- ▶ ¿Qué falta? Datos ausentes, y si su ausencia significa algo.
- ▶ ¿Qué se relaciona con qué? Comparaciones entre grupos y asociaciones entre variables.
- ▶ **Cada respuesta cambia la decisión siguiente: qué limpiar, qué transformar, qué modelar.**

Explorar es dejar que los datos sorprendan




La misma variable, mirada de nuevo



Lo que la exploración reveló

- ▶ La media (0,38 t) es 66 veces la mediana (0,006 t).
- ▶ Casi todos los establecimientos emiten poco; unos pocos emiten muchísimo.
- ▶ Sin explorar, habríamos reportado un promedio que no describe a nadie.
- ▶ **Este hallazgo cambia el análisis completo: qué medida reportar, qué escala usar, qué modelo tiene sentido.**



El ciclo del EDA

- ▶ Explorar no es una lista de pasos: es un ciclo que se repite.
 - 1. Hacer una pregunta sobre los datos.
 - 2. Responderla con un resumen numérico o un gráfico.
 - 3. Mirar el resultado: ¿qué sorprende?, ¿qué no cuadra?
 - 4. Esa sorpresa genera la siguiente pregunta.
- ▶ El ciclo se detiene cuando uno entiende los datos lo suficiente para el paso siguiente.
- ▶ **Por eso el EDA se hace en un notebook: el registro del ciclo es parte del resultado.**

El EDA dentro de un proyecto de datos

- ▶ En el ciclo de vida que vimos en la clase 1, el EDA va después de obtener los datos y antes de modelar.
- ▶ Pero en la práctica reaparece todo el tiempo:
 - Al limpiar: la exploración muestra qué hay que limpiar.
 - Al modelar: los residuos de un modelo también se exploran.
 - Al comunicar: los gráficos del EDA suelen ser los que mejor explican el resultado.
- ▶ **En este curso: EDA numérico hoy, métodos gráficos y visualización la próxima clase.**

Síntesis

- ▶ EDA es la etapa de mirar los datos antes de modelarlos, y la actitud de dejarse sorprender por ellos.
- ▶ Nace con Tukey (1977) como contrapeso al análisis puramente confirmatorio.
- ▶ Explora la forma, lo típico y lo extremo, lo que falta y lo que se relaciona.
- ▶ Es un ciclo de preguntas y respuestas, no una receta fija.
- ▶ **Un buen EDA evita conclusiones equivocadas: el promedio de las emisiones era la prueba.**

Referencias

- ▶ Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.
- ▶ Bruce, P., Bruce, A. y Gedeck, P. (2020). Practical Statistics for Data Scientists, 2ª ed. O'Reilly. Capítulo 1.
- ▶ Datos: Registro de Emisiones y Transferencias de Contaminantes (RETC), Ministerio del Medio Ambiente. <https://datosretc.mma.gob.cl>